



Análisis crítico e interpretable de la clasificación de etapas del sueño a partir de señales de dispositivos wearable

Grado en Ingeniería Informática

Trabajo Fin de Grado

Autor:

Alejandro Cerezal Jiménez

Tutor/es:

Manuel Campos Martínez



Facultad
de Informática
UMU

Análisis crítico e interpretable de la clasificación de etapas del sueño a partir de señales de dispositivos wearable

Análisis de la importancia de las características fisiológicas en la clasificación de etapas del sueño.

Autor

Alejandro Cerezal Jiménez


Tutor

Manuel Campos Martínez

Departamento de Informática y Sistemas



UNIVERSIDAD
DE MURCIA



Facultad
de Informática

Grado en Ingeniería Informática

Murcia, 27 de Agosto de 2026

Convocatoria de Junio

Declaración firmada sobre originalidad del trabajo

D./Dña. **Alejandro Cerezal Jiménez**, con DNI **24426219N**, estudiante de la titulación de **Grado en Ingeniería Informática** de la Universidad de Murcia y autor del TFG titulado “**Análisis crítico e interpretable de la clasificación de etapas del sueño a partir de señales de dispositivos wearable**”.

De acuerdo con el Reglamento por el que se regulan los Trabajos Fin de Grado y de Fin de Máster en la Universidad de Murcia (aprobado C. de Gob. 30-04-2015, modificado 22-04-2016, 28-09-2018 y 28/06/2022), así como la normativa interna para la oferta, asignación, elaboración y defensa de los Trabajos Fin de Grado y Fin de Máster de las titulaciones impartidas en la Facultad de Informática de la Universidad de Murcia (aprobada en Junta de Facultad el 19-06-2025)

DECLARO:

Que el Trabajo Fin de Grado presentado para su evaluación es original y de elaboración personal. Todas las fuentes utilizadas han sido debidamente citadas. Así mismo, declara que no incumple ningún contrato de confidencialidad, ni viola ningún derecho de propiedad intelectual e industrial

Murcia, a 27 de Agosto de 2026



Fdo.: Alejandro Cerezal Jiménez
Autor del TFG

Resumen

La clasificación automática de etapas del sueño mediante dispositivos *wearable* constituye una línea de investigación cada vez más relevante, al ofrecer una alternativa menos intrusiva y más escalable que la polisomnografía clínica. Sin embargo, las señales registradas desde dispositivos de muñeca presentan limitaciones importantes: son más ruidosas, contienen menos información fisiológica que una PSG completa y dificultan especialmente la separación entre fases de sueño con patrones similares. En este contexto, el presente trabajo aborda la clasificación de etapas del sueño a partir de señales procedentes de dispositivos *wearable*, priorizando tanto la interpretabilidad de los modelos como la validez metodológica de los resultados.

Para ello, se emplea la base de datos DREAMT, publicada en PhysioNet, que contiene registros de 100 participantes monitorizados durante un estudio nocturno del sueño con una pulsera Empatica E4 y anotaciones clínicas derivadas de polisomnografía. Las señales utilizadas incluyen pulso de volumen sanguíneo (BVP), frecuencia cardíaca (HR), intervalos entre latidos (IBI), acelerometría triaxial (ACC), actividad electrodérmica (EDA) y temperatura cutánea (TEMP). A partir de estas señales se realiza un proceso de preprocesamiento y extracción de características fisiológicas por épocas de 30 segundos, obteniendo variables estadísticas, cardiovasculares, de movimiento, temperatura y respuesta electrodérmica. Posteriormente, se aplica una selección de características basada en multicolinealidad para reducir redundancias y mejorar la interpretación de los modelos.

El trabajo evalúa dos modelos basados en árboles de decisión: *Random Forest* y *LightGBM*. Ambos se entrenan para dos problemas de clasificación: una tarea binaria vigilia/sueño y una tarea multiclase W/NREM/REM. Para evitar fugas de información, la partición de los datos se realiza por sujeto mediante *GroupKFold*, de forma que las épocas de un mismo participante no aparezcan simultáneamente en entrenamiento y validación. Asimismo, las técnicas de balanceo de clases y la optimización de hiperparámetros se restringen al conjunto de entrenamiento, preservando un escenario de evaluación más próximo a una aplicación real.

Los resultados muestran que ambos modelos son capaces de identificar patrones fisiológicos útiles para diferenciar sueño y vigilia. En la clasificación binaria, *Random Forest* obtiene una exactitud de 0.77 y un F1-Macro de 0.68, mientras que *LightGBM* alcanza una exactitud de 0.73 y un F1-Macro de 0.67. No obstante, el rendimiento

desciende en la clasificación W/NREM/REM, donde la fase REM resulta especialmente difícil de detectar. Esta dificultad se debe tanto a la menor representación de dicha clase como a la ambigüedad fisiológica de las señales de muñeca, ya que REM comparte características con la vigilia y con el sueño NREM.

El análisis de interpretabilidad mediante SHAP permite comprobar que los modelos se apoyan en relaciones fisiológicamente coherentes. Las variables de movimiento y frecuencia cardíaca son relevantes para separar vigilia y sueño, mientras que la baja actividad motora, la frecuencia cardíaca estable, la temperatura periférica y ciertas respuestas electrodérmicas contribuyen a la identificación de sueño NREM. En cambio, las explicaciones asociadas a REM son menos consistentes, lo que refuerza la dificultad observada en las métricas.

Finalmente, se realiza un análisis crítico de prácticas metodológicas presentes en la literatura. Los experimentos muestran que dividir los datos por épocas o evaluar sobre conjuntos previamente balanceados puede inflar artificialmente las métricas, generando una imagen excesivamente optimista del rendimiento real. Por tanto, este trabajo concluye que la clasificación de sueño con dispositivos *wearable* es prometedora, pero debe evaluarse con protocolos rigurosos, separación por sujeto e interpretabilidad fisiológica para evitar conclusiones engañosas.

Palabras clave: clasificación de etapas del sueño; dispositivos *wearable*; DREAMT; Random Forest; LightGBM; SHAP; señales fisiológicas; interpretabilidad; fuga de información.

Extended Abstract

Sleep is a fundamental physiological process whose structure is not homogeneous throughout the night. Instead, it is organised into recurring stages that include wakefulness, non-rapid eye movement sleep and rapid eye movement sleep. The correct identification of these stages is relevant in clinical contexts because changes in sleep architecture may reflect respiratory disorders, neurological alterations, fragmented sleep, fatigue, or impaired cognitive functioning. Traditionally, sleep staging is performed by trained experts using polysomnography, which records multiple physiological signals such as brain activity, eye movements, muscle tone, respiration and oxygen saturation. Although polysomnography remains the clinical reference standard, it is expensive, intrusive and difficult to scale outside specialised sleep laboratories. This limitation has encouraged growing interest in automatic sleep-stage classification from wearable devices, which are more comfortable, cheaper and suitable for long-term monitoring in natural environments.

The main challenge addressed in this work is the classification of sleep stages from physiological signals collected with a wrist-worn wearable device. The problem is approached from an interpretable machine learning perspective. Rather than prioritising the highest possible predictive performance through complex deep learning architectures, the study focuses on classical tree-based models combined with explicit feature extraction and explainability analysis. This decision is motivated by two considerations. First, wearable signals are limited and noisy when compared with full polysomnography, so it is important to understand which physiological patterns they actually provide. Second, in a health-related application, a model that obtains apparently good metrics but cannot be interpreted or validated rigorously may be of limited practical value. Therefore, this work aims to build a classification pipeline whose results are not only measurable, but also physiologically meaningful and methodologically reliable.

The general objective of the project is to develop and critically analyse interpretable models for sleep-stage classification using wearable signals. More specifically, the work pursues five objectives. The first is to preprocess the raw signals from the selected database and extract physiological features that summarise each sleep epoch. The second is to train two tree-based classifiers, Random Forest and LightGBM, for both a binary Wake/Sleep task and a three-class W/NREM/REM task. The third is to evaluate the models with standard metrics such as precision, recall, F1-Score, balanced accuracy and confusion matrices. The fourth is to apply SHAP in order to study which extracted

features are most relevant for each model and each class. Finally, the fifth objective is to analyse methodological issues found in the literature, especially data leakage, inappropriate balancing strategies and validation protocols that do not respect subject independence.

The database used in the project is DREAMT, a PhysioNet dataset designed for real-time sleep-stage estimation using multisensor wearable technology. DREAMT contains recordings from 100 participants who underwent an overnight clinical sleep study while wearing an Empatica E4 device on the left wrist. The dataset is particularly appropriate for this work because it combines wearable signals with expert sleep annotations derived from polysomnography. The wearable signals include blood volume pulse, heart rate, inter-beat interval, triaxial accelerometry, electrodermal activity and skin temperature. These signals offer complementary information about cardiovascular activity, body movement, sympathetic nervous system activation and peripheral thermoregulation. The data also contain sleep-stage labels in 30-second epochs, which makes it possible to formulate a supervised learning task where the wearable features are the input and the expert annotations are the target.

An important aspect of DREAMT is that its population is clinically relevant. The participants come from a sleep-disorder laboratory and many of them present respiratory alterations such as obstructive sleep apnea or obesity-related complications. This makes the classification task more realistic and more difficult than it would be in a dataset composed exclusively of healthy subjects. The study focuses on the 64 Hz version of DREAMT, which includes the wearable signals and the aligned sleep annotations. The original labels include wakefulness, N1, N2, N3, REM, a preparation label and missing values. For the purposes of this work, the labels are adapted to two classification settings. The first is a binary Wake/Sleep problem, where all sleep stages are grouped into a single Sleep class. The second is a three-class W/NREM/REM problem, where stages N1, N2 and N3 are grouped into a single NREM class while REM and wakefulness are preserved as separate classes.

The methodological pipeline begins with signal preprocessing. Since wearable data are more exposed to noise and artefacts than clinical recordings, preprocessing is necessary before feature extraction. The implementation is inspired by the public DREAMT_FE repository, but several decisions are adapted and justified. The BVP signal is filtered using a Chebyshev type II band-pass filter, following the frequency ranges supported by previous work on short photoplethysmography signals. The original HR and IBI values provided by DREAMT are preserved after comparison with values recalculated from filtered BVP, because the recalculated heart-rate estimates produced implausible values in some periods. HR values outside a plausible range are removed, outliers are handled, and normalisation is performed at subject level to account for individual baseline differences. Accelerometry is filtered and summarised through features

that capture movement intensity and variability. EDA is decomposed into tonic and phasic components using NeuroKit2, and features are extracted from skin conductance responses. Temperature is filtered by plausible physiological limits and summarised with basic statistics.

Feature extraction is performed epoch by epoch. For BVP, statistical descriptors and Hjorth parameters are computed. For HRV, features such as SDNN, RMSSD, Poincare descriptors, fractal dimensions and sample entropy are considered. HR, IBI and temperature are described through statistics such as mean, median, maximum, minimum and standard deviation. Accelerometry is represented through trimmed statistics and an aggregated movement index derived from the variability of the acceleration magnitude. EDA features describe the intensity and temporal behaviour of skin conductance responses, including height, amplitude, rise time and recovery time. In total, 64 initial features are extracted. However, using all of them would reduce interpretability because many features encode redundant information. For that reason, feature selection based on multicollinearity is applied within the training data. Variables with an absolute correlation above 0.9 are removed, resulting in a final set of 38 features used in the classification pipeline.

A central methodological decision is the way in which the data are split. In sleep-stage classification, a random split by epochs can lead to overly optimistic results because epochs from the same subject may appear in both training and test. This allows the model to exploit subject-specific patterns instead of learning generalisable physiological relations. To avoid this form of leakage, the pipeline uses a subject-wise GroupKFold strategy. The 100 subjects are divided into five groups, and one group is reserved as an independent test subset. Feature selection, class balancing, hyperparameter tuning and model training are performed only on the remaining subjects. This design aims to approximate a real deployment scenario in which the model is evaluated on patients not seen during training.

Class imbalance is another important issue. In the binary task, approximately 26% of the epochs correspond to Wake and 74% to Sleep. In the three-class task, the distribution is approximately 26% Wake, 64% NREM and 10% REM. This imbalance is especially problematic for REM, which is both underrepresented and physiologically difficult to separate from NREM using wrist signals. Several strategies are considered, including synthetic oversampling methods such as SMOTE and ADASYN, and the use of class weights. Since synthetic physiological data may amplify artefacts or reduce natural variability, balancing is restricted to the training subset and evaluated carefully. For the final models, Random Forest uses class weighting in the binary task and ADASYN in the three-class task, while LightGBM uses class weighting in both settings. Hyperparameters are optimised with Grid Search CV using subject-wise grouping and F1-Score as the reference metric.

The two selected models are Random Forest and LightGBM. Both are based on decision trees, but they follow different learning principles. Random Forest builds an ensemble of independent trees trained on random samples and random subsets of features, reducing variance and improving robustness. LightGBM is a gradient boosting method that builds trees sequentially, where each new tree attempts to correct previous errors. These models are suitable for tabular feature-based classification, can capture nonlinear relationships and interactions between physiological variables, and provide a practical balance between performance and interpretability. Their tree structure also makes them compatible with efficient SHAP explanations through TreeSHAP.

The binary Wake/Sleep results show that both models are able to distinguish sleep from wakefulness to a meaningful degree, although the minority Wake class remains challenging. Random Forest obtains an accuracy of 0.7706, a balanced accuracy of 0.6669, an F1-Macro of 0.6814 and an F1-Weighted of 0.7555. LightGBM obtains an accuracy of 0.7257, a balanced accuracy of 0.6785, an F1-Macro of 0.6716 and an F1-Weighted of 0.7302. Random Forest reaches a high F1-Score for the majority Sleep class, around 0.85, but performs worse on Wake, around 0.51. LightGBM produces a slightly more balanced behaviour, sacrificing some accuracy on the majority class to improve the minority-class detection. Overall, these results indicate that wrist signals contain enough information to identify broad sleep-wake patterns, but that class imbalance and physiological variability still limit robust wake detection.

The three-class W/NREM/REM task is considerably more difficult. The models still identify wakefulness with results close to those observed in the binary setting, but they struggle to separate REM from NREM. Random Forest performs somewhat better than LightGBM in balancing the predictions between NREM and REM, suggesting that it captures some relations that distinguish sleep stages within sleep. However, the confusion matrices show that REM is frequently classified as NREM. For Random Forest, the final F1-Macro is 0.46, approximately 33% lower than in the binary classification. The results confirm what is commonly reported in the literature: REM is the most problematic stage when only wrist-worn wearable signals are available. This difficulty can be explained by the fact that REM shares some properties with wakefulness, such as irregular heart activity, and others with NREM, such as reduced motor activity.

The SHAP analysis provides insight into the internal behaviour of the models. In the Wake/Sleep task, both models rely strongly on features related to accelerometry and heart rate. This is physiologically coherent because wakefulness is generally associated with higher movement and higher pulse values, whereas sleep is associated with reduced motor activity and more stable cardiovascular behaviour. Temperature and several cardiovascular descriptors also contribute to the predictions. Random Forest gives particular importance to BVP kurtosis and HRV SDNN, while LightGBM assigns greater

relevance to the intensity of electrodermal responses. These findings suggest that the models are not acting as black boxes that exploit arbitrary correlations, but are at least partially using signals compatible with known sleep physiology.

In the W/NREM/REM task, interpretability becomes more complex. Random Forest gives more importance to accelerometry features, while LightGBM distributes importance across cardiovascular, electrodermal and temperature variables. For NREM, both models associate low movement, low and stable heart rate, and higher peripheral temperature with the class. This is consistent with physiological expectations: NREM sleep is linked to reduced movement, stable autonomic activity and peripheral vasodilation, which may increase skin temperature at the wrist. LightGBM also identifies high electrodermal activity as relevant for NREM, a relation supported by studies that report increased wrist electrodermal activity during deep sleep. For REM, however, the SHAP patterns are less consistent. Random Forest captures the relevance of heart-rate variability, but shows contradictory effects for movement variables. LightGBM gives considerable importance to mean peripheral temperature, but does not establish a clearly separable criterion. These explanations reinforce the interpretation that the poor REM performance is not only a statistical limitation, but also reflects ambiguous physiological evidence in the available signals.

Beyond model performance, the work includes a critical methodological comparison with related studies. Several publications in the field report higher metrics, but some of them use procedures that can inflate performance. Examples include selecting features before the final validation split, optimising hyperparameters on the complete dataset, applying synthetic balancing before cross-validation, evaluating on balanced validation data, or splitting by epochs instead of by subjects. To quantify the effect of these practices, additional experiments are performed with the optimised Random Forest model. When subject independence is ignored and epochs are split randomly, the binary F1-Macro increases from 0.68 to 0.74 and accuracy from 0.77 to 0.81. In the three-class task, F1-Macro increases from 0.46 to 0.51 and accuracy from 0.56 to 0.61. When ADASYN balancing is applied before splitting and evaluation is performed on a balanced distribution, the inflation is larger: the binary F1-Macro rises to 0.84, and the three-class F1-Macro rises to 0.63. REM F1-Score increases artificially from 0.19 to 0.65. These results demonstrate that methodological choices can substantially change the apparent quality of a classifier.

The main conclusion is that interpretable tree-based models can extract meaningful sleep-related patterns from wearable physiological signals, especially for distinguishing sleep from wakefulness and for identifying some characteristics of NREM sleep. However, reliable REM classification remains limited with the available wrist-worn signals. The models are able to recognise reduced movement, stable heart-rate patterns, peripheral temperature changes and electrodermal responses, but these signals do not

provide a sufficiently clear separation between REM and NREM in all cases. A second conclusion is that methodological integrity is as important as model performance. In this domain, optimistic metrics obtained through data leakage or unrealistic validation distributions may lead to misleading claims about clinical usefulness. Therefore, subject-wise validation, strict separation between training and validation, and careful handling of class imbalance are essential.

Future work should explore temporal features that capture the cyclical architecture of sleep, such as contextual information from neighbouring epochs or circadian descriptors. It would also be useful to compare models trained exclusively with PPG-derived features against models that include the full multimodal wearable set, in order to isolate the contribution of accelerometry, temperature and electrodermal activity. More robust strategies for class imbalance should be analysed, considering not only F1-Score but also the physiological plausibility and variability of generated samples. Finally, the classification could be extended to the five original classes W/N1/N2/N3/REM, although this would likely require more data, stronger temporal modelling and potentially hybrid architectures. In summary, this work supports the value of wearable-based sleep analysis, but argues that its development must be guided by interpretability, physiological coherence and rigorous validation.

Keywords: sleep-stage classification; wearable devices; DREAMT; Random Forest; LightGBM; SHAP; physiological signals; data leakage; interpretable machine learning.

Índice general

1. Introducción	1
2. Estado del arte	3
2.1. Estudios basados en explicabilidad	4
3. Análisis de objetivos	9
3.1. Justificación del trabajo	9
3.2. Objetivos específicos	10
4. Materiales	11
4.1. Base de datos DREAMT	11
4.2. Fundamento teórico de los modelos de clasificación	13
4.2.1. Random Forest	13
4.2.2. LightGBM	14
4.3. Fundamento teórico de SHAP	15
4.4. Entorno de programación	17
5. Metodología	19
5.1. Preprocesamiento y extracción de características de DREAMT	19
5.1.1. Preprocesamiento	20
5.1.2. Extracción de características	24
5.2. Descripción de la implementación de clasificación y SHAP	27
5.2.1. Implementación de modelos de clasificación	27
5.2.2. Implementación de explicabilidad con SHAP	31
6. Resultados y análisis	33
6.1. Resultados	33
6.1.1. Selección de características	33
6.1.2. Técnicas de balanceo de clases	34
6.1.3. Hiperparámetros óptimos	34
6.1.4. Métricas obtenidas	35
6.1.5. Análisis de explicabilidad	38
6.1.6. Comparativas	41
6.2. Comparaciones de diseño	42
6.2.1. Análisis crítico de la literatura	43
6.2.2. Experimentos	44

7. Conclusiones y vías futuras	47
7.1. Trabajo futuro	48
Bibliografía	49
Lista de Acrónimos y Abreviaturas	55
A. Resumen del estado del arte	57
B. requirements.txt	59
C. Lista de características extraídas	61
D. Uso de inteligencia artificial	65

Índice de figuras

5.1.	Fases principales del pipeline experimental.	19
5.2.	Comparación entre la señal HR de DREAMT y la derivada de la señal BVP filtrada.	21
5.3.	Comparación entre la señal EDA cruda y preprocesada, tanto a escala original como centradas en 0.	23
5.4.	Fundamentos fisiológicos de la señal EDA [1]	26
5.5.	Pipeline de clasificación y validación del modelo.	31
6.1.	Comparación Random Forest y LightGBM para clasificación Wa- ke/Sleep.	35
6.2.	Matrices de confusión para Wake/Sleep	36
6.3.	Comparación Random Forest y LightGBM para clasificación W/N- REM/REM.	37
6.4.	Matrices de confusión para W/NREM/REM	37
6.5.	Importancia global de características para Wake/Sleep	38
6.6.	Importancia global de características para W/NREM/REM	39
6.7.	Gráfico <i>beeswarm</i> de SHAP para NREM	40
6.8.	Gráfico <i>beeswarm</i> de SHAP para REM	41
6.9.	Comparación resultados tras balancear y no particionar por sujeto en ambas clasificaciones.	45

Índice de tablas

4.1.	Resumen de las señales registradas por el dispositivo Empatica E4 disponibles en DREAMT.	12
4.2.	Resumen del entorno de programación empleado.	17
5.1.	Comparación entre el preprocesamiento propuesto en DREAMT_FE y el preprocesamiento finalmente adoptado.	23
5.2.	Grid de hiperparámetros empleado para cada modelo.	30
6.1.	Técnicas de balanceo empleadas para cada modelo.	34
6.2.	Mejores hiperparámetros obtenidos para Random Forest.	34
6.3.	Mejores hiperparámetros obtenidos para LightGBM.	34
A.1.	Comparación de estudios del estado del arte.	57
B.1.	Dependencias declaradas en <code>requirements.txt</code> y versiones instaladas.	59
C.1.	Características extraídas por señal.	61

1. Introducción

Un buen descanso es vital para la salud. La presencia de malos hábitos de sueño da lugar a desequilibrios hormonales y del sistema inmunitario, que pueden derivar progresivamente en patologías crónicas como la diabetes tipo 2, hipertensión arterial, obesidad y trastornos de salud mental tales como la depresión [2]. Por ello, la población global está cada vez más concienciada con la calidad de su sueño [3].

Desde el punto de vista fisiológico, el sueño no es un estado homogéneo, sino que se organiza en una arquitectura cíclica compuesta por fases de sueño REM (movimiento ocular rápido) y sueño no REM (NREM). El sueño NREM incluye estados progresivamente más profundos, mientras que el sueño REM se caracteriza por una mayor actividad cerebral y se asocia con procesos como la regulación emocional y la consolidación de la memoria. En adultos sanos, el sueño NREM representa aproximadamente el 75–80% del tiempo total de sueño, mientras que el sueño REM supone alrededor del 20–25%, alternándose ambas fases en ciclos de unos 90–120 minutos a lo largo de la noche [4, 5]. Por ello, la calidad del sueño depende de la estabilidad y continuidad de esta arquitectura. La fragmentación del sueño puede modificar la proporción y organización de las fases NREM y REM, reducir la eficiencia del sueño y afectar negativamente a funciones cognitivas como la atención, la inhibición y la sensación subjetiva de fatiga [6]. En consecuencia, el seguimiento de estas fases resulta relevante para evaluar de forma más completa la salud del sueño, detectar alteraciones en su estructura y favorecer intervenciones orientadas a mejorar los hábitos de descanso y el estado general de salud.

La polisomnografía (PSG) se considera el estándar clínico de referencia para el estudio del sueño, ya que permite registrar de forma simultánea múltiples señales fisiológicas, como la actividad cerebral, los movimientos oculares, la actividad muscular, la respiración y la saturación de oxígeno, posibilitando así una identificación precisa de las fases de sueño y de posibles trastornos asociados [7]. Sin embargo, se trata de una técnica costosa, poco accesible y generalmente dependiente de entornos clínicos especializados, lo que dificulta su uso repetido o prolongado en la vida cotidiana. En este contexto, los dispositivos *wearable* han adquirido una relevancia creciente como alternativa cómoda, no invasiva y de bajo coste relativo para el seguimiento longitudinal del sueño, permitiendo recoger señales como acelerometría, frecuencia cardíaca o fotopleletismografía en condiciones domésticas. Esta tendencia refleja un interés cada vez mayor de la población por monitorizar su descanso mediante tecnologías de consumo. En el último año, el porcentaje de usuarios de dispositivos *wearable* que realizan

un seguimiento regular de su sueño ha aumentado de un 16% a un 53% globalmente [3].

Es por ello que el desarrollo de algoritmos de clasificación de fases del sueño basados en datos recogidos mediante dispositivos *wearable* se ha convertido en un área de investigación activa, con el objetivo de mejorar la precisión y utilidad de estas herramientas para la evaluación del sueño en entornos no clínicos. En este contexto, el presente trabajo se centra en la aplicación de técnicas de aprendizaje automático interpretables para poder clasificar las fases del sueño a partir de datos al alcance de todos los usuarios y, principalmente, tratar de descubrir qué características de las señales fisiológicas son más relevantes para esta tarea, con el fin de que futuras investigaciones puedan poner el foco en los atributos más importantes.

2. Estado del arte

Como se ha mencionado, la monitorización del sueño mediante dispositivos wearable es una tendencia creciente entre la población. Esto, junto a difícil accesibilidad a los entornos clínicos basados en PSG, ha hecho que la clasificación automática de etapas del sueño a partir de señales fisiológicas registradas mediante dispositivos *wearable* se haya consolidado en los últimos años como una línea de investigación relevante dentro del análisis computacional del sueño. Sin embargo, la sustitución o aproximación de la información polisomnográfica mediante señales más limitadas, como acelerometría (ACC) o fotopletimografía (PPG), plantea todavía importantes retos desde el punto de vista del modelado, la generalización y la fiabilidad de las predicciones.

En la literatura reciente pueden identificarse dos orientaciones principales en el desarrollo de modelos de clasificación de etapas del sueño en este contexto. La primera se centra en el diseño de modelos cada vez más potentes, capaces de capturar dependencias temporales complejas y mejorar las métricas de clasificación respecto a aproximaciones anteriores. En esta línea se sitúan arquitecturas profundas basadas en redes convolucionales, redes recurrentes, mecanismos de atención, modelos híbridos y, más recientemente, arquitecturas secuenciales avanzadas. Estos trabajos suelen priorizar el rendimiento predictivo, buscando aproximarse lo máximo posible a la clasificación profesional determinada con la evidencia obtenida mediante PSG.

La segunda orientación, que es la que marca el enfoque adoptado en este trabajo, pone el énfasis en la explicabilidad del modelo y en la comprensión de las variables que influyen en la clasificación de las etapas del sueño. En lugar de buscar el mejor rendimiento posible, estos trabajos intentan construir modelos que permitan analizar qué características extraídas de las señales *wearable* contribuyen en mayor medida a distinguir entre vigilia, sueño REM y sueño NREM. Esta perspectiva es especialmente interesante cuando se trabaja con señales fisiológicas reducidas, ya que permite estudiar hasta qué punto variables como el movimiento corporal, la frecuencia cardíaca o medidas derivadas contienen información útil para aproximar la arquitectura del sueño.

2.1. Estudios basados en explicabilidad

A continuación, se analiza la literatura actual respectiva a la clasificación de etapas del sueño centrada en el desarrollo de modelos interpretables. Los estudios referenciados establecen la base para el desarrollo de este trabajo.

“PPG-Based Sleep Stage Classification Using Pulse Wave Feature Fusion and Explainable AI”

En esta línea, Smarandache et al. proponen un modelo interpretable basado en *Random Forest* para la clasificación de etapas del sueño a partir de señales de fotopletimografía (PPG), complementado con explicaciones mediante SHAP [8]. El estudio utiliza registros nocturnos procedentes de 10 voluntarios del Charité Hospital de Berlín [9, 10], todos ellos con trastornos respiratorios del sueño, incluyendo señales PSG y PPG. Las señales se segmentan en épocas de 30 segundos y las etiquetas se obtienen manualmente por expertos. El trabajo plantea tres tareas de clasificación: una clasificación binaria sueño-vigilia, una clasificación de tres clases diferenciando vigilia, NREM y REM, y una clasificación de cuatro clases con vigilia, sueño ligero, sueño profundo (que dividen NREM) y REM.

Hay dos aspectos especialmente relevantes en este trabajo. En primer lugar, la elección del modelo *Random Forest* tras obtener estas mejores métricas de clasificación que otros modelos como SVM, KNN y *Logistic Regression*. Además, destaca el uso de SHAP para analizar la importancia de las variables de entrada para la predicción realizada por el modelo, lo que permite interpretar qué características extraídas de la señal PPG contribuyen a la clasificación de las etapas del sueño. En segundo lugar, lo que llaman *pulse wave feature fusion*. Esto es, la extracción de características estadísticas, temporales y no lineales de la señal PPG medida. La idea fisiológica es que la señal PPG cruda contiene información indirecta como variabilidad cardiovascular, vasodilatación o cambios respiratorios. Estos fenómenos experimentan cambios entre las fases de vigilia, REM y NREM, por lo que se busca que las características mencionadas aporten información discriminativa.

Sin embargo, para reducir dimensionalidad y eliminar variables redundantes, los autores aplican *Recursive Feature Elimination (RFE)* y seleccionan solamente las 10 características más relevantes. El procedimiento es simple, se entrena un modelo con todas las features y se elimina la que menos ha aportado a la clasificación de etapas según SHAP. Este proceso se repite iterativamente hasta conseguir el número de características deseado. El estudio afirma que las 10 features que pasan el filtro, en orden de aportación general a la clasificación, son: dimensión fractal de Higuchi, complejidad de Hjorth, media geométrica, momento central, factor de forma, valor máximo, media

recortada al 25%, valor mínimo, desviación absoluta mediana y media aritmética.

“Interpretable feature-based machine learning for automatic sleep detection using photoplethysmography”

Un enfoque similar es el de Markov et al., que desarrollan un modelo basado en características (*feature-based*) para la clasificación entre sueño y vigilia utilizando PPG [11]. En este caso, la base de datos utilizada es la *Cyclic Alternating Pattern Sleep Database* de PhysioNet [12], compuesta por 84 participantes que presentaban trastornos del sueño, a los que se les realizó un registro completo PSG. Para la clasificación sueño-vigilia se emplearon únicamente las señales PPG y las etiquetas que sirvieron como *ground truth* fueron anotadas por expertos basándose en los registros PSG.

Del preprocesamiento de la señal cruda PPG se obtienen finalmente 85.542 épocas de 30 segundos con su correspondiente etiqueta. Uno de los problemas que se trata en el artículo es el desbalanceo de las clases debido a agrupar todas las etiquetas REM y NREM como *Sleep*. Para equilibrar la distribución de 19% *Wake* y 81% *Sleep*, los autores aplican ADASYN para generar de forma adaptativa muestras sintéticas de la clase minoritaria. En el artículo se realiza un exhaustivo procedimiento de extracción y selección de características. Se obtienen inicialmente 330 características por época y se aplica una selección de variables más elaborada que la descrita en la anterior referencia [8]. Tras un test de normalidad, eliminación de variables redundantes por multicolinealidad y la aplicación del método *SelectFromModel* para filtrar las features que se sitúan por debajo de un umbral de importancia, se obtienen finalmente 75 características para el dataset original y 35 para el dataset balanceado con ADASYN.

Tras comparar varios modelos basados en *LightGBM*, *XGBoost* y *Random Forest*, se eligió este último como clasificador principal. Se realiza una optimización de hiperparámetros por *Matthews Correlation Coefficient (MCC)* aplicando secuencialmente *Randomized Search* y *Grid Search*, que concretan una distribución de parámetros óptima para cada dataset. Para evitar fuga de información entre sujetos, se utiliza una estrategia de validación cruzada agrupada por individuos. Se prueban varios tamaños de partición *GroupKFold*, concluyendo que los resultados son estables. Para estudiar el rendimiento entre distintas patologías, se realiza también una validación cruzada *Leave-One-Subject-Out (LOSO)*.

Los resultados demuestran que el modelo en el dataset original obtiene mejor F1 Score (89,05% frente a 81,40% en el dataset balanceado), pero tiene más problemas para detectar la vigilia. Otro aspecto a destacar es que, para la explicabilidad del modelo, se basan en las *feature importances* del Random Forest, observando que la importancia de las características cambia en función del dataset utilizado.

Sin embargo, este trabajo presenta algunas limitaciones que se exponen en el mismo artículo. La primera de ellas es que la clasificación se limita a dos clases y ni siquiera diferencia las etapas REM y NREM. La segunda es que, pese a que se trabaja con PPG para reivindicar la monitorización del sueño mediante dispositivos *wearable* frente a la PSG, la base de datos se ha obtenido clínicamente y no presenta la variabilidad y el ruido que se encontraría en un entorno de monitorización domiciliaria. También se menciona la posibilidad de trabajar en un futuro con un dataset sin datos sintéticos de ADASYN o de utilizar SHAP para mejorar la interpretabilidad.

“Gender-Specific Machine Learning Modeling for Sleep Stage Classification Using Wearable Device Data”

También resultan relevantes los trabajos presentados en entornos de conferencia ya que, pese a no poder leer más que el abstract de congreso, nos permiten conocer las tendencias de investigación en el área. En la reunión anual de la Biomedical Engineering Society (BMES) de 2024, Jean Lee, Shaurya Bisht y Grace X. Gao presentan un estudio acerca de modelos específicos de género para la clasificación de etapas del sueño con datos de dispositivos *wearable* [13].

Para ello, utilizan la base de datos DREAMT [14], descrita en profundidad en la sección 4.1 y que contiene registros de 100 sujetos con señales procedentes de la pulsera Empatica E4. El estudio, a diferencia de los anteriores, utiliza tanto BVP (pulso de volumen sanguíneo, equivalente a PPG) como métricas de movimiento y temperatura para evaluar diferentes tareas de clasificación: sueño-vigilia, vigilia-REM-NREM y clasificación de cinco clases con vigilia, N1, N2, N3 y REM. Su principal objetivo es comparar el rendimiento de modelos entrenados con datos de un género específico frente a modelos genéricos.

Se entrenan los modelos *Random Forest* (que vuelve a dar los mejores resultados de clasificación), regresión logística y LASSO, siendo este último modelo el que utilizan para interpretar qué características extraídas de las señales son las más relevantes debido a su capacidad de selección de variables. A la hora de la validación se aplicó LOSO y se corrigió el desbalanceo de clases, especialmente presente en la clasificación de 5 clases por la escasa representación de N1 y N3, mediante SMOTE.

Los resultados del resumen indican que las características de IBI, las variables circadianas y las métricas de acelerometría tienen un papel relevante en la discriminación entre etapas, mientras que N1 y N3 aparecen como clases especialmente difíciles de detectar por su menor representación y por la mayor ambigüedad fisiológica. A su vez, los modelos específicos de género muestran un rendimiento ligeramente superior al mo-

delo genérico, lo que sugiere que las diferencias fisiológicas entre géneros pueden influir en la clasificación del sueño a partir de señales *wearable*.

Sin embargo, hay que tomar este resumen meramente como referencia de la tendencia de investigación, ya que no se dispone de información detallada sobre la extracción de características ni un análisis completo de los resultados.

“Ensemble AI Solutions for Personalized Sleep Monitoring Using Wrist-worn Wearables”

Finalmente, Vasco António Portilho Carvalho da Silva expone una tesis en el Instituto Superior de Ingeniería de Porto en la que aborda el uso de dispositivos de muñeca para monitorización personalizada del sueño mediante modelos de inteligencia artificial y técnicas de explicabilidad [15]. La tesis plantea un marco general para integrar datos multimodales procedentes de *wearables*, principalmente PPG y acelerometría, con el objetivo de realizar clasificación de etapas del sueño y detección de apnea.

En la parte dedicada a la clasificación de etapas del sueño, se utiliza un subconjunto de la base de datos MESA Sleep [16], con anotaciones polisomnográficas de expertos en cinco clases: vigilia, N1, N2, N3 y REM. Las señales PPG obtenidas con el dispositivo Actiwatch Spectrum se segmentan en épocas de 30 segundos y se alinean con las etiquetas de la PSG. Posteriormente, se extraen características de la señal PPG relacionadas con la morfología del pulso y con la serie de intervalos entre latidos para cada época. A diferencia de los trabajos anteriores, Silva no trata las épocas de 30 segundos independientemente, sino que las agrupa en ventanas deslizantes de 3 minutos que avanzan cada 60 segundos, es decir, con solapamiento. Se justifica esta segmentación por la naturaleza de las características y se etiquetan en función de la clase mayoritaria dentro de la ventana.

Se experimentó también un problema de desbalanceo de clases, que se resuelve con una estrategia híbrida: SMOTE para generar muestras sintéticas de las clases minoritarias en los conjuntos de entrenamiento y submuestreo aleatorio para equiparar las proporciones en los conjuntos de validación. Se comparan 6 modelos clásicos con optimización de hiperparámetros y *Random Forest* es el que obtiene mejores métricas globales, aunque sigue teniendo problemas para reconocer N1 debido a la naturaleza fisiológica de esta etapa del sueño.

La interpretabilidad en la tesis se articula de forma distinta en función de si es global o por clases. A nivel de explicabilidad global, se aplica *permutation importance* para evaluar la variabilidad del resultado cuando cada una de las características es permutada. Respecto a la explicabilidad por clases, se utiliza SHAP para concretar las features que más influyen en la predicción de cada etapa del sueño.

Resumen

En conjunto, estos trabajos muestran que los modelos interpretables de clasificación del sueño suelen compartir una estrategia común: sustituir la entrada directa de señales crudas por un conjunto de características fisiológicas, entrenar modelos clásicos para la clasificación de distinto número de etapas del sueño, y complementar el análisis mediante técnicas de explicabilidad para entender las características que más aportan a la predicción.

Esta orientación interpretable resulta especialmente adecuada para trabajos basados en señales *wearable*, ya que permite estudiar qué información aportan realmente la acelerometría, la PPG, la frecuencia cardíaca o la variabilidad del pulso en la clasificación de las etapas del sueño. Así, se pueden destacar variables sobre las que poner el foco en futuros estudios orientados a mejorar la monitorización del sueño mediante dispositivos *wearable*.

Sin embargo, es difícil establecer comparaciones directas entre los distintos estudios debido a la diversidad de variables y estrategias empleadas. A modo de resumen, se presenta en el anexo A una tabla comparativa con las diversas decisiones de diseño tomadas en cada estudio.

3. Análisis de objetivos

Una vez analizado el estado del arte, se justifica la realización del presente trabajo y se exponen tanto su objetivo general como los objetivos específicos que pretende alcanzar.

3.1. Justificación del trabajo

El trabajo realizado se enmarca dentro del ámbito de la clasificación de etapas del sueño a partir de señales procedentes de dispositivos *wearable* mediante modelos de aprendizaje automático interpretables. Concretamente, se emplearán dos modelos aprendizaje automático basados en árboles, *Random Forest* y *LightGBM*, para la predicción tanto de las clases vigilia, REM y NREM, como de la clasificación binaria vigilia/sueño. La elección de estos modelos específicos viene motivada por su amplia presencia en la literatura y obtención de mejores métricas de rendimiento en este contexto en comparación con modelos como Regresión Logística, SVM o LASSO, entre otros [8, 11, 13, 15].

Para entrenar y validar el modelo, se empleará la base de datos DREAMT. Esta base de datos de PhysioNet contiene registros de señales fisiológicas del sueño capturadas con la pulsera Empatica E4, lo que la convierte en una fuente apropiada para el ámbito de estudio basado en datos recogidos por dispositivos *wearable*. Además, dispone de anotaciones de las etapas del sueño realizadas por expertos, lo que permite una evaluación rigurosa del modelo. Un aspecto a favor de DREAMT respecto a otras bases de datos utilizadas en estudios de la literatura es que, además de la señal PPG que estas ofrecen, contiene registros de acelerometría, actividad electrodérmica y temperatura cutánea, permitiendo un análisis de interpretabilidad más completo.

Siguiendo la línea de los estudios analizados en el estado del arte, el flujo de trabajo comenzará con un preprocesamiento de los datos crudos para la extracción de características con las que alimentar al modelo de clasificación. Este enfoque nos aporta también mayor explicabilidad a la hora de analizar las variables fisiológicas en las que más se apoya el modelo para predecir cada fase. Esto último se implementa mediante SHAP, una técnica que ya emplean o sugieren dichos estudios. Con ella, se analizará la importancia de cada característica tanto a nivel global como para cada etapa del sueño.

Finalmente, se hará un análisis crítico comparativo. Los estudios de la literatura

referenciados, aún ofreciendo un camino a seguir, presentan errores metodológicos que afectan directamente a la validez de sus resultados. Todas estas faltas están relacionadas con la incorrecta gestión de los conjuntos de entrenamiento y validación. Validar un modelo utilizando un conjunto de datos que previamente ha servido para optimizarlo [8, 11], que contiene épocas de un paciente presente en el entrenamiento [8, 15] o que ha sido previamente balanceado [11, 13, 15] son decisiones que pueden alterar los resultados, aumentando falsamente las métricas y ofreciendo un rendimiento que no se corresponde con la realidad médica para la que están orientados los estudios.

Así, se demostrará que las malas prácticas mencionadas resultan en *data leakage* y se buscará un camino a seguir que, aún ofreciendo unos resultados más modestos actualmente, sea más fiel a la realidad y sirva de referencia para futuros estudios.

3.2. Objetivos específicos

El objetivo principal de este TFG es desarrollar modelos de clasificación de etapas del sueño a partir de señales de dispositivos *wearable*, priorizando la interpretabilidad de los modelos y la validez de los resultados obtenidos. Más concretamente, los objetivos específicos que se pretenden alcanzar son los siguientes:

- Preprocesar los datos crudos de DREAMT para la posterior extracción de características fisiológicas.
 - Implementar dos modelos de clasificación basados, respectivamente, en *Random Forest* y *LightGBM* para predecir tanto las clases vigilia, REM y NREM como la clasificación binaria vigilia/sueño a partir de las características extraídas.
 - Evaluar el rendimiento de los modelos utilizando métricas estándar como precisión, *recall*, F1-Score y matriz de confusión.
 - Analizar las malas prácticas metodológicas presentes en los estudios de la literatura y demostrar cómo afectan a la validez de los resultados obtenidos.
 - Aplicar la técnica de explicabilidad SHAP para analizar la importancia de cada característica en la predicción de etapas del sueño, tanto a nivel global como específico para cada clase.
-

4. Materiales

En esta sección se describen los materiales y herramientas metodológicas que sustentan el desarrollo del trabajo. Se busca establecer una base clara sobre los datos empleados y sobre las técnicas de aprendizaje automático e interpretabilidad utilizadas para abordar el problema.

A su vez, se expone el entorno de programación empleado

4.1. Base de datos DREAMT

DREAMT, acrónimo de *Dataset for Real-time sleep stage EstimAtion using Multi-sensor wearable Technology*, es una base de datos publicada en PhysioNet orientada al estudio de la estimación de etapas del sueño mediante señales procedentes de dispositivos *wearable*. Como ya se ha explicado, su principal interés para este trabajo reside en que combina registros de una pulsera multisensor con anotaciones clínicas de sueño obtenidas a partir de polisomnografía, lo que permite plantear un problema de aprendizaje supervisado en el que las señales recogidas por el dispositivo portátil actúan como entrada y las fases del sueño anotadas por técnicos expertos sirven como *ground truth* [14, 17, 18].

La base de datos fue recopilada a partir de 100 participantes a los que se les realizó un estudio nocturno del sueño, diseñado principalmente para detectar y monitorizar eventos de apnea durante el sueño, y simultáneamente se les colocaba una pulsera Empatica E4 en la muñeca izquierda. La adquisición combinaba, por tanto, el registro continuo de señales del dispositivo *wearable* con una polisomnografía clínica nocturna realizada mediante el sistema Nihon Kohden Polysmith 1004.

La población incluida en DREAMT corresponde a pacientes procedentes de un laboratorio de trastornos del sueño, con una presencia relevante de alteraciones respiratorias como la apnea obstructiva del sueño. La página oficial de PhysioNet indica una edad media de 56.2 ± 16.6 años, un índice de masa corporal medio de 33.7 ± 8.6 kg/m², un OAHÍ medio de 19.4 ± 27.5 eventos/hora y un AHI medio de 22.1 ± 28.7 eventos/hora. Además, 68 de los 100 participantes presentaban obesidad o obesidad severa, definida como un IMC mayor o igual a 30 kg/m²; entre los 23 participantes con apnea obstructiva del sueño severa, definida como AHI mayor de 30 eventos/hora, 17 eran obesos o severamente obesos. Esta composición convierte a DREAMT en una base de datos

especialmente relevante para evaluar modelos de estimación del sueño en una población clínica, más compleja que una muestra formada únicamente por sujetos sanos.

En cuanto al contenido de la base de datos, se incluyen señales procedentes de la pulsera Empatica E4 y señales de PSG alineadas temporalmente. Las señales del dispositivo *wearable* comprenden seis señales crudas: pulso de volumen sanguíneo o *Blood Volume Pulse* (BVP), acelerometría triaxial en los ejes ACC_X, ACC_Y y ACC_Z, actividad electrodérmica (EDA) y temperatura cutánea (TEMP). Además, se proporcionan dos señales derivadas del BVP: la frecuencia cardíaca (HR) y el intervalo entre latidos (IBI). Estas señales, resumidas en la tabla 4.1 permiten estudiar distintos aspectos fisiológicos relacionados con el sueño, como la actividad cardiovascular, el movimiento corporal y la variación térmica.

Tabla 4.1: Resumen de las señales registradas por el dispositivo Empatica E4 disponibles en DREAMT.

Categoría	Señales	Interpretación
Cardiovascular	BVP, HR, IBI	Pulso de Volumen Sanguíneo, Frecuencia Cardíaca e Intervalo temporal Entre Latidos.
Movimiento	ACC_X, ACC_Y, ACC_Z	Actividad motora de la muñeca registrada en los tres ejes espaciales del acelerómetro.
Actividad electrodérmica	EDA	Variaciones en la conductancia eléctrica de la piel relacionadas principalmente con la actividad del sistema nervioso simpático.
Temperatura periférica	TEMP	Temperatura cutánea periférica registrada en la superficie de la muñeca.

Las etiquetas de sueño incluidas en DREAMT proceden de las anotaciones realizadas por técnicos expertos a partir de la PSG. Estas etiquetas se proporcionan en épocas de 30 segundos, siguiendo la estructura habitual de los estudios de sueño. Las clases disponibles incluyen vigilia (W), sueño NREM en sus etapas N1, N2 y N3, y sueño REM (R). También se contempla una etiqueta P de preparación previa al inicio del registro polisomnográfico y una etiqueta Missing de datos ausentes en casos puntuales. Para una clasificación simplificada como la de este trabajo, las etapas N1, N2 y N3 pueden agruparse en una única clase NREM, obteniendo así un problema de clasificación en tres clases.

La base de datos se organiza en dos modalidades principales. La carpeta `data_64Hz` contiene únicamente las señales procedentes del dispositivo Empatica E4, remuestreadas a 64 Hz y alineadas mediante una marca temporal común, junto con las etiquetas derivadas de la PSG. Según la documentación oficial, no se aplica preprocesamiento adicional sobre los datos crudos más allá del remuestreo. Por otro lado, la carpeta `data_100Hz` incluye tanto las señales del dispositivo *wearable* como las señales de polisomnografía, todas ellas remuestreadas a 100 Hz para facilitar su alineamiento temporal. Esta segunda modalidad incorpora canales clínicos como electroencefalograma (EEG), electrocardiograma (ECG), señales respiratorias, ronquido, movimiento de piernas, saturación de oxígeno en sangre y demás registros que no son del interés de este estudio de clasificación a partir de datos recopilados con dispositivos *wearable*.

La carpeta `data_64Hz`, que es la que se empleará en este trabajo, contiene un archivo `.csv` por cada participante, con las señales del dispositivo *wearable* y las etiquetas de sueño correspondientes a cada época de 30 segundos. Cada fila del archivo representa una época de 1/64 segundos, con columnas para cada señal (BVP, HR, IBI, ACC_X, ACC_Y, ACC_Z, EDA, TEMP) y una columna adicional *Sleep_Stage* para la etiqueta de la etapa del sueño. Esta estructura facilita el preprocesamiento y la extracción de características necesarias para alimentar al modelo de clasificación.

En definitiva, la elección de DREAMT como base de datos para este trabajo, como ya han realizado otras investigaciones [13], otorga un punto de partida adecuado. Sin embargo, con el objetivo de alcanzar resultados interpretables, se requiere un enfoque de extracción de características acertado.

4.2. Fundamento teórico de los modelos de clasificación

A continuación, se expone la base teórica de los dos modelos basados en árboles de decisión utilizados para la clasificación de etapas del sueño.

4.2.1. Random Forest

Random Forest es un algoritmo de aprendizaje supervisado basado en un conjunto de árboles de decisión [19]. En lugar de construir un único árbol, el modelo entrena múltiples árboles sobre diferentes muestras aleatorias del conjunto de entrenamiento. Además, en cada división de cada árbol se evalúa únicamente un subconjunto aleatorio de las características disponibles. Estas dos fuentes de aleatoriedad reducen la correlación entre los árboles y mejoran la capacidad de generalización del modelo.

En un problema de clasificación como el del presente trabajo, cada árbol genera una predicción individual para la muestra dada y la clase final se obtiene mediante

votación mayoritaria entre los árboles, es decir, con la moda de las predicciones. De forma equivalente, la probabilidad asignada a una clase puede calcularse promediando las probabilidades estimadas por todos los árboles:

$$P(y = c \mid x) = \frac{1}{T} \sum_{t=1}^T P_t(y = c \mid x), \quad (4.1)$$

donde T es el número total de árboles y $P_t(y = c \mid x)$ representa la probabilidad estimada por el árbol t para la clase c .

El uso de múltiples árboles permite reducir la varianza y el sobreajuste asociados a un árbol de decisión individual. Además, *Random Forest* puede modelar relaciones no lineales e interacciones entre características sin requerir una normalización previa de los datos, por lo que resulta adecuado para problemas tabulares con variables fisiológicas heterogéneas, como el que se presenta.

4.2.2. LightGBM

LightGBM, acrónimo de *Light Gradient Boosting Machine*, es un algoritmo de aprendizaje supervisado basado en árboles de decisión entrenados mediante *gradient boosting* [20]. A diferencia de *Random Forest*, donde los árboles se construyen de forma independiente y sus predicciones se agregan posteriormente, *LightGBM* genera los árboles de manera secuencial. Cada nuevo árbol intenta corregir los errores cometidos por el conjunto de árboles anterior, de modo que el modelo final puede expresarse como una suma:

$$F_T(x) = F_0(x) + \sum_{t=1}^T \eta f_t(x), \quad (4.2)$$

donde $F_0(x)$ es la predicción inicial, $f_t(x)$ representa el árbol añadido en la iteración t , T es el número total de árboles y η es la tasa de aprendizaje. Cada árbol se ajusta siguiendo el gradiente negativo de la función de pérdida, buscando reducir progresivamente el error de clasificación.

A diferencia de otros algoritmos basados en *gradient boosting* como el previamente mencionado *XGBoost*, *LightGBM* incorpora distintas estrategias orientadas a mejorar la eficiencia del entrenamiento. Además, comparte con *Random Forest* algunas cualidades convenientes para este trabajo de clasificación de etapas del sueño a partir de características fisiológicas, como la capacidad para modelar relaciones no lineales entre variables. Por tanto, dada su similitud, son dos modelos comparables en esta tarea.

4.3. Fundamento teórico de SHAP

SHAP, acrónimo de *SHapley Additive exPlanations*, es una técnica de explicabilidad basada en los valores de Shapley procedentes de la teoría de juegos cooperativos [21]. Su objetivo es cuantificar la contribución individual de cada variable de entrada a la predicción realizada por un modelo de aprendizaje automático. En este contexto, cada característica del conjunto de datos se interpreta como un jugador y la predicción del modelo como la ganancia que debe repartirse entre dichos jugadores.

Dado un modelo predictivo f y una muestra concreta x , SHAP expresa la predicción como una suma aditiva de contribuciones:

$$f(x) = \phi_0 + \sum_{j=1}^M \phi_j, \quad (4.3)$$

donde M es el número total de características, ϕ_0 representa el valor esperado de la predicción del modelo sobre el conjunto de referencia, y ϕ_j es el valor SHAP asociado a la característica j . Por tanto, cada ϕ_j mide cuánto contribuye dicha característica a desplazar la predicción desde el comportamiento medio del modelo hasta la predicción concreta para la muestra x .

El valor SHAP de una característica i se define como:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(M - |S| - 1)!}{M!} [f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S)], \quad (4.4)$$

donde F es el conjunto de todas las características, S representa un subconjunto de características que no contiene a la característica i , y M es el número total de características. El término entre corchetes mide la variación en la predicción al añadir la característica i a un subconjunto S . El factor

$$\frac{|S|!(M - |S| - 1)!}{M!} \quad (4.5)$$

pondera dicha contribución teniendo en cuenta todas las posibles ordenaciones en las que las características pueden incorporarse al modelo. De este modo, el valor SHAP de una variable equivale a su contribución marginal media considerando todas las combinaciones posibles de variables.

Una propiedad fundamental de SHAP es la *eficiencia* o *aditividad local*, según la cual la suma de todas las contribuciones individuales reconstruye exactamente la diferencia entre la predicción de la muestra y la predicción media del modelo:

$$f(x) - \mathbb{E}[f(X)] = \sum_{j=1}^M \phi_j. \quad (4.6)$$

Por tanto, si $\phi_j > 0$, la característica j contribuye a aumentar la salida del modelo respecto al valor medio. Por el contrario, si $\phi_j < 0$, dicha característica reduce la salida del modelo. La magnitud $|\phi_j|$ indica la intensidad de la contribución.

En problemas de clasificación, el modelo no produce una única salida escalar, sino una probabilidad o puntuación para cada clase. En este caso, los valores SHAP se calculan de forma independiente para cada clase. Así, para una clase concreta c , la predicción puede expresarse como:

$$f_c(x) = \phi_{0,c} + \sum_{j=1}^M \phi_{j,c}, \quad (4.7)$$

donde $f_c(x)$ representa la salida del modelo para la clase c , $\phi_{0,c}$ es el valor esperado de dicha salida y $\phi_{j,c}$ es la contribución de la característica j a la predicción de la clase c .

Aplicado a la clasificación de etapas del sueño, cada muestra x representa una época de sueño descrita mediante características fisiológicas derivadas de las señales aportadas por DREAMT como la frecuencia cardíaca media, la actividad del acelerómetro o la temperatura periférica. Si el modelo predice que una época pertenece a la clase REM, SHAP permite descomponer dicha decisión indicando qué variables han aumentado o reducido la probabilidad asignada a esa clase.

Por ejemplo, para una etapa concreta, la probabilidad predicha para la clase REM podría expresarse como:

$$P(\text{REM}|x) = \mathbb{E}[P(\text{REM})] + \phi_{\text{HR}} + \phi_{\text{ACC}} + \phi_{\text{TEMP}} + \dots \quad (4.8)$$

Si ϕ_{ACC} es positivo, la información procedente de la acelerometría está favoreciendo la clasificación como REM. Si ϕ_{HR} es negativo, la frecuencia cardíaca de esa época está reduciendo la probabilidad asignada a dicha clase. De este modo, SHAP ayuda a indicar qué variables son globalmente relevantes y también cómo contribuyen a una predicción individual.

En modelos basados en árboles, como los empleados en este estudio, el cálculo exacto de los valores de Shapley se realiza a través del algoritmo eficiente *TreeSHAP*. Este método aprovecha la estructura interna de los árboles de decisión para calcular las contribuciones de las variables de forma mucho más eficiente que una enumeración completa de subconjuntos.

4.4. Entorno de programación

El desarrollo del trabajo se ha llevado a cabo en un entorno local basado en Python, empleando un entorno virtual para aislar las dependencias del proyecto. Esta configuración permite ejecutar el código de preprocesamiento, extracción de características, entrenamiento de modelos y análisis de interpretabilidad de forma reproducible. La tabla 4.2 resume los principales elementos del entorno utilizado.

Tabla 4.2: Resumen del entorno de programación empleado.

Elemento	Versión	Uso principal
Visual Studio Code	1.125.1	Edición y ejecución del código del proyecto.
Python	3.12.13	Lenguaje principal de programación.
Entorno virtual <code>venv</code>	Python 3.12.13	Aislamiento de las librerías instaladas en el proyecto.

Las dependencias directas del proyecto se definieron en el archivo `requirements.txt`. Dicho archivo recoge los paquetes necesarios para el tratamiento de datos, el entrenamiento de modelos de aprendizaje automático, la generación de gráficas y el análisis mediante SHAP. Se puede observar en el anexo B una tabla con el contenido de este archivo.

5. Metodología

En este capítulo se describe la metodología empleada para abordar el problema de clasificación de etapas del sueño con los materiales y herramientas previamente presentados. Como se ha mencionado, el flujo de trabajo es común para toda la literatura referenciada y sigue el esquema de la figura 5.1.




Figura 5.1: Fases principales del pipeline experimental.

5.1. Preprocesamiento y extracción de características de DREAMT

Los datos recopilados mediante dispositivos *wearable* están más expuestos a ruido que los obtenidos clínicamente mediante PSG, lo que puede afectar a la calidad de las mediciones [14]. Es por ello que, para asegurar una clasificación de las etapas del sueño lo más rigurosa posible, se debe realizar un preprocesamiento adecuado de la base de datos. Además de esto, DREAMT contiene registros con distinta frecuencia de muestreo, sensibilidad al ruido y significado fisiológico. Trabajar directamente con las señales crudas exigiría arquitecturas profundas capaces de aprender representaciones temporales complejas, lo que incrementa la dimensionalidad, el coste computacional y la dificultad de interpretación [17].

Tanto esta situación como la correspondencia de las anotaciones de etapas del sueño basadas en PSG con épocas de 30 segundos convierten a la extracción de características derivadas de los registros en una estrategia efectiva para resumir la información concentrada en cada una de estas épocas [8, 11, 13]. Este enfoque permite reducir la dimensionalidad del problema a la vez que se facilita la explicabilidad del modelo. Las características extraídas pueden relacionarse con mecanismos fisiológicos conocidos, como la reducción del movimiento durante el sueño o los cambios de actividad cardíaca entre REM y NREM [5].

Para la implementación del preprocesamiento y la extracción de características, se utiliza como fuente principal el repositorio abierto `DREAMT_FE` de Will Ke Lang, colaborador del estudio DREAMT [22]. En él se detalla un *pipeline* para preprocesar las señales y extraer características con la finalidad de entrenar modelos de clasificación de etapas del sueño. Sobre su script `feature_engineering.py` se fundamenta toda la implementación del proceso llevado a cabo en este trabajo, discrepando solamente en algunas decisiones de diseño resumidas en la tabla 5.1. A continuación, se describen las técnicas de preprocesamiento y extracción de características aplicadas a cada una de las señales de DREAMT utilizadas en este estudio: BVP, HR, IBI, ACC, EDA y TEMP.

5.1.1. Preprocesamiento

El preprocesamiento comienza eliminando tanto los registros con etiquetas de sueño P, que corresponden a períodos de preparación, como los etiquetados como *Missing*, que reflejan errores en la monitorización [14]. Estas mediciones no aportan información relevante para la clasificación, por lo que no merece la pena almacenarlas. Posteriormente, se preprocesa cada una de las señales tal y como se detalla en los siguientes apartados.

BVP

La señal de volumen de pulso sanguíneo, muestreada a 64 Hz, se filtra mediante un filtro pasabanda Chebyshev tipo II [13, 22]. Este tipo de filtro permite atenuar las componentes frecuenciales situadas fuera de la banda de interés, es decir, las muestras que pueden corresponder a ruido, a la vez que mantiene una respuesta monótona en la banda de paso, atribuible a valores acertados del pulso cardíaco. El estudio *An optimal filter for short photoplethysmogram signals* (Liang et al., 2018) [23] afirma que Chebyshev tipo II es el filtro con la mejora más efectiva para las señales PPG y destaca su cuarto orden como el óptimo. El rango de frecuencias de corte se establece entre 0.5 y 8 Hz [15].

HR e IBI

En cuanto al preprocesamiento de HR e IBI, hay que hacer una distinción. `DREAMT_FE` recalcula estas variables a partir de la señal BVP previamente filtrada, ignorando los valores aportados por la propia base de datos y que ya fueron derivados del sensor PPG. Ante la duda de si optar por esta estrategia o conservar los registros originales, se realizó un análisis con una secuencia aleatoria correspondiente a un único sujeto. Para ello, se filtró BVP y se recalcularon HR e IBI a partir de esta señal, de la misma forma que se realiza en el repositorio `DREAMT_FE`. A continuación, se compararon los

valores obtenidos con los aportados por DREAMT.

En la figura 5.2 se puede observar la comparativa entre los valores HR originales de la base de datos y los derivados de la señal. Como se puede apreciar, el cálculo de la frecuencia cardíaca a partir de los picos de la señal BVP filtrada da lugar a valores inestables e improbables, alcanzándose frecuencias superiores a 200 latidos por minuto (bpm) durante gran parte de la noche. Estos datos, además de tener poca credibilidad, no se corresponden con la información aportada por DREAMT, por lo que se opta por conservar sus registros originales.




Figura 5.2: Comparación entre la señal HR de DREAMT y la derivada de la señal BVP filtrada.

Por tanto, el preprocesamiento de estas variables se realiza como sigue: Para HR se eliminan los valores improbables, concretando un rango de 30-220 bpm, se eliminan outliers de cara a la extracción de características y se normaliza por sujeto [13]. El motivo de esta decisión reside en que un mismo valor de HR puede tener un significado fisiológico distinto dependiendo del paciente, por lo que la normalización por sujeto permite contextualizar cada medición dentro de su rango habitual. De esta manera, el modelo puede aprender a identificar patrones de variación de HR que sean indicativos de las etapas del sueño, independientemente de la frecuencia cardíaca basal de cada individuo. Por ejemplo, la fase REM se caracteriza por una mayor variabilidad de la frecuencia cardíaca, similar a la de la vigilia, mientras que los episodios de fase NREM suelen mostrar una disminución progresiva del HR para permitir la recuperación cardiovascular [24].

Respecto a IBI, se eliminan los registros fisiológicamente improbables siguiendo la fórmula $IBI = \frac{60}{HR}$, es decir, para el rango de frecuencia cardíaca previamente seleccionado corresponde un intervalo aproximado de 0.3 - 2 segundos. También se quitan outliers por sujeto y se interpolan linealmente.

ACC

Los valores de acelerometría de DREAMT se dividen en mediciones para cada eje espacial (X, Y, Z) y son muestreados a 32 Hz. Para su preprocesamiento, se aplica un filtro pasabanda Butterworth de orden 3 con frecuencias de corte de 3 y 10 Hz a cada uno de los ejes, utilizando su misma frecuencia de muestreo [22].

EDA

El preprocesamiento de la actividad electrodérmica (EDA) añade un componente distinto. La señal está muestreada a 4 Hz, por lo que se trabaja a esta frecuencia y posteriormente se reconstruye a 64 Hz repitiendo los valores 16 veces. En primer lugar, se hace un *detrending* local en ventanas de 5 segundos (equivalentes a 20 muestras en frecuencia de muestreo) [22].

El *detrending* local es una técnica que consiste en dividir una señal en ventanas y eliminar la tendencia específica de cada segmento [25]. De esta forma, se estabiliza la señal alrededor de una media constante, consiguiendo eliminar bajas frecuencias y aislando los picos que contienen la información relevante de la señal EDA [26].

Tras ello, se aplica un filtro paso bajo Butterworth de orden 3 con frecuencia de corte de 0.7 Hz [22]. El objetivo es eliminar las oscilaciones rápidas de la señal que podrían corresponder a ruido ya que la EDA, fisiológicamente, tiene cambios lentos [26]. La figura 5.3 muestra una comparación entre la señal cruda y la preprocesada, tanto a escala original como superpuestas.

TEMP

La temperatura cutánea se preprocesa de forma simple, como IBI. Se eliminan los valores fuera del rango fisiológico de 31 a 40 grados centígrados y se interpolan linealmente [22].

Resumen

En la tabla 5.1 se puede observar un resumen del preprocesamiento aplicado a cada señal aportada por DREAMT, a la vez que se compara con el preprocesamiento implementado en el repositorio DREAMT_FE.




Figura 5.3: Comparación entre la señal EDA cruda y preprocesada, tanto a escala original como centradas en 0.

Tabla 5.1: Comparación entre el preprocesamiento propuesto en DREAMT_FE y el preprocesamiento finalmente adoptado.

Señal	Preprocesamiento de DREAMT_FE	Preprocesamiento adoptado
BVP	Filtro pasabanda Chebyshev tipo II de orden 10, con frecuencias de corte entre 0,5 y 15 Hz.	Filtro pasabanda Chebyshev tipo II de orden 4, con frecuencias de corte entre 0,5 y 8 Hz.
IBI/HR	Recálculo de las señales de IBI y HR a partir de los picos detectados en la señal BVP filtrada.	Eliminación e interpolación de valores atípicos. En el caso de HR, se aplica además normalización por sujeto.
ACC	Filtro pasabanda Butterworth de orden 3, con frecuencias de corte entre 3 y 10 Hz.	Filtro pasabanda Butterworth de orden 3, con frecuencias de corte entre 3 y 10 Hz.
EDA	Eliminación de tendencia local y filtro paso bajo Butterworth de orden 3, con frecuencia de corte de 0,7 Hz.	Eliminación de tendencia local y filtro paso bajo Butterworth de orden 3, con frecuencia de corte de 0,7 Hz.
TEMP	Eliminación de valores fuera del intervalo 31–40 °C e interpolación de los valores descartados.	Eliminación de valores fuera del intervalo 31–40 °C e interpolación de los valores descartados.

5.1.2. Extracción de características

Una vez preprocesadas las señales, se procede a la extracción de características asociadas a épocas de 30 segundos. Como ya se ha mencionado, esta práctica ayuda tanto a facilitar la explicabilidad como a sintetizar la información, reduciendo así la dimensionalidad. Esta metodología, común en toda la literatura referida en el estado del arte, se justifica también por la correspondencia de las anotaciones de etapas del sueño basadas en PSG con épocas de 30 segundos.

Para la extracción de características de BVP, HR e IBI, registros que corresponden a la señal PPG con la que han trabajado todos los estudios referidos, se busca un equilibrio entre la metodología que estos han empleado y la llevada a cabo por DREAMT_FE. Respecto al resto de señales, solo presentes en DREAMT, se reproducirá fielmente la extracción descrita en dicho repositorio.

BVP

De la señal preprocesada, se calculan directamente algunas estadísticas básicas [22] y se incluyen otras como la asimetría (`BVP_skewness`) o la curtosis (`BVP_kurtosis`), que han demostrado tener importancia en la clasificación de etapas del sueño [11]. Además, a partir de BVP, se obtienen características de la variabilidad de la frecuencia cardíaca o *Heart Rate Variability* (HRV), incluidas en este apartado por cómo se calcula, a pesar de su estrecha relación con la señal IBI [22]. Para ello, se emplea `NeuroKit2`: un repositorio de código abierto diseñado específicamente para el preprocesamiento y análisis de señales fisiológicas [27].

A través de esta librería, se obtienen valores relevantes en otros estudios como las features tipo Poincaré (`HRV_SD1SD2`), características de complejidad como la dimensión fractal de Higuchi (`HRV_HFD`) y la entropía muestral (`HRV_SampEn`) o features en dominio frecuencial como la variabilidad de corto plazo de los intervalos entre latidos (`HRV_RMSSD`) [11, 13, 15]. Además, se amplía la funcionalidad de DREAMT_FE calculando los parámetros Hjorth de la señal BVP, relevantes para la clasificación global [8, 15].

Los parámetros Hjorth, indicadores estadísticos en el dominio temporal, son tres: Actividad, Movilidad y Complejidad [28]. La Actividad corresponde simplemente a la varianza de la señal y, por tanto, ya está contemplada. La Movilidad (`BVP_Hjorth_mobility`) mide cuánto cambia la señal respecto a su amplitud y se calcula con la fórmula:

$$Movilidad(x) = \sqrt{\frac{Var(dx)}{Var(x)}} \quad (5.1)$$

donde $x = [x_1, x_2, \dots, x_N]$ son las muestras de la señal BVP en la época y, entonces, $dx_i = x_{i+1} - x_i$.

Finalmente, la Complejidad (`BVP_Hjorth_complexity`) compara la Movilidad de la derivada con la Movilidad de la señal original, es decir:

$$Complejidad(x) = \frac{Movilidad(dx)}{Movilidad(x)} \quad (5.2)$$

HR e IBI

La información cardiovascular queda bastante representada con las features anteriores, por lo que para estas dos señales solamente se extraen algunas características estadísticas: la media, la mediana, el valor máximo, el valor mínimo y la desviación estándar.

ACC

En primer lugar, para cada eje se eliminan los valores situados por debajo del percentil 10 y por encima del percentil 90, reduciendo así la influencia de valores extremos o artefactos puntuales que puedan afectar a las características estadísticas. Sobre la señal resultante se calculan tres medidas: la media filtrada, el valor máximo filtrado y el rango intercuartílico (IQR). De este modo, para cada eje se generan las características `ACC_X_trimmed_mean`, `ACC_X_trimmed_max`, `ACC_X_trimmed_IQR`, y sus equivalentes para los ejes Y y Z [22].

Estas estadísticas también se calculan, además de sobre la señal filtrada, sobre la desviación media absoluta de la señal (MAD). En este caso, cada época se divide en subventanas de 5 segundos. Para cada subventana se calcula la MAD respecto a la media local, definida como:

$$MAD = \frac{1}{N} \sum_{i=1}^N |x_i - \bar{x}|, \quad (5.3)$$

donde x_i representa cada muestra de acelerometría dentro de la subventana, $\bar{x}$ es la media de dicha subventana y N es el número de muestras. Este procedimiento sirve para capturar la variabilidad local del movimiento dentro de la época. Como resultado, se obtienen las características `ACC_X_MAD_trimmed_mean`, `ACC_X_MAD_trimmed_max` y `ACC_X_MAD_trimmed_IQR`, junto con sus equivalentes para los ejes Y y Z [22].

Finalmente, se calcula una característica global de actividad denominada `ACC_INDEX` [22]. Para ello, primero se obtiene la magnitud vectorial de la aceleración combinando los tres ejes:

$$ACC = \sqrt{ACC_X^2 + ACC_Y^2 + ACC_Z^2}. \quad (5.4)$$

Posteriormente, esta magnitud se divide en bloques de 5 segundos y se calcula la desviación estándar de cada bloque. La característica `ACC_INDEX` se define como la suma de dichas desviaciones estándar a lo largo de la época. Por tanto, esta variable actúa como un índice agregado de actividad motora: valores elevados indican mayor variabilidad de la aceleración y, por ende, mayor presencia de movimiento durante la ventana analizada.

EDA

Se vuelve a emplear `NeuroKit2`, esta vez para descomponer la señal EDA preprocesada en sus componentes tónica y fásica [22]. La componente tónica representa el nivel basal o lento de conductancia de la piel, mientras que la componente fásica recoge las variaciones rápidas asociadas a respuestas electrodermales puntuales, conocidas como *Skin Conductance Responses* (SCR) [1]. En la figura 5.4 se puede apreciar la descomposición de la señal EDA en sus dos componentes, así como la identificación visual de una SCR.




Figura 5.4: Fundamentos fisiológicos de la señal EDA [1]

La extracción de características se centra en la componente fásica de la EDA. Más concretamente, en los picos de estas respuestas electrodermales a estímulos. Para ello, se detectan los picos SCR a un umbral mínimo de amplitud de 0.1. A partir de los eventos SCR detectados, se consideran cuatro magnitudes principales: la altura (`SCR_Height`), la amplitud (`SCR_Amplitude`), el tiempo de subida (`SCR_RiseTime`) y el tiempo de recuperación (`SCR_RecoveryTime`). Estas variables describen tanto la intensidad de las respuestas electrodermales como su dinámica temporal y, para cada una de ellas, se calculan la media y el valor máximo, generando ocho características EDA por época [22].

TEMP

La extracción de características de la señal de temperatura cutánea periférica es muy sencilla. Al igual que con HR e IBI, para cada época se calculan cinco estadísticas: la media, la mediana, el valor máximo, el valor mínimo y la desviación estándar [22].

Resumen

En el anexo C se puede encontrar una tabla resumen de todas las 64 características extraídas junto con su definición. Sin embargo, no todas ellas se utilizan para la clasificación de etapas del sueño ya que algunas están altamente correlacionadas entre sí. Al aportar prácticamente la misma información, utilizar todas las variables redundantes puede afectar negativamente a la interpretabilidad del modelo por repartir la importancia entre varias características que realmente reflejan un único patrón fisiológico.

5.2. Descripción de la implementación de clasificación y SHAP

Se detalla el proceso llevado a cabo para la clasificación de etapas del sueño y el posterior análisis de explicabilidad.

5.2.1. Implementación de modelos de clasificación

En este apartado se detallan y justifican las decisiones tomadas para el diseño del *pipeline* de clasificación de etapas del sueño, que es común para ambos modelos. Para la implementación de *Random Forest* se emplea `RandomForestClassifier` de `scikit-learn` y para *LightGBM* se utiliza `LGBMClassifier` de la biblioteca `lightgbm`.

Datos de entrada

Una vez preprocesadas las señales de DREAMT y extraídas las características por épocas, se obtienen los datos que servirán de entrada a los modelos de clasificación. En total, se disponen de 80.291 épocas de 30 segundos, correspondientes a 100 pacientes distintos. Cada época está descrita por las 64 características referenciadas en el anexo C y está acompañada de una etiqueta que indica la etapa del sueño a la que pertenece.

Las etiquetas, originalmente divididas en W/N1/N2/N3/REM, están adaptadas a las clasificaciones realizadas. Para el caso binario Wake/Sleep, las épocas se reparten en 26% Wake y 74% Sleep. Por su parte, la clasificación multiclase W/NREM/REM tiene una distribución 26% W, 64% NREM y 10% REM.

Partición train/test

A la hora de elegir la estrategia de partición de los datos en los subconjuntos de entrenamiento y validación, hay un aspecto relevante a tener en cuenta. Para evitar que el modelo aprenda patrones específicos de cada paciente, no se puede hacer una separación aleatoria de las épocas. En su lugar, se debe aplicar una partición disjunta por sujetos, de manera que todas las épocas de un mismo paciente se asignen a un único conjunto. Así, el modelo se enfrenta a un escenario realista en el que debe generalizar patrones de sueño a partir de sujetos no vistos durante el entrenamiento [11, 29].

Además, como ya se ha comentado, es primordial que el modelo se evalúe sobre un conjunto de datos completamente independiente del conjunto de entrenamiento. Todo proceso de eliminación de características redundante, balanceo de clases y optimización de hiperparámetros debe realizarse únicamente sobre un subconjunto ajeno al de validación [29, 30].

Para ello, se procede a aplicar una separación *GroupKFold* por sujeto con $K = 5$ [11]. Es decir, se dividen los 100 sujetos en 5 grupos y uno de ellos se reserva intacto hasta la validación. Sobre los 4 grupos restantes tiene lugar tanto la selección de features como el resto de apartados descritos a continuación. De esta forma, se evita el *data leakage* y se garantiza que el modelo no se beneficie de información de los sujetos del conjunto de validación para tomar decisiones tan importantes como qué características son más relevantes, qué técnica de balanceo de clases es más beneficiosa o cuál es la configuración óptima de hiperparámetros.

Selección de características

Con las características de las épocas de entrenamiento, se realiza un análisis de multicolinealidad para eliminar aquellas que tengan un coeficiente absoluto de correlación superior a 0.9 con otra característica [11, 22]. De esta forma, el modelo no tendrá que dividir la importancia entre variables que aportan información redundante, lo que podría sesgar la interpretabilidad de los resultados.

Balanceo de clases

En la literatura, es común utilizar técnicas de sobremuestreo como SMOTE [13, 15, 22] o ADASYN [11] para balancear las etapas del sueño. Estos métodos generan datos sintéticos basados en las muestras existentes, permitiendo aumentar la representación de las clases minoritarias y aprender mejor sus patrones [31]. Sin embargo, aún con sus ventajas, hay que tener en cuenta algunos aspectos.

En primer lugar, los datos que se tratan en estos estudios son de carácter fisiológico, por lo que su generación sintética puede traer inconvenientes. Las nuevas muestras se

generan a partir de las existentes, que, en el caso de DREAMT, no dejan de ser datos extraídos a personas con trastornos del sueño mediante un dispositivo *wearable* y, aunque filtrados para mitigar el ruido, pueden aportar información no siempre coherente con la fisiología real del paciente. Producir datos sintéticos puede acentuar tendencias de la señal que se alejan del comportamiento real del cuerpo humano, así como conllevar pérdida de variabilidad por reproducir únicamente dichas tendencias [31].

Otro aspecto a considerar cuando se aplican técnicas de balanceo es la necesidad de restringirlas a los datos de entrenamiento. Validar un modelo con datos balanceados puede dar lugar a resultados erróneos, ya que el modelo no se enfrenta a la realidad de los datos de validación. Es por ello que tanto la generación sintética como el submuestreo de datos deben limitarse al entrenamiento para evitar mejoras artificiales de las métricas [30].

Una alternativa que presentan tanto *Random Forest* como *LightGBM* es darle el valor "balanced" al parámetro `class_weight` de su constructor. Con esta configuración, el modelo automáticamente ajusta los pesos de cada clase otorgándoles una importancia inversamente proporcional a su frecuencia de aparición. Esto se consigue a través de la fórmula para una clase c :

$$weight_c = \frac{n_{samples}}{n_{classes} \cdot n_{samples-of-c}} \quad (5.5)$$

De esta forma, se penalizan en mayor escala los errores de predicción de las clases minoritarias y se consigue que el modelo no se limite a conseguir buenos resultados en las clases mayoritarias, que de por sí le otorgan un rendimiento general aceptable.

Para decidir qué estrategia de balanceo es más adecuada, se tomará como referencia la métrica F1-Score de las clases minoritarias al aplicar estas técnicas al conjunto de entrenamiento, buscando una mayor representación de todas las clases antes que un resultado global superior pero discriminatorio.

Optimización de hiperparámetros

Para la elección de los parámetros que definen los modelos, se opta por la optimización de la métrica F1-Score mediante *Grid Search CV* con *5-fold GroupKFold* por sujeto [11, 15]. Los parámetros, junto con el rango de posibles valores sobre los que se realiza la búsqueda, se muestran en la tabla 5.2.

Métricas de evaluación

Para evaluar el rendimiento de los modelos se emplearon métricas que permiten analizar tanto la calidad global de la clasificación como su comportamiento frente a clases

Tabla 5.2: Grid de hiperparámetros empleado para cada modelo.

Modelo	Hiperparámetro	Valores evaluados
<i>Random Forest</i>	<code>n_estimators</code>	100, 300, 500
	<code>max_depth</code>	10, 20, sin límite
	<code>min_samples_split</code>	2, 5, 10
	<code>min_samples_leaf</code>	1, 2, 4
<i>LightGBM</i>	<code>n_estimators</code>	100, 300, 500
	<code>learning_rate</code>	0.05, 0.1
	<code>num_leaves</code>	15, 30
	<code>max_depth</code>	sin límite, 8
	<code>min_child_samples</code>	50, 200

desbalanceadas [32].

La **precisión** (*precision*) indica qué proporción de las muestras asignadas por el modelo a una clase pertenecen realmente a ella. Se define como:

$$\text{Precisión} = \frac{VP}{VP + FP}, \quad (5.6)$$

donde *VP* representa los verdaderos positivos y *FP* los falsos positivos. Un valor elevado implica que el modelo genera pocas predicciones positivas incorrectas.

La **sensibilidad** o *recall* mide qué proporción de las muestras pertenecientes realmente a una clase son correctamente identificadas:

$$\text{Recall} = \frac{VP}{VP + FN}, \quad (5.7)$$

donde *FN* representa los falsos negativos. Esta métrica resulta especialmente relevante para comprobar si el modelo detecta adecuadamente las clases minoritarias.

La métrica **F1-Score** combina precisión y sensibilidad mediante su fórmula:

$$F1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}. \quad (5.8)$$

El F1-Score alcanza valores elevados únicamente cuando ambas métricas presentan un buen comportamiento y puede calcularse de forma independiente para cada clase. Además, para un análisis global, se presentan dos variantes: El *F1-Macro* obtiene la

media sin ponderar entre clases, es decir, otorga la misma importancia a cada clase. El $F1$ -weighted, por su parte, pondera el resultado de cada clase según su número de muestras, dando un resultado final acorde a la distribución de las clases.

Para el análisis global de la clasificación, se emplea también la **exactitud** (*accuracy*), que indica el porcentaje de predicciones correctas sobre el total de muestras:

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}, \quad (5.9)$$

donde VN representa los verdaderos negativos. Sin embargo, puede resultar engañosa en escenarios con clases desbalanceadas, ya que un modelo que prediga siempre la clase mayoritaria podría obtener una exactitud elevada sin realmente aprender a clasificar correctamente las clases minoritarias. Por ello, se emplea también la *balanced accuracy*, que calcula la media aritmética de la sensibilidad de cada clase, ofreciendo una comparación equilibrada.

Pipeline de clasificación

A continuación, se muestra un diagrama que resume el flujo de trabajo de entrenamiento y validación del modelo de clasificación. Este *pipeline* se repite por cada clasificación Wake/Sleep o W/NREM/REM y por cada modelo *Random Forest* o *LightGBM*.




Figura 5.5: Pipeline de clasificación y validación del modelo.

5.2.2. Implementación de explicabilidad con SHAP

Una vez obtenidos los resultados de la clasificación, se aplica en la misma ejecución el previamente detallado *TreeSHAP* para obtener los valores de la importancia en la predicción de cada característica. Como resultado, se obtienen varias gráficas que facilitan el análisis de explicabilidad de la sección 6.1.5.

En primer lugar, se generan gráficos de importancia global basados en la media del valor SHAP absoluto. En ellos, se ordenan las características según la magnitud media de su impacto sobre las predicciones y se desglosa la contribución global entre las clases. Este tipo de representación permite identificar las características más utilizadas por el modelo, aunque no informa sobre si sus valores favorecen o desfavorecen una clase determinada.

De forma complementaria, se obtienen también gráficos *beeswarm* independientes para cada clase. En ellos, cada punto representa una observación y su posición horizontal corresponde al valor SHAP de la característica. Los valores positivos indican que la variable incrementa la salida del modelo para la clase analizada, mientras que los negativos indican que la reduce. El color representa el valor original de la característica, empleándose tonos rojos para valores elevados y azules para valores bajos. Estos gráficos permiten analizar conjuntamente la importancia, la dirección y la distribución del efecto de cada variable, así como detectar relaciones no lineales, valores atípicos e interacciones entre características.

Sin embargo, hay que tener presente que la interpretación obtenida mediante *TreeSHAP* describe las reglas aprendidas por el modelo y no implica necesariamente la existencia de relaciones fisiológicas causales. Por este motivo, las relaciones establecidas se contrastarán con estudios acerca de las diferencias fisiológicas entre etapas del sueño.

6. Resultados y análisis

6.1. Resultados

En este apartado se exponen los resultados de aplicar el *pipeline* de clasificación de la figura 5.5 y se realiza un análisis interpretable de la importancia de variables obtenida para cada clasificación y modelo.

6.1.1. Selección de características

Pese a haber realizado la selección de características basada en multicolinealidad en cada uno de los distintos *splits* de los datos de entrada según el caso de estudio específico, se obtuvo en todos la misma lista final.

- Respecto a las estadísticas extraídas de BVP, la desviación estándar (BVP_std) concentra la información aportada por la desviación absoluta media (BVP_mad) y el valor cuadrático medio (BVP_rms). Además, se simplifican los valores máximo (BVP_max) y mínimo (BVP_min) de la señal filtrada en su diferencia (BVP_range).
- La selección de características HRV sintetiza la información de la variabilidad en el diagrama de Poincaré (HRV_SD1, HRV_SD2) y de la variable HRV_RMSSD en la desviación estándar de los intervalos entre latidos (HRV_SDNN).
- Las features estadísticas de IBI, HR y TEMP comparten el mismo análisis. Aparte de la desviación estándar (_std), las demás características están altamente correlacionadas entre sí, por lo que se reducen a la media (_mean).
- La acelerometría también contiene características muy correlacionadas entre sí. Tras el análisis, de las 19 features iniciales se conservan las 3 estadísticas filtradas para cada eje, pero el resto se resumen en ACC_X_MAD_trimmed_IQR, ACC_Y_MAD_trimmed_max y ACC_INDEX.
- Finalmente, las características de altura y amplitud SCR extraídas de la señal EDA aportan prácticamente la misma información, por lo que se simplifican todas en SCR_Height_mean.

Por tanto, tras la selección de características, se obtiene una lista final de 38 variables con las que realizar el resto del *pipeline* de clasificación de etapas del sueño.

6.1.2. Técnicas de balanceo de clases

Tomando el F1-Score de la clase minoritaria como métrica de referencia para elegir la técnica de balanceo de clases con la que definir el modelo, se obtuvieron los resultados descritos en la tabla 6.1.

Tabla 6.1: Técnicas de balanceo empleadas para cada modelo.

Modelo	F1 Original	Técnica de Balanceo	F1 Balanceado
<i>Random Forest</i>	$F1_{\text{Wake}} = 0.44$	<code>class_weight</code>	$F1_{\text{Wake}} = 0.5$
	$F1_{\text{REM}} = 0.01$	ADASYN	$F1_{\text{REM}} = 0.11$
<i>LightGBM</i>	$F1_{\text{Wake}} = 0.47$	<code>class_weight</code>	$F1_{\text{Wake}} = 0.52$
	$F1_{\text{REM}} = 0.03$	<code>class_weight</code>	$F1_{\text{REM}} = 0.19$

6.1.3. Hiperparámetros óptimos

Las tablas 6.2 y 6.3 sintetizan los resultados obtenidos de la optimización de hiperparámetros. Los modelos con estas configuraciones son los utilizados finalmente para la validación y obtención de métricas.

Tabla 6.2: Mejores hiperparámetros obtenidos para Random Forest.

Hiperparámetro	Wake/Sleep	W/NREM/REM
<code>max_depth</code>	None	10
<code>min_samples_leaf</code>	1	1
<code>min_samples_split</code>	10	2
<code>n_estimators</code>	500	300

Tabla 6.3: Mejores hiperparámetros obtenidos para LightGBM.

Hiperparámetro	Wake/Sleep	W/NREM/REM
<code>learning_rate</code>	0.05	0.05
<code>max_depth</code>	8	-1 (sin límite)
<code>min_child_samples</code>	50	200
<code>n_estimators</code>	100	300
<code>num_leaves</code>	30	30

6.1.4. Métricas obtenidas

Se presentan y analizan los resultados obtenidos por ambos modelos para cada problema de clasificación.

Wake/Sleep

La figura 6.1 ofrece una comparativa visual entre las métricas obtenidas para cada modelo y en la figura 6.2 se aprecian sus matrices de confusión. Como se puede observar, ambos modelos presentan comportamientos similares tanto en rendimiento global como específico por clase.




Figura 6.1: Comparación Random Forest y LightGBM para clasificación Wake/Sleep.

Random Forest consigue un F1-Score de 0.85 para la clase mayoritaria Sleep, pero obtiene peores resultados al predecir Wake (F1-Score de 0.51). *LightGBM*, por su parte, consigue ligeramente un mayor equilibrio, que no perjudica su rendimiento global.

Prestando atención a F1-Score Macro y *Balanced Accuracy*, que otorgan importancia por igual a ambas clases, se observa que, aún tras aplicar balanceo de clases, el modelo sigue encontrando dificultades para predecir con exactitud la clase Wake.

Además, las matrices de confusión confirman que, mientras que *Random Forest* se

centra en Sleep y predice erróneamente más de la mitad de las épocas Wake, *LightGBM* sacrifica acierto en Sleep para mejorar las predicciones de la clase minoritaria.




Figura 6.2: Matrices de confusión para Wake/Sleep

W/NREM/REM

En la clasificación de 3 etapas, ambos modelos vuelven a seguir tendencias similares, pero los resultados son menos consistentes. En la figura 6.3 se aprecia la gran diferencia de rendimiento entre las predicciones de cada clase. La clase W obtiene resultados muy parecidos a los de la clasificación binaria, pero los modelos no logran separar correctamente la clase Sleep en NREM y REM.

Para este problema, sin embargo, cambia la dinámica de los modelos. Ahora es *Random Forest* el que equilibra algo más el acierto en las predicciones entre NREM y REM. Por tanto, se puede presuponer que *Random Forest* consigue establecer relaciones que diferencien mejor las fases dentro del sueño, mientras que *LightGBM* es ligeramente más efectivo separando la vigilia del sueño.

La confusión NREM/REM se aprecia claramente en la figura 6.4. Aún para *Random Forest*, que consigue casi el doble de sensibilidad REM que *LightGBM*, la predicción errónea de REM como NREM es 2 veces más frecuente que su clasificación correcta. Esta dificultad para separar las fases dentro del sueño provoca un descenso en las métricas globales, con un rendimiento F1-Macro de 0.46, un 33% inferior con respecto a la clasificación binaria.




Figura 6.3: Comparación Random Forest y LightGBM para clasificación W/NREM/REM.




Figura 6.4: Matrices de confusión para W/NREM/REM

Sin embargo, cabe aclarar que la insuficiencia presentada por ambos modelos para separar correctamente las fases de REM y sueño profundo no es de extrañar. Varios estudios destacan la dificultad de reflejar los rasgos que identifican la fase REM en

señales obtenidas mediante un dispositivo de muñeca, y sitúan la predicción de esta clase como la más problemática al clasificar etapas del sueño en este contexto [8, 13, 33].

6.1.5. Análisis de explicabilidad

Una vez obtenidos los resultados de clasificación, se analiza qué características extraídas de DREAMT han tenido más importancia en las predicciones.

Wake/Sleep

La figura 6.5 muestra la importancia global de las características para la clasificación binaria. Se puede observar cómo todas las variables aportan prácticamente la misma información absoluta a la predicción de ambas clases. Esto tiene sentido, pues la evidencia a favor para clasificar Wake tiende a estar directamente relacionada con la evidencia en contra de Sleep, y viceversa.




Figura 6.5: Importancia global de características para Wake/Sleep

En general, ambos modelos utilizan las mismas características para clasificar. Comparten en el podio de características más contribuyentes a aquellas relacionadas con la desviación absoluta de la acelerometría y la media de la frecuencia cardíaca. Esto tiene sentido fisiológico, pues el movimiento corporal y las pulsaciones altas son dos rasgos característicos de la vigilia [24].

La temperatura y varias características cardiovasculares son también consideradas de alta relevancia. Como excepción, se puede apreciar cómo *Random Forest* presta más atención la curtosis de la señal BVP (*BVP_kurtosis*) y a la desviación estándar de los intervalos entre latidos (*HRV_SDNN*). Por su parte, *LightGBM* confía más en la intensidad de las respuestas electrodérmicas (*SCR_Height_mean*).

W/NREM/REM

El análisis interpretable multiclase es más complejo. Pese a conseguir unas métricas similares, se puede apreciar en la figura 6.6 cómo los modelos se fijan en características diferentes. *Random Forest* presta mucha atención a la información aportada por las características de acelerometría, mientras que *LightGBM* distribuye la importancia entre el resto de categorías fisiológicas.




Figura 6.6: Importancia global de características para W/NREM/REM

Sin embargo, ante la diferencia de rendimiento entre las predicciones de cada clase, es interesante realizar un análisis individual, especialmente entre NREM y REM. La figura 6.7 muestra los gráficos *beeswarm* de SHAP para la clase NREM. En ellos, se muestran las características más relevantes en orden decreciente de importancia y cómo afectan a la predicción.

Así, se puede apreciar cómo *Random Forest* asocia principalmente valores bajos de

acelerometría, baja frecuencia cardíaca con poca variación y una alta temperatura media con la fase NREM. Por su parte, *LightGBM* establece unas relaciones algo más moderadas. Comparte con *Random Forest* las asociaciones de alta temperatura y frecuencia cardíaca baja y estable, pero crea muchas relaciones lineales con características derivadas de la señal BVP. Además, destaca la fuerte asociación entre una respuesta electrodérmica alta y la fase NREM.




Figura 6.7: Gráfico *beeswarm* de SHAP para NREM

A nivel fisiológico, se pueden hacer algunas apreciaciones. La fase NREM efectivamente se caracteriza por una frecuencia cardíaca baja y estable, además de la obvia disminución de movimiento corporal con respecto a la vigilia [34].

Además, aunque la temperatura central del cuerpo desciende en esta fase, la vasodilatación periférica tiende a producir un aumento de la temperatura cutánea, que es la que se registra en DREAMT [35]. Por tanto, al contrario de lo que pudiera parecer en un principio, esta relación presenta coherencia fisiológica. Por otra parte, existen estudios que evidencian una elevada actividad electrodérmica de muñeca durante NREM, una relación que *LightGBM* ha establecido correctamente [36].

Finalmente, se intenta relacionar el comportamiento interno de los modelos reflejado en la figura 6.8 con su escaso rendimiento al predecir REM. Fisiológicamente, la fase REM comparte propiedades tanto con la vigilia, por ejemplo, frecuencia cardíaca irre-

gular y temperatura periférica menos controlada, como con NREM, mediante la baja actividad motora [34, 35]. Los gráficos muestran algunas relaciones contradictorias.




Figura 6.8: Gráfico *beeswarm* de SHAP para REM

Por ejemplo, *Random Forest* establece contradicciones entre las variables que reflejan el movimiento, aportando evidencia en contra de la clase tanto para valores altos como bajos de acelerometría. Sin embargo, parece captar la irregularidad de la frecuencia cardíaca presente en esta fase, siendo *HR_std* una de las variables que más información aporta. *LightGBM*, a diferencia de *Random Forest*, presta mucha atención a la temperatura periférica media, pero no logra establecer un criterio concluyente.

En definitiva, puede apreciarse en los valores SHAP tanto la dificultad de los modelos para asociar eventos fisiológicos con la fase REM como la correcta identificación de relaciones coherentes con la etapa de sueño profundo, derivando consecuentemente en métricas de rendimiento dispares.

6.1.6. Comparativas

A continuación, se comparan, en la medida de lo posible, los resultados obtenidos tanto en las métricas de clasificación como en la importancia de las características con los registrados en los estudios del estado del arte.

- El estudio de Smarandache et al. [8] consigue valores *accuracy* globales de 0.82

y 0.78, junto con dos F1-Score de 0.75 para las clasificaciones Wake/Sleep y W/NREM/REM, respectivamente.

- Markov et al. [11] presentan resultados de clasificación binaria para el dataset original y balanceado con ADASYN. Para la validación cruzada de 20 *folds*, se obtienen los respectivos valores: *accuracy* de 0.81 y 0.80, F1-Score de 0.89 y 0.81, y *recall* de 0.24 y 0.71.

Los resultados obtenidos para la clasificación Wake/Sleep no distan tanto de los recién presentados, acentuándose la diferencia al comparar las métricas obtenidas en W/NREM/REM. Sin embargo, como se detalla en la siguiente sección, se deben tener en cuenta ciertos aspectos metodológicos que pueden afectar directamente a la validez de los resultados.

Respecto a las variables más importantes, los estudios destacan características de la señal PPG que también han considerado estos modelos, como las relacionadas con su distribución (HR_mean, BVP_range, HR_std, BVP_kurtosis, BVP_iqr), propiedades derivadas de HRV (HRV_HFD, HRV_SDNN) y características de complejidad no lineal (BVP_Hjorth_Complexity).

El resumen de Lee et al. [13], el único que utiliza el resto de señales fisiológicas empleadas en este trabajo, destaca también la presencia de características derivadas de la acelerometría entre las variables más importantes, como sucede en el caso de *Random Forest*.

6.2. Comparaciones de diseño

Como se detalla en el capítulo 2, realizar comparaciones directas con los resultados de otros estudios no es una tarea sencilla. En primer lugar, se presentan modelos alimentados con diferentes características fisiológicas, extraídas a su vez de distintas bases de datos que aportan registros con diversidad de condiciones, como el número de sujetos, la condición clínica de los pacientes o el dispositivo de monitorización. Algunas, incluso, ofrecen muestras extraídas clínicamente y no por dispositivo *wearable* [11].

Por otra parte, el diseño del proceso de clasificación de las etapas del sueño, subdivididas desde Wake/Sleep hasta W/N1/N2/N3/REM, presenta variaciones en los enfoques metodológicos. El anexo A resume las principales discrepancias de diseño entre investigaciones, aportando algunas de estas decisiones un aumento injustificado de las métricas debido al *data leakage*.

En esta sección se destacan las malas prácticas llevadas a cabo por algunos estudios y se comprueba experimentalmente cómo estas decisiones de diseño afectan a los resulta-

dos obtenidos por los modelos de clasificación, demostrando que un diseño inadecuado del *pipeline* de clasificación conlleva una mejora artificial de las métricas.

6.2.1. Análisis crítico de la literatura

En la sección 5.2.1 se explica la importancia de realizar las particiones de los datos agrupando por sujeto [11, 29], limitar el balanceo al conjunto de entrenamiento [30] y reservar un subconjunto para la validación final que no participe en la selección de características ni en la optimización de hiperparámetros [29]. A continuación, se detalla cuáles de estas restricciones son incumplidas por los estudios de referencia.

El artículo de **Smarandache et al.** [8] no detalla explícitamente la aplicación de separación por sujeto al particionar el dataset. Se habla simplemente de validación cruzada para 10 *folds*, lo que presumiblemente implica que se separó el dataset por épocas. Esto, para un conjunto de 10 sujetos como es su caso, supone un sesgo en la evaluación del modelo. Además, describe cómo se realiza la selección de características basadas en importancia y la posterior optimización de hiperparámetros sobre todo el conjunto de datos, antes de aplicar la 10 *fold cross-validation* final. Por tanto, se valida sobre un subconjunto que ha participado en buena parte del proceso.

El estudio de **Markov et al.** [11] pone énfasis en la importancia de separar por sujeto, pero cae en el error de evaluar sobre un conjunto balanceado. Los autores aplican ADASYN sobre todo el dataset para posteriormente evaluarlo mediante *GroupKFold cross-validation*. Como indica el propio artículo, ya que los datos sintéticos son generados a partir de los auténticos, muestras artificialmente próximas pueden repartirse entre las particiones.

Por otra parte, se realiza una exhaustiva selección de las 330 características iniciales. Para cada conjunto de datos completo, original y balanceado, se aplica *Shapiro-Wilk*, *t-test/Mann-Whitney*, eliminación por correlación y *SelectFromModel* con *Random Forest*. Todo ello, antes de la validación cruzada final, volviendo a incidir en *data leakage*.

El problema con el resumen de congreso de **Lee et al.** [13] es la ausencia de una memoria completa que especifique el proceso llevado a cabo. Se menciona la aplicación de SMOTE para balancear las clases e, inmediatamente, evaluación mediante *Leave-One-Subject-Out cross-validation*. No se puede afirmar si el balanceo se aplica únicamente en el entrenamiento de cada iteración o antes de la validación cruzada. De igual forma, la selección de características se describe vagamente, sin posibilidad de conocer la integridad del proceso.

Por último, **Silva** en su tesis [15] eleva el problema de la separación por sujeto. No recalca el uso de esta práctica y, además, el hecho de trabajar con ventanas de 3 mi-

nutos con solapamiento acentúa la fuga de información si ventanas con información del mismo sujeto a la misma hora se encuentran separadas en entrenamiento y validación. Respecto al balanceo de clases, aplica SMOTE únicamente en entrenamiento y submuestra el conjunto de test, perdiendo información real y obteniendo métricas globales no representativas de la distribución original de las fases del sueño.

6.2.2. Experimentos

Para comprobar que, en el contexto de este trabajo, aplicar alguna de las prácticas recién mencionadas afecta directamente a los resultados, se proponen los siguientes experimentos. En ellos se utiliza el modelo *Random Forest* optimizado, ya que ha sido empleado para la prueba final por toda la literatura referenciada en el estado del arte.

Separación por sujeto

Al realizar la partición de los datos por épocas sin tener en cuenta la separación por sujeto, se obtuvieron las siguientes mejoras:

- Wake/Sleep: F1-Score Macro de $0.68 \rightarrow 0.74$, Accuracy de $0.77 \rightarrow 0.81$. Destaca el aumento de sensibilidad de Wake de $0.43 \rightarrow 0.57$.
- W/NREM/REM: F1-Score Macro de $0.46 \rightarrow 0.51$, Accuracy de $0.56 \rightarrow 0.61$. Se mejora sobre todo en las clases NREM y REM, obteniendo esta última un aumento de una décima tanto en precisión como en sensibilidad, provocando un F1-Score de $0.19 \rightarrow 0.3$.

Evaluación sobre conjunto balanceado

Cuando se balancea con ADASYN la distribución de clases y, posteriormente, se particiona el conjunto de datos en entrenamiento y test, los resultados aún distan más:

- Wake/Sleep: F1-Score Macro de $0.68 \rightarrow 0.84$, Accuracy de $0.77 \rightarrow 0.84$. En la clase minoritaria Wake se alcanzan valores de rendimiento similares a Sleep, con un F1-Score de $0.51 \rightarrow 0.82$.
- W/NREM/REM: F1-Score Macro de $0.46 \rightarrow 0.63$, Accuracy de $0.56 \rightarrow 0.63$. Se equiparan todas las clases: NREM mantiene sus métricas, W aumenta F1-Score de $0.51 \rightarrow 0.58$, pero la mayor mejora cae en REM, obteniendo esta última un aumento de F1-Score de $0.19 \rightarrow 0.65$.

Experimento conjunto

Finalmente, se realiza un experimento combinando ambas malas prácticas. Se balancea el conjunto de datos con ADASYN y, posteriormente, se particiona por épocas

sin tener en cuenta la separación por sujeto.

Los resultados obtenidos se pueden visualizar en la figura 6.9 y muestran que no hay diferencia de resultados al anidar el *data leakage*, ya que las métricas son las mismas que se obtienen al balancear el conjunto de prueba.




Figura 6.9: Comparación resultados tras balancear y no particionar por sujeto en ambas clasificaciones.

7. Conclusiones y vías futuras

Una vez realizado todo el trabajo, se pueden extraer dos conclusiones principales, relacionadas con la capacidad de los modelos estudiados para clasificar fases del sueño y con la integridad de la metodología empleada para ello.

La primera conclusión extraíble es la de que, con los datos fisiológicos que proporciona la monitorización del sueño de una población con trastornos del sueño mediante un dispositivo *wearable*, modelos sencillos como *Random Forest* o *LightGBM* son capaces de reconocer algunos patrones en los registros que corresponden al comportamiento natural de las fases de sueño. Por ejemplo, son capaces de diferenciar el sueño de la vigilia observando la reducción del movimiento corporal y de la frecuencia cardíaca, o de reconocer patrones sutiles como el aumento de la temperatura cutánea y de la actividad electrodérmica en la fase NREM.

Sin embargo, no hay que obviar las limitaciones que se presentan en este contexto. La más destacable es la dificultad de predecir correctamente la fase REM. Aunque los métodos de balanceo de clases consiguen redirigir a los modelos para que no busquen unas métricas finales aceptables fundamentadas en la perfección sobre las clases mayoritarias y la discriminación total de la menos representada, sigue sin encontrarse suficiente evidencia para separar con precisión la fase REM del sueño profundo. Bien por la insuficiencia de sensores en los dispositivos de muñeca capaces de recoger las variables fisiológicas más representativas de esta fase, o bien por la incapacidad predictiva de los modelos presentados con los datos disponibles, lo cierto es que se debe seguir mejorando la metodología para conseguir unos resultados fiables en todas las etapas del sueño.

La segunda conclusión refleja la importancia de tomar decisiones de diseño basadas en la interpretación fisiológica de los datos para presentar resultados que se midan en escenarios reales. En efecto, los modelos de clasificación presentados en este trabajo han sido implementados mediante un *pipeline* que considera prácticas aconsejadas en estudios de la literatura para no concluir unos resultados exitosos pero sin utilidad práctica. No considerar prácticas como comprobar el aprendizaje de los modelos en conjuntos de pacientes completamente independientes del entrenamiento y con una distribución natural de las etapas del sueño puede suponer una malinterpretación del alcance de los modelos. Esto es relevante, pues se debe buscar un escenario de prueba lo más parecido posible al entorno real.

7.1. Trabajo futuro

Este trabajo presenta varias limitaciones que pueden ser abordadas en estudios futuros. Entre ellas, se pueden destacar las siguientes:

- Extraer características temporales que reflejen la arquitectura cíclica del sueño. Variables circadianas, que son extraídas por `DREAMT_FE` y que están presentes entre las más importantes según estudios que las emplean [13, 22], o características contextuales entre épocas que aporten información acerca de las épocas colindantes pueden servir a los modelos para mejorar la predicción de las fases del sueño.
 - A su vez, se puede hacer lo contrario y trabajar únicamente con características extraídas de la señal PPG, para comparar la aportación del resto de variables de distinto carácter fisiológico y analizar las tendencias cardiovasculares en las que se fijan los modelos.
 - Utilizar mejores métricas comparativas para las distintas técnicas de balanceo de clases. Emplear el F1-Score de la clase minoritaria como métrica de referencia para seleccionar técnicas de balanceo obvia otros factores relevantes en datos de naturaleza médica como puede ser la pérdida de información o la calidad de los datos generados.
 - Ampliar el estudio a un mayor número de clases, dividiendo la fase NREM en sus subfases N1, N2 y N3, para analizar si los modelos son capaces de discriminar entre ellas.
 - Por último, si lo que se busca es un aumento significativo de las métricas que deje de lado la interpretabilidad, se debe seguir la primera línea presentada en el estado del arte. Modelos masivamente preentrenados y con arquitecturas híbridas complejas basadas en CNN, LSTM, Transformer o Mamba consiguen entender mejor el comportamiento del cuerpo humano y prestar atención a amplios rangos de tiempo que reflejan la arquitectura cíclica del sueño, lo que les permite discriminar mejor entre las distintas fases.
-

Bibliografía

- [1] Hugo F. Posada-Quintero and Ki H. Chon. Innovations in Electrodermal Activity Data Collection and Signal Processing: A Systematic Review. *Sensors*, 20(2):479, January 2020. doi: 10.3390/s20020479.
- [2] National Institute of Child Health and Human Development. ¿Cómo afecta la salud un sueño inadecuado? <https://espanol.nichd.nih.gov/salud/temas/sleep/informacion/inadecuado>, September 2018. Oficina de Comunicaciones, NICHD. Consultado el 5 de junio de 2026.
- [3] Resmed. 2026 Global Sleep Survey. <https://sleepsurvey.resmed.com/>, 2026. Consultado el 5 de junio de 2026.
- [4] Joshua E. Brinkman, Vidyadhar Reddy, and Sandeep Sharma. Physiology of sleep. StatPearls, NCBI Bookshelf, 2023. Available at: <https://www.ncbi.nlm.nih.gov/books/NBK482512/>.
- [5] Joseph Feriante and Joao Francisco Araujo. Physiology, rem sleep. StatPearls, NCBI Bookshelf, 2023. Available at: <https://www.ncbi.nlm.nih.gov/books/NBK531454/>.
- [6] Oumaima Benkirane, Mounir Chennaoui, Adrien Gauthier, Pierrick J. Arnal, Colette Drogou, Fabien Sauvet, and Danielle Gomez-Merino. Impact of sleep fragmentation on cognition and fatigue. *International Journal of Environmental Research and Public Health*, 19(23):15485, 2022. doi: 10.3390/ijerph192315485.
- [7] Jessica V. Rundo and Ralph Downey. Polysomnography. *Handbook of Clinical Neurology*, 160:381–392, 2019. doi: 10.1016/B978-0-444-64032-1.00025-4.
- [8] Florentin Smarandache, Satyasri Akula, Saleh I. Alzahrani, Farrukh Arslan, and Amir Ijaz. PPG-Based Sleep Stage Classification Using Pulse Wave Feature Fusion and Explainable AI. *Engineering, Technology & Applied Science Research*, 15(5): 27640–27645, 2025. doi: 10.48084/etasr.13077. URL <https://etasr.com/index.php/ETASR/article/view/13077>.
- [9] Md Abdul Motin, Chandan K. Karmakar, Thomas Penzel, and Marimuthu Palaniswami. Sleep-Wake Classification Using Statistical Features Extracted from Photoplethysmographic Signals. In *2019 41st Annual International Conference of*

-
- the IEEE Engineering in Medicine and Biology Society (EMBC)*. IEEE, 2019. doi: 10.1109/EMBC.2019.8857302.
- [10] Md Abdul Motin, Chandan K. Karmakar, Marimuthu Palaniswami, and Thomas Penzel. Photoplethysmographic-Based Automated Sleep–Wake Classification Using a Support Vector Machine. *Physiological Measurement*, 41(7):075013, 2020. doi: 10.1088/1361-6579/ab948c.
 - [11] Karmen Markov, Mohamed Elgendi, Vera Birrer, and Carlo Menon. Interpretable feature-based machine learning for automatic sleep detection using photoplethysmography. *npj Biosensing*, 2(24), 2025. doi: 10.1038/s44328-025-00041-2. URL <https://www.nature.com/articles/s44328-025-00041-2>.
 - [12] Mario Giovanni Terzano, Liborio Parrino, A. Sherieri, Ronald Chervin, Sudhansu Chokroverty, Christian Guilleminault, Max Hirshkowitz, Mark Mahowald, Harvey Moldofsky, Angela Rosa, Robert Thomas, and Arthur Walters. Atlas, Rules, and Recording Techniques for the Scoring of Cyclic Alternating Pattern (CAP) in Human Sleep. *Sleep Medicine*, 2(6):537–553, November 2001. doi: 10.1016/S1389-9457(01)00149-6. Erratum in: *Sleep Medicine*, 2002 Mar;3(2):185.
 - [13] Jean Lee, Shaurya Bisht, and Grace X. Gao. Gender-Specific Machine Learning Modeling for Sleep Stage Classification Using Wearable Device Data. Poster presented at the 2024 BMES Annual Meeting, 2024. URL <https://2024bmesannual.eventscribe.net/ajaxcalls/PresentationInfo.asp?PresentationID=1504942>. Poster 80, Biomedical Engineering Society Annual Meeting, October 26, 2024.
 - [14] Ke Wang, Jiamu Yang, Ayush Shetty, and Jessilyn Dunn. DREAMT: Dataset for Real-time sleep stage Estimation using Multisensor wearable Technology. *PhysioNet*, June 2026. doi: 10.13026/3f7y-2d80. URL <https://doi.org/10.13026/3f7y-2d80>. Version 2.2.0.
 - [15] Vasco António Portilho Carvalho da Silva. Ensemble AI Solutions for Personalized Sleep Monitoring Using Wrist-worn Wearables. Master’s thesis, Instituto Superior de Engenharia do Porto, Polytechnic Institute of Porto, 2025. URL <http://hdl.handle.net/10400.22/31317>.
 - [16] Xuan Chen, Rui Wang, Phyllis Zee, Pamela L. Lutsey, Sogol Javaheri, Carmela Alcántara, Chandra L. Jackson, Michelle A. Williams, and Susan Redline. Racial/Ethnic Differences in Sleep Disturbances: The Multi-Ethnic Study of Atherosclerosis (MESA). *Sleep*, 38(6):877–888, June 2015. doi: 10.5665/sleep.4732.
 - [17] Will Ke Wang, Jiamu Yang, Leeor Hershkovich, Hayoung Jeong, Bill Chen, Karnika Singh, Ali R. Roghanizad, Md Mobashir Hasan Shandhi, Andrew R. Spector, and Jessilyn Dunn. Addressing wearable sleep tracking inequity: A new dataset
-

- and novel methods for a population with sleep disorders. In Tom Pollard, Edward Choi, Pankhuri Singhal, Michael Hughes, Elena Sizikova, Bobak Mortazavi, Irene Chen, Fei Wang, Tasmie Sarker, Matthew McDermott, and Marzyeh Ghassemi, editors, *Proceedings of the Fifth Conference on Health, Inference, and Learning*, volume 248 of *Proceedings of Machine Learning Research*, pages 380–396. PMLR, 27–28 Jun 2024. URL <https://proceedings.mlr.press/v248/wang24a.html>.
- [18] Ary L. Goldberger, Luis A. N. Amaral, Leon Glass, Jeffrey M. Hausdorff, Plamen Ch. Ivanov, Roger G. Mark, Joseph E. Mietus, George B. Moody, Chung-Kang Peng, and H. Eugene Stanley. PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. *Circulation*, 101(23):e215–e220, 2000. doi: 10.1161/01.CIR.101.23.e215. RRID:SCR_007345.
- [19] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001. doi: 10.1023/A:1010933404324.
- [20] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3146–3154. Curran Associates, Inc., 2017.
- [21] Scott M. Lundberg and Su-In Lee. A Unified Approach to Interpreting Model Predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/file/8a20a8621978632d76c43dfd28b67767-Paper.pdf.
- [22] Will Ke Wang and Jerry Yang. DREAMT_FE: DREAMT Feature Engineering Repository. https://github.com/WillKeWang/DREAMT_FE, 2025. GitHub repository. Accessed: 2026-06-09.
- [23] Yongbo Liang, Mohamed Elgendi, Zhencheng Chen, and Rabab Ward. An Optimal Filter for Short Photoplethysmogram Signals. *Scientific Data*, 5:180076, May 2018. doi: 10.1038/sdata.2018.76.
- [24] Philippe Boudreau, Wen-Hsiu Yeh, Guy A. Dumont, and Diane B. Boivin. Circadian Variation of Heart Rate Variability Across Sleep Stages. *Sleep*, 36(12):1919–1928, December 2013. doi: 10.5665/sleep.3230.
- [25] Charalampos Tsirmpas, Stasinos Konstantopoulos, Dimitris Andrikopoulos, Konstantina Kyriakouli, and Panagiotis Fatouros. Transformer-based decomposition of electrodermal activity for real-world mental health applications. 2025. URL <https://arxiv.org/abs/2506.06378>.
-

-
- [26] Marcin Jukiewicz and Joanna Marcinkowska. Analysis of electrodermal signal features as indicators of cognitive and emotional reactions—comparison of the effectiveness of selected statistical measures. *Sensors*, 25(11), 2025. ISSN 1424-8220. doi: 10.3390/s25113300. URL <https://www.mdpi.com/1424-8220/25/11/3300>.
- [27] Dominique Makowski, Tam Pham, Zen J. Lau, Jan C. Brammer, François Lespinasse, Hung Pham, Christopher Schölzel, and S. H. Annabel Chen. NeuroKit2: A Python Toolbox for Neurophysiological Signal Processing. *Behavior Research Methods*, 53(4):1689–1696, 2021. doi: 10.3758/s13428-020-01516-y. URL <https://github.com/neuropsychology/NeuroKit>.
- [28] Bo Hjorth. Eeg analysis based on time domain properties. *Electroencephalography and Clinical Neurophysiology*, 29(3):306–310, 1970. ISSN 0013-4694. doi: [https://doi.org/10.1016/0013-4694\(70\)90143-4](https://doi.org/10.1016/0013-4694(70)90143-4). URL <https://www.sciencedirect.com/science/article/pii/0013469470901434>.
- [29] Matthew Rosenblatt, Lu Tejavibulya, Ru Kong Jiang, Stephanie Noble, and Dustin Scheinost. The Effects of Data Leakage on Connectome-Based Machine Learning Models. *bioRxiv*, page 2023.06.09.544383, 2023. doi: 10.1101/2023.06.09.544383. Preprint.
- [30] imbalanced-learn Developers. Common Pitfalls and Recommended Practices. https://imbalanced-learn.org/stable/common_pitfalls.html, 2026. imbalanced-learn documentation. Accessed: 2026-06-18.
- [31] Daniel McDuff, Theodore Curran, and Achuta Kadambi. Synthetic data in healthcare, 2023. URL <https://arxiv.org/abs/2304.03243>.
- [32] Marina Sokolova and Guy Lapalme. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4):427–437, 2009. doi: 10.1016/j.ipm.2009.03.002.
- [33] Mustafa Radha, Pedro Fonseca, Aurélien Moreau, Martin Ross, Alena Cerny, Peter Anderer, Xi Long, and Ronald M. Aarts. Sleep Stage Classification from Heart-Rate Variability Using Long Short-Term Memory Neural Networks. *Scientific Reports*, 9:14149, 2019. doi: 10.1038/s41598-019-49703-y.
- [34] Anne M. Fink, Ulf G. Bronas, and Michael W. Calik. Autonomic Regulation During Sleep and Wakefulness: A Review with Implications for Defining the Pathophysiology of Neurological Disorders. *Clinical Autonomic Research*, 28(6):509–518, 2018. doi: 10.1007/s10286-018-0560-9.
- [35] Edward C. Harding, Nicholas P. Franks, and William Wisden. Sleep and Thermoregulation. *Current Opinion in Physiology*, 15:7–13, 2020. doi: 10.1016/j.cophys.2019.11.008.
-

-
- [36] Akane Sano, Rosalind W. Picard, and Robert Stickgold. Quantitative Analysis of Wrist Electrodermal Activity During Sleep. *International Journal of Psychophysiology*, 94(3):382–389, 2014. doi: 10.1016/j.ijpsycho.2014.09.011.
-

Lista de Acrónimos y Abreviaturas

ACC	acelerometría.
ADASYN	Adaptive Synthetic Sampling.
AHI	Apnea-Hypopnea Index.
AI	Artificial Intelligence.
BMES	Biomedical Engineering Society.
BVP	Blood Volume Pulse.
CNN	Convolutional Neural Network.
CV	Cross-Validation.
DREAMT	Dataset for Real-time sleep stage EstimAtion using Multisensor wearable Technology.
DREAMT_FE	DREAMT Feature Engineering.
ECG	electrocardiograma.
EDA	actividad electrodérmica.
EEG	electroencefalograma.
F1	F1-Score.
FN	falsos negativos.
FP	falsos positivos.
GPT	Generative Pre-trained Transformer.
HFD	Higuchi Fractal Dimension.
HR	Heart Rate.
HRV	Heart Rate Variability.
IBI	Inter-Beat Interval.
IMC	índice de masa corporal.
IQR	Interquartile Range.
KFD	Katz Fractal Dimension.
KNN	K-Nearest Neighbors.
LASSO	Least Absolute Shrinkage and Selection Operator.
LightGBM	Light Gradient Boosting Machine.
LOSO	Leave-One-Subject-Out.
LSTM	Long Short-Term Memory.
MAD	Mean Absolute Deviation.

MCC	Matthews Correlation Coefficient.
MESA	Multi-Ethnic Study of Atherosclerosis.
N1	fase 1 de sueño NREM.
N2	fase 2 de sueño NREM.
N3	fase 3 de sueño NREM.
NREM	Non-Rapid Eye Movement.
OAH	Obstructive Apnea-Hypopnea Index.
P	preparación previa al registro polisomnográfico.
pNN50	porcentaje de diferencias sucesivas superiores a 50 ms.
PPG	fotopletismografía.
PPI	Pulse-to-Pulse Interval.
PSG	polisomnografía.
R	sueño REM.
REM	Rapid Eye Movement.
RFE	Recursive Feature Elimination.
RMSSD	Root Mean Square of Successive Differences.
SampEn	Sample Entropy.
SCR	Skin Conductance Response.
SD	Standard Deviation.
SD1	desviación estándar transversal del diagrama de Poincaré.
SD2	desviación estándar longitudinal del diagrama de Poincaré.
SDNN	Standard Deviation of NN intervals.
SHAP	SHapley Additive exPlanations.
SMOTE	Synthetic Minority Over-sampling Technique.
SVM	Support Vector Machine.
TEMP	temperatura.
TFG	Trabajo Fin de Grado.
VN	verdaderos negativos.
VP	verdaderos positivos.
W	vigilia.
XGBoost	Extreme Gradient Boosting.

A. Resumen del estado del arte

Tabla A.1: Comparación de estudios del estado del arte.

Categoría	Smarandache et al. [8]	Markov et al. [11]	Lee et al. [13]	Silva [15]
Modelo final	Random Forest optimizado	Random Forest optimizado	Random Forest	Random Forest optimizado
Número de épocas del conjunto de datos	9 394 épocas de 30 s	85 542 épocas de 30 s	No reportado	12 230 ventanas de 3 min
Clases predichas	Wake/Sleep; Wake/NREM/REM; Wake/Light/Deep/-REM	Wake/Sleep	Wake/Sleep; Wake/REM/NREM; Wake/N1/N2/N3/REM	Wake/N1/N2/N3/REM
Tipo de datos	PPG procedente de dispositivo <i>wearable</i>	PPG clínico y características PPI/HRV derivadas	Datos multimodales <i>wearable</i> : BVP, ACC, EDA, TEMP, HR e IBI	PPG procedente de dispositivo <i>wearable</i> y características IBI/HRV derivadas
Selección de características	RFE	Test de normalidad, análisis de multicolinealidad y <code>SelectFromModel</code>	Ninguna	Ninguna
Balanceo de clases	Ninguno	ADASYN	SMOTE	SMOTE en entrenamiento y submuestreo en validación
Validación con separación por sujeto	No	Sí; <i>GroupKFold</i> por sujeto y LOSO	Sí; LOSO	No
Método de interpretabilidad	SHAP	Importancia de características de Random Forest	LASSO	Importancia por permutación y SHAP

B. requirements.txt

La tabla B.1 muestra cada dependencia junto con la versión instalada en el entorno virtual empleado.

Tabla B.1: Dependencias declaradas en `requirements.txt` y versiones instaladas.

Paquete	Versión	Uso en el proyecto
numpy	2.4.6	Cálculo numérico y operaciones con matrices.
pandas	2.3.3	Carga, limpieza y transformación de datos tabulares.
scikit-learn	1.9.0	Entrenamiento, evaluación y validación de modelos.
matplotlib	3.10.9	Generación de gráficas y visualizaciones.
shap	0.52.0	Interpretabilidad de modelos mediante valores SHAP.
joblib	1.5.3	Serialización y carga de modelos entrenados.
seaborn	0.13.2	Visualización estadística de resultados.
lightgbm	4.6.0	Entrenamiento del modelo LightGBM.
xgboost	3.2.0	Comparación experimental con modelos de <i>gradient boosting</i> .
imbalanced-learn	0.14.2	Aplicación de técnicas de sobremuestreo como SMOTE y ADASYN.
scipy	1.17.1	Filtrado de señales, detección de picos y cálculo estadístico.
neurokit2	0.2.13	Extracción de características fisiológicas a partir de señales.

C. Lista de características extraídas

Tabla C.1: Características extraídas por señal.

Tipo	Feature	Definición breve
BVP: Pulso Sanguíneo Periférico		
Estadística	BVP_mean	Media de la amplitud de la señal BVP.
	BVP_median	Mediana de la amplitud de la señal BVP.
	BVP_std	Desviación estándar de la señal BVP.
	BVP_min	Valor mínimo de la señal BVP.
	BVP_max	Valor máximo de la señal BVP.
	BVP_range	Diferencia entre el máximo y el mínimo.
	BVP_iqr	Rango intercuartílico de la señal BVP.
	BVP_mad	Desviación absoluta media de la señal BVP.
	BVP_rms	Valor cuadrático medio de la señal BVP.
	BVP_skewness	Asimetría de la distribución de amplitudes.
	BVP_kurtosis	Curtosis de la distribución de amplitudes.
Complejidad	BVP_Hjorth_mobility	Movilidad de Hjorth de la señal BVP.
	BVP_Hjorth_complexity	Complejidad de Hjorth de la señal BVP.
HRV: Variabilidad de la Frecuencia Cardíaca derivada de BVP		
Temporal	HRV_SDNN	Desviación estándar de los intervalos entre latidos.
	HRV_RMSSD	Raíz cuadrática media de diferencias sucesivas entre intervalos.
	HRV_pNN50	Porcentaje de diferencias sucesivas superiores a 50 ms.

Continued on next page

Tabla C.1: Características extraídas por señal. (Continued)

Tipo	Feature	Definición breve
Poincaré	HRV_SD1	Variabilidad de corto plazo en el diagrama de Poincaré.
	HRV_SD2	Variabilidad de largo plazo en el diagrama de Poincaré.
	HRV_SD1SD2	Relación entre la variabilidad de corto y largo plazo.
Complejidad	HRV_HFD	Dimensión fractal de Higuchi de los intervalos cardíacos.
	HRV_KFD	Dimensión fractal de Katz de los intervalos cardíacos.
	HRV_SampEn	Entropía muestral de la variabilidad cardíaca.
HR: Frecuencia Cardíaca		
Estadística	HR_mean	Frecuencia cardíaca media de la época.
	HR_median	Mediana de la frecuencia cardíaca.
	HR_max	Frecuencia cardíaca máxima.
	HR_min	Frecuencia cardíaca mínima.
	HR_std	Desviación estándar de la frecuencia cardíaca.
IBI: Intervalos entre Latidos		
Estadística	IBI_mean	Intervalo medio entre latidos.
	IBI_median	Mediana del intervalo entre latidos.
	IBI_max	Mayor intervalo entre latidos.
	IBI_min	Menor intervalo entre latidos.
	IBI_std	Desviación estándar de los intervalos entre latidos.
ACC: Acelerometría Triaxial		
Estadística filtrada	ACC_X_trimmed_mean	Media filtrada del eje X.
	ACC_X_trimmed_max	Máximo filtrado del eje X.
	ACC_X_trimmed_IQR	Rango intercuartílico filtrado del eje X.
	ACC_Y_trimmed_mean	Media filtrada del eje Y.

Continued on next page

Tabla C.1: Características extraídas por señal. (Continued)

Tipo	Feature	Definición breve
Estadística	ACC_Y_trimmed_max	Máximo filtrado del eje Y.
	ACC_Y_trimmed_IQR	Rango intercuartílico filtrado del eje Y.
	ACC_Z_trimmed_mean	Media filtrada del eje Z.
	ACC_Z_trimmed_max	Máximo filtrado del eje Z.
	ACC_Z_trimmed_IQR	Rango intercuartílico filtrado del eje Z.
	ACC_X_MAD_trimmed_mean	Media de la desviación absoluta media del eje X.
	ACC_X_MAD_trimmed_max	Máximo de la desviación absoluta media del eje X.
	ACC_X_MAD_trimmed_IQR	IQR de la desviación absoluta media del eje X.
	ACC_Y_MAD_trimmed_mean	Media de la desviación absoluta media del eje Y.
	ACC_Y_MAD_trimmed_max	Máximo de la desviación absoluta media del eje Y.
	ACC_Y_MAD_trimmed_IQR	IQR de la desviación absoluta media del eje Y.
	ACC_Z_MAD_trimmed_mean	Media de la desviación absoluta media del eje Z.
	ACC_Z_MAD_trimmed_max	Máximo de la desviación absoluta media del eje Z.
	ACC_Z_MAD_trimmed_IQR	IQR de la desviación absoluta media del eje Z.
	ACC_INDEX	Índice agregado de variabilidad de la aceleración.
EDA: Actividad Electrodermal		
Amplitud SCR	SCR_Height_mean	Altura media de las respuestas electrodermales.
	SCR_Height_max	Altura máxima de las respuestas electrodermales.
	SCR_Amplitude_mean	Amplitud media de las respuestas electrodermales.

Continued on next page

Tabla C.1: Características extraídas por señal. (Continued)

Tipo	Feature	Definición breve
Temporal SCR	SCR_Amplitude_max	Amplitud máxima de las respuestas electrodermales.
	SCR_RiseTime_mean	Tiempo medio de subida de las respuestas SCR.
	SCR_RiseTime_max	Tiempo máximo de subida de las respuestas SCR.
	SCR_RecoveryTime_mean	Tiempo medio de recuperación de las respuestas SCR.
	SCR_RecoveryTime_max	Tiempo máximo de recuperación de las respuestas SCR.
TEMP: Temperatura Periférica		
Estadística	TEMP_mean	Temperatura media de la época.
	TEMP_median	Mediana de la temperatura.
	TEMP_max	Temperatura máxima.
	TEMP_min	Temperatura mínima.
	TEMP_std	Desviación estándar de la temperatura.

D. Uso de inteligencia artificial

Durante el desarrollo de este trabajo se han utilizado herramientas de inteligencia artificial generativa como apoyo en distintas tareas de documentación, programación y edición. En concreto, se ha empleado ChatGPT, en su versión GPT-5.5, para asistir en la búsqueda y localización de bibliografía relevante, identificar trabajos relacionados con la clasificación de etapas del sueño mediante dispositivos *wearable* y preparar las correspondientes referencias bibliográficas. Las fuentes sugeridas mediante esta herramienta fueron posteriormente revisadas y contrastadas antes de incorporarlas al documento. Se utilizó también para la síntesis y comparación de información relevante extraída de los artículos seleccionados.

Asimismo, ChatGPT se utilizó como apoyo para la generación y edición de elementos destinados a mejorar la legibilidad de la memoria, como tablas comparativas, esquemas, diagramas y gráficos en formato $\text{\LaTeX}$. Su uso se centró principalmente en proponer estructuras visuales, adaptar su formato al espacio disponible en el documento y generar código compatible con los paquetes utilizados en la plantilla.

También se emplearon herramientas de inteligencia artificial para asistir en la implementación del código desarrollado durante el proyecto. Parte de este código se basó en metodologías y fragmentos públicamente disponibles en repositorios abiertos, especialmente aquellos relacionados con el preprocesamiento de señales fisiológicas, la extracción de características y su posterior selección. El código obtenido de estas fuentes debidamente referenciadas no se incorporó de forma directa, sino que fue estudiado, modificado y adaptado a las necesidades específicas del trabajo, que le fueron planteadas a ChatGPT para que generara propuestas de código que se ajustaran a los requisitos técnicos y metodológicos del proyecto.

Adicionalmente, se utilizó Codex integrado en el entorno de desarrollo Visual Studio Code como herramienta de asistencia para la resolución de errores de programación y configuración. Su uso estuvo orientado principalmente a detectar problemas de dependencias, interpretar mensajes de error, resolver incompatibilidades del entorno de ejecución y corregir incidencias relacionadas con la compilación y adaptación de la plantilla $\text{\LaTeX}$.

En todos los casos, las herramientas de inteligencia artificial se utilizaron como sistemas de apoyo y no como sustitutos del proceso de análisis y toma de decisiones. La

selección de las fuentes bibliográficas, el diseño metodológico, la implementación final del código, la ejecución de los experimentos, la interpretación de los resultados y la revisión del contenido generado fueron decisiones tomadas personalmente y siempre basados en las referencias consultadas. Del mismo modo, las propuestas producidas mediante inteligencia artificial fueron verificadas, corregidas o descartadas cuando no se ajustaban a los requisitos técnicos y académicos del proyecto.
