



Clasificación de etapas del sueño a partir de señales de dispositivos wearable mediante modelos de aprendizaje automático interpretables

Grado en Ingeniería Informática

Trabajo Fin de Grado

Autor:

Alejandro Cerezal Jiménez

Tutor/es:

Manuel Campos Martínez



Facultad
de Informática
UMU

Clasificación de etapas del sueño a partir de señales de dispositivos wearable mediante modelos de aprendizaje automático interpretables

Análisis de la importancia de las características fisiológicas
en la clasificación de etapas del sueño.

Autor

Alejandro Cerezal Jiménez


Tutor/es

Manuel Campos Martínez

Departamento de Informática y Sistemas



UNIVERSIDAD
DE MURCIA



Facultad
de Informática

Grado en Ingeniería Informática

Murcia, 9 de Junio de 2026

Convocatoria de Junio

Índice general

1	Introducción	1
2	Estado del arte	3
2.1	Estudios basados en rendimiento	4
2.2	Estudios basados en explicabilidad	4
3	Análisis de objetivos	9
3.1	Justificación del trabajo	9
3.2	Objetivos específicos	10
4	Materiales	11
4.1	Base de datos DREAMT	11
4.2	Explicación de RF y SHAP	13
5	Metodología	15
5.1	Descripción y justificación del preprocesamiento y extracción de features	15
5.1.1	Introducción	15
5.1.2	BVP	16
5.1.3	HR e IBI	17
5.1.4	ACC	17
5.1.5	EDA	18
5.1.6	TEMP	18
5.2	Descripción y justificación de la implementación de RF y SHAP	18
5.3	Posibles probaturas	18
6	Resultados obtenidos	19
6.1	Posibles comparativas	19
7	Conclusiones y vías futuras	21
	Bibliografía	23
	Lista de Acrónimos y Abreviaturas	27

Índice de figuras

Índice de tablas

4.1	Resumen visual de las señales de Empatica E4 disponibles en DREAMT.	12
5.1	Implementaciones del script <code>feature_engineering.py</code> de DREAMT_FE consultadas en cada funcionalidad.	18

Índice de Códigos

1 Introducción

Un buen descanso es vital para la salud. La presencia de malos hábitos de sueño da lugar a desequilibrios hormonales y del sistema inmunitario, que pueden derivar progresivamente en patologías crónicas como la diabetes tipo 2, hipertensión arterial, obesidad y trastornos de salud mental tales como la depresión [1]. Por ello, la población global está cada vez más concienciada con la calidad de su sueño. [2]

Desde el punto de vista fisiológico, el sueño no es un estado homogéneo, sino que se organiza en una arquitectura cíclica compuesta por fases de sueño REM (movimiento ocular rápido) y sueño no REM (NREM). El sueño NREM incluye estados progresivamente más profundos, mientras que el sueño REM se caracteriza por una mayor actividad cerebral y se asocia con procesos como la regulación emocional y la consolidación de la memoria. En adultos sanos, el sueño NREM representa aproximadamente el 75–80% del tiempo total de sueño, mientras que el sueño REM supone alrededor del 20–25%, alternándose ambas fases en ciclos de unos 90–120 minutos a lo largo de la noche [3, 4]. Por ello, la calidad del sueño depende de la estabilidad y continuidad de esta arquitectura. La fragmentación del sueño puede modificar la proporción y organización de las fases NREM y REM, reducir la eficiencia del sueño y afectar negativamente a funciones cognitivas como la atención, la inhibición y la sensación subjetiva de fatiga [5]. En consecuencia, el seguimiento de estas fases resulta relevante para evaluar de forma más completa la salud del sueño, detectar alteraciones en su estructura y favorecer intervenciones orientadas a mejorar los hábitos de descanso y el estado general de salud.

La polisomnografía (PSG) se considera el estándar clínico de referencia para el estudio del sueño, ya que permite registrar de forma simultánea múltiples señales fisiológicas, como la actividad cerebral, los movimientos oculares, la actividad muscular, la respiración y la saturación de oxígeno, posibilitando así una identificación precisa de las fases de sueño y de posibles trastornos asociados [6]. Sin embargo, se trata de una técnica costosa, poco accesible y generalmente dependiente de entornos clínicos especializados, lo que dificulta su uso repetido o prolongado en la vida cotidiana. En este contexto, los dispositivos *wearable* han adquirido una relevancia creciente como alternativa cómoda, no invasiva y de bajo coste relativo para el seguimiento longitudinal del sueño, permitiendo recoger señales como acelerometría, frecuencia cardíaca o fotopleletismografía en condiciones domésticas. Esta tendencia refleja un interés cada vez mayor de la población por monitorizar su descanso mediante tecnologías de consumo. En el último año, el porcentaje de usuarios de dispositivos *wearable* que realizan

un seguimiento regular de su sueño ha aumentado de un 16% a un 53% globalmente. [2].

Es por ello que el desarrollo de algoritmos de clasificación de fases del sueño basados en datos recogidos mediante dispositivos *wearable* se ha convertido en un área de investigación activa, con el objetivo de mejorar la precisión y utilidad de estas herramientas para la evaluación del sueño en entornos no clínicos. En este contexto, el presente trabajo se centra en la aplicación de técnicas de aprendizaje automático interpretables para poder clasificar las fases del sueño a partir de datos al alcance de todos los usuarios y, principalmente, tratar de descubrir qué características de las señales fisiológicas son más relevantes para esta tarea, con el fin de que futuras investigaciones puedan poner el foco en los atributos más importantes.

2 Estado del arte

Como se ha mencionado, la monitorización del sueño mediante dispositivos wearable es una tendencia creciente entre la población. Esto, junto a difícil accesibilidad a los entornos clínicos basados en PSG, ha hecho que la clasificación automática de etapas del sueño a partir de señales fisiológicas registradas mediante dispositivos *wearable* se haya consolidado en los últimos años como una línea de investigación relevante dentro del análisis computacional del sueño. Sin embargo, la sustitución o aproximación de la información polisomnográfica mediante señales más limitadas, como acelerometría (ACC), frecuencia cardíaca o fotopletismografía (PPG), plantea todavía importantes retos desde el punto de vista del modelado, la generalización y la fiabilidad de las predicciones.

En la literatura reciente pueden identificarse dos orientaciones principales en el desarrollo de modelos de clasificación de etapas del sueño en este contexto. La primera orientación se centra en el diseño de modelos cada vez más potentes, capaces de capturar dependencias temporales complejas y mejorar las métricas de clasificación respecto a aproximaciones anteriores. En esta línea se sitúan arquitecturas profundas basadas en redes convolucionales, redes recurrentes, mecanismos de atención, modelos híbridos y, más recientemente, arquitecturas secuenciales avanzadas. Estos trabajos suelen priorizar el rendimiento predictivo, buscando aproximarse lo máximo posible a la clasificación profesional determinada con la evidencia obtenida mediante PSG.

La segunda orientación, que es la que marca enfoque adoptado en este trabajo, pone el énfasis en la explicabilidad del modelo y en la comprensión de las variables que influyen en la clasificación de las etapas del sueño. En lugar de buscar el mejor rendimiento posible, estos trabajos intentan construir modelos que permitan analizar qué características extraídas de las señales *wearable* contribuyen en mayor medida a distinguir entre vigilia, sueño REM y sueño NREM. Esta perspectiva es especialmente interesante cuando se trabaja con señales fisiológicas reducidas, ya que permite estudiar hasta qué punto variables como el movimiento corporal, la frecuencia cardíaca o medidas derivadas contienen información útil para aproximar la arquitectura del sueño.

2.1 Estudios basados en rendimiento

Más breve que la siguiente sección, solo por contextualizar lo que se investiga sin entrar en detalles técnicos. A mí me gustaría ponerla aunque no sé si es suficientemente relevante para el TFG. Discutir con tutor.

2.2 Estudios basados en explicabilidad

Vamos a anañizar ahora la literatura actual respectiva a la clasificación de etapas del sueño se centra en el desarrollo de modelos interpretables.

Primera fuente: (Indexación temporal)

En esta línea, Smarandache et al. proponen un modelo interpretable basado en *Random Forest* para la clasificación de etapas del sueño a partir de señales de fotopletiografía (PPG), complementado con explicaciones mediante SHAP [7]. El estudio utiliza registros nocturnos procedentes de 10 voluntarios del Charité Hospital de Berlín [8, 9], todos ellos con trastornos respiratorios del sueño, incluyendo señales PSG y PPG. Las señales se segmentan en épocas de 30 segundos y las etiquetas se obtienen manualmente por expertos.. El trabajo plantea tres tareas de clasificación: una clasificación binaria sueño-vigilia, una clasificación de tres clases diferenciando vigilia, NREM y REM, y una clasificación de cuatro clases con vigilia, sueño ligero, sueño profundo (que dividen NREM) y REM.

Hay dos aspectos especialmente relevantes en este trabajo. En primer lugar, la elección del modelo Random Forest, tras obtener este mejores métricas de clasificación que otros modelos como SVM, KNN y Logistic Regression, así como el uso de SHAP para analizar la importancia de las variables de entrada, lo que permite interpretar qué características extraídas de la señal PPG contribuyen a la clasificación de las etapas del sueño. En segundo lugar, lo que llaman *pulse wave feature fusion*. Esto es, la extracción características estadísticas, temporales y no lineales de la señal PPG medida. La idea fisiológica es que la señal PPG cruda contiene información indirecta como variabilidad cardiovascular, vasodilatación o cambios respiratorios. Estos fenómenos experimentan cambios entre las fases de vigilia, REM y NREM, por lo que se busca que las features mencionadas aporten información discriminativa.

Sin embargo, para reducir dimensionalidad y eliminar variables redundantes, los autores aplican *Recursive Feature Elimination (RFE)* para seleccionar solamente las 10 características más relevantes. El procedimiento es simple, se entrena un modelo con todas las features y se elimina la que menos ha aportado a la clasificación de etapas según SHAP. Este proceso se repite iterativamente hasta conseguir el número de características deseado. El estudio afirma que las 10 features que pasan el filtro, en orden

de aportación general a la clasificación, son: dimensión fractal de Higuchi, complejidad de Hjorth, media geométrica, momento central, factor de forma, valor máximo, media recortada al 25%, valor mínimo, desviación absoluta mediana y media aritmética.

Segunda fuente:

Un enfoque similar es el de Markov et al., que desarrollan un modelo basado en características (feature-based) para la clasificación esta vez solamente entre sueño y vigilia utilizando PPG [10]. En este caso, la base de datos utilizada es la *Cyclic Alternating Pattern Sleep Database* de PhysioNet [11], compuesta por 84 participantes que presentaban trastornos del sueño, a los que se les realizó un registro completo PSG. Para la clasificación sueño-vigilia se emplearon únicamente las señales PPG y las etiquetas que sirvieron como *ground truth* fueron anotadas por expertos basándose en los registros PSG.

Del preprocesamiento de la señal cruda PPG se obtienen finalmente 85.542 épocas de 30 segundos con su correspondiente etiqueta. Uno de los problemas que se trata en el artículo es el desbalanceo de las clases debido a agrupar todas las etiquetas REM y NREM como *Sleep*. Para equilibrar la distribución de 19% *Wake* y 81% *Sleep*, los autores aplican ADASYN para generar de forma adaptativa muestras sintéticas de la clase minoritaria. En el artículo se realiza un exhaustivo procedimiento de extracción y selección de características. Se obtienen inicialmente 330 características por época y se aplica una selección de variables más elaborada que la descrita en la anterior referencia [7]. Tras un test de normalidad, eliminación de variables redundantes por multicolinealidad y la aplicación del método *SelectFromModel* para filtrar las features que se sitúan por debajo de un umbral de importancia, se obtienen finalmente 75 características para el dataset original y 35 para el dataset balanceado con ADASYN.

Tras comparar varios modelos basados en *LightGBM*, *XGBoost* y *Random Forest*, se eligió este último como clasificador principal. Se realiza una optimización de hiperparámetros por *Matthews Correlation Coefficient (MCC)* aplicando secuencialmente *Randomized Search* y *Grid Search*, que concretan una distribución de parámetros óptima para cada dataset. Para evitar fuga de información entre sujetos, se utiliza una estrategia de validación cruzada agrupada por individuos. Se prueban varios tamaños de partición concluyendo que los resultados son estables. Para estudiar el rendimiento entre distintas patologías, se realiza también una validación cruzada *Leave-One-Subject-Out (LOSO)*.

Los resultados demuestran que el modelo en el dataset original obtiene mejor F1 Score (89,05% frente a 81,40% en el dataset balanceado), pero tiene más problemas para detectar la vigilia. Otro aspecto a destacar es que, para la explicabilidad del modelo, se basan en las *feature importances* del Random Forest, observando que la importancia

de las características cambia en función del dataset utilizado.

Sin embargo, este trabajo presenta algunas limitaciones que se exponen en el mismo artículo. La primera de ellas es que la clasificación se limita a dos clases y ni siquiera diferencia las etapas REM y NREM. La segunda es que, pese a que se trabaja con PPG para reivindicar la monitorización del sueño mediante dispositivos *wearable* frente a la PSG, la base de datos se ha obtenido clínicamente y no presenta la variabilidad y el ruido que se encontraría en un entorno de monitorización domiciliaria. También se menciona la posibilidad de trabajar en un futuro con un dataset sin datos sintéticos de ADASYM o de utilizar SHAP para mejorar la interpretabilidad.

Tercera fuente:

También resultan relevantes los trabajos presentados en entornos de conferencia ya que, pese a no poder leer más que el abstract de congreso, nos permiten conocer las tendencias de investigación en el área. En la reunión anual de la Biomedical Engineering Society (BMES) de 2024, Jean Lee, Shaurya Bisht y Grace X. Gao presentan un estudio acerca de modelos específicos de género para la clasificación de etapas del sueño con datos de dispositivos *wearable* [12]. Para ello, utiliza la base de datos DREAMT [13], la cual se describe en profundidad en la sección 4.1, que contiene registros de 100 sujetos con señales procedentes de la pulsera Empatica E4. El estudio, a diferencia de los anteriores, utiliza tanto BVP (equivalente a PPG) como métricas de movimiento y temperatura para evaluar diferentes tareas de clasificación: sueño-vigilia, vigilia-REM-NREM y clasificación de cinco clases con vigilia, N1, N2, N3 y REM. Su principal objetivo es comparar el rendimiento de modelos entrenados con datos de un género específico frente a modelos genéricos.

Se entrenan los modelos *Random Forest* (que vuelve a dar los mejores resultados de clasificación), regresión logística y LASSO, siendo este último el que utilizan para la interpretar qué características son más relevantes debido a su capacidad de selección de variables. A la hora de la validación se aplicó LOSO y se corrigió el desbalanceo de clases, especialmente presente en la clasificación de 5 clases por la escasa representación de N1 y N3, mediante SMOTE.

Los resultados del resumen indican que las características de IBI, las variables circadianas y las métricas de acelerometría tienen un papel relevante en la discriminación entre etapas, mientras que N1 y N3 aparecen como clases especialmente difíciles de detectar por su menor representación y por la mayor ambigüedad fisiológica. A su vez, los modelos específicos de género muestran un rendimiento ligeramente superior al modelo genérico, lo que sugiere que las diferencias fisiológicas entre géneros pueden influir en la clasificación del sueño a partir de señales *wearable*.

Cuarta fuente:

Finalmente, Vasco António Portilho Carvalho da Silva expone una tesis en el Instituto Superior de Ingeniería de Porto en la que aborda el uso de dispositivos de muñeca para monitorización personalizada del sueño mediante modelos de inteligencia artificial y técnicas de explicabilidad [14]. La tesis plantea un marco general para integrar datos multimodales procedentes de *wearables*, principalmente PPG y acelerometría, con el objetivo de realizar clasificación de etapas del sueño y detección de apnea.

En la parte dedicada a la clasificación de etapas del sueño, se utiliza un subconjunto de la base de datos MESA Sleep [15], con anotaciones polisomnográficas de expertos en cinco clases: vigilia, N1, N2, N3 y REM. Las señales PPG obtenidas con el dispositivo Actiwatch Spectrum se segmentan en épocas de 30 segundos y se alinean con las etiquetas de la PSG. Posteriormente, se extraen características de la señal PPG relacionadas con la morfología del pulso y con la serie de intervalos entre latidos para cada época. A diferencia de los trabajos anteriores, Silva no trata las épocas de 30 segundos independientemente, sino que las agrupa en ventanas deslizantes de 3 minutos que avanzan cada 60 segundos, es decir, con solapamiento. Se justifica esta segmentación por la naturaleza de las características y se etiquetan en función de la clase mayoritaria dentro de la ventana.

Se experimentó también un problema de desbalanceo de clases, que se resuelve con una estrategia híbrida: SMOTE para generar muestras sintéticas de las clases minoritarias en los conjuntos de entrenamiento y submuestreo aleatorio para equiparar las proporciones en los conjuntos de validación. Se comparan 6 modelos clásicos con optimización de hiperparámetros y *Random Forest* es el que obtiene mejores métricas globales, aunque sigue teniendo problemas para reconocer N1 debido a la naturaleza fisiológica de esta etapa del sueño.

La interpretabilidad en la tesis se articula de forma distinta en función de si es global o por clases. A nivel de explicabilidad global, se aplica *permutation importance* para evaluar la variabilidad del resultado cuando cada una de las características es permutada. Respecto a la explicabilidad por clases, se utiliza SHAP para concretar las features que más influyen en la predicción de cada etapa del sueño.

Resumen:

En conjunto, estos trabajos muestran que los modelos interpretables de clasificación del sueño suelen compartir una estrategia común: sustituir la entrada directa de señales crudas por un conjunto de características fisiológicas, entrenar modelos clásicos para la clasificación de distinto número de etapas del sueño, y complementar el análisis mediante técnicas de explicabilidad para entender las características que más aportan

a la predicción. Esta orientación resulta especialmente adecuada para trabajos basados en señales *wearable*, ya que permite estudiar qué información aportan realmente la acelerometría, la PPG, la frecuencia cardíaca, la variabilidad del pulso o las variables circadianas en la clasificación de las etapas del sueño. A continuación, tablas comparando distintos ámbitos de los estudios: Métricas, features más relevantes, ...

3 Análisis de objetivos

Una vez analizado el estado del arte, se expone el objetivo general de este trabajo así como los objetivos específicos que se pretenden alcanzar. Aquí se explicará cuál es el objetivo del trabajo. Un modelo RandomForest con explicabilidad SHAP para buscar la importancia de cada feature a la hora de clasificar cada etapa del sueño.

3.1 Justificación del trabajo

El proyecto a realizar se enmarca dentro del ámbito de la clasificación de etapas del sueño a partir de señales procedentes de dispositivos *wearable* mediante modelos de aprendizaje automático interpretables. Concretamente, se empleará un modelo de *Random Forest* para la predicción de las clases vigilia, REM y NREM. La elección de este modelo específico viene motivada por su obtención de mejores métricas de rendimiento en este contexto en comparación con otros modelos como Regresión Logística, SVM, LASSO, *XGBoost* o *LightGBM*, entre otros, según los estudios previamente mencionados [7, 10, 12, 14].

Para entrenar y validar el modelo, se empleará la base de datos DREAMT. Esta database de PhysioNet contiene registros de señales fisiológicas del sueño capturadas con la pulsera Empatica E4, lo que la convierte en un fuente apropiada para el ámbito de estudio basado en datos recogidos por dispositivos *wearable*. Además, contiene anotaciones de las etapas del sueño realizadas por expertos, lo que permite una evaluación rigurosa del modelo. Un aspecto a favor de DREAMT respecto a otras bases de datos utilizadas en estudios de la literatura es que, además de la señal PPG que estas ofrecen, contiene registros de acelerometría, actividad electrodérmica y temperatura cutánea, permitiendo un análisis de interpretabilidad más completo.

Siguiendo la línea de los estudios analizados en el estado del arte, el flujo de trabajo comenzará con un preprocesamiento de los datos crudos para la extracción de características con las que alimentar al modelo de clasificación. Este enfoque nos aporta también mayor explicabilidad a la hora de analizar las variables fisiológicas en las que más se apoya el modelo para predecir cada fase. Esto se implementa mediante SHAP, una técnica que ya emplean y sugieren varios de los estudios analizados previamente. Con ella, se analizará la importancia de cada característica tanto a nivel global como para cada etapa del sueño.

3.2 Objetivos específicos

La fiabilidad de la clasificación será estandar, no se busca mejorarla pero debe ser algo parecido a la media de la literatura. El objetivo principal es la interpretabilidad, que se explique qué features son más importantes para cada etapa que vamos a clasificar (de momento 3) y también globalmente.

Así, los objetivos específicos de este trabajo pretende alcanzar son:

- Preprocesar los datos crudos de DREAMT para la extracción de características fisiológicas.
 - Implementar un modelo de clasificación basado en *Random Forest* para predecir las clases vigilia, REM y NREM a partir de las características extraídas.
 - Evaluar el rendimiento del modelo utilizando métricas estándar como precisión, recall, F1-score y matriz de confusión, comparando los resultados con los obtenidos en estudios previos.
 - Aplicar la técnica de explicabilidad SHAP para analizar la importancia de cada característica en la predicción de etapas del sueño, tanto a nivel global como específico para cada clase.
 - Realizar comparaciones en la medida de lo posible con los resultados que han obtenido otros estudios.
-

4 Materiales

En esta sección se describen los materiales y herramientas metodológicas que sustentan el desarrollo del trabajo. Se busca establecer una base clara sobre los datos empleados y sobre las técnicas de aprendizaje automático e interpretabilidad utilizadas para abordar el problema.

4.1 Base de datos DREAMT

DREAMT, acrónimo de *Dataset for Real-time sleep stage EstimAtion using Multi-sensor wearable Technology*, es una base de datos publicada en PhysioNet orientada al estudio de la estimación de etapas del sueño mediante señales procedentes de dispositivos *wearable*. Como ya se ha explicado, su principal interés para este trabajo reside en que combina registros de una pulsera multisensor con anotaciones clínicas de sueño obtenidas a partir de polisomnografía, lo que permite plantear un problema de aprendizaje supervisado en el que las señales recogidas por el dispositivo portátil actúan como entrada y las fases del sueño anotadas por técnicos expertos sirven como *ground truth* [13, 16, 17].

La base de datos fue recopilada a partir de 100 participantes a los que se les realizaba un estudio nocturno del sueño, diseñado principalmente para detectar y monitorizar eventos de apnea durante el sueño, y se les colocaba una pulsera Empatica E4 en la muñeca izquierda. La adquisición combinaba, por tanto, el registro continuo de señales del dispositivo *wearable* con una polisomnografía clínica nocturna realizada mediante el sistema Nihon Kohden Polysmith 1004.

La población incluida en DREAMT corresponde a pacientes procedentes de un laboratorio de trastornos del sueño, con una presencia relevante de alteraciones respiratorias como la apnea obstructiva del sueño. La página oficial de PhysioNet indica una edad media de 56.2 ± 16.6 años, un índice de masa corporal medio de 33.7 ± 8.6 kg/m², un OAHÍ medio de 19.4 ± 27.5 eventos/hora y un AHI medio de 22.1 ± 28.7 eventos/hora. Además, 68 de los 100 participantes presentaban obesidad o obesidad severa, definida como un IMC mayor o igual a 30 kg/m²; entre los 23 participantes con apnea obstructiva del sueño severa, definida como AHI mayor de 30 eventos/hora, 17 eran obesos o severamente obesos. Esta composición convierte a DREAMT en una base de datos especialmente relevante para evaluar modelos de estimación del sueño en una población

clínica, más compleja que una muestra formada únicamente por sujetos sanos.

En cuanto al contenido de la base de datos, se incluyen señales procedentes de la pulsera Empatica E4 y señales de PSG alineadas temporalmente. Las señales del dispositivo *wearable* comprenden seis señales crudas: pulso de volumen sanguíneo o *Blood Volume Pulse* (BVP), acelerometría triaxial en los ejes ACC_X, ACC_Y y ACC_Z, actividad electrodérmica (EDA) y temperatura cutánea (TEMP). Además, se proporcionan dos señales derivadas del BVP: la frecuencia cardíaca (HR) y el intervalo entre latidos (IBI). Estas señales permiten estudiar distintos aspectos fisiológicos relacionados con el sueño, como la actividad cardiovascular, el movimiento corporal y la variación térmica.

Tabla 4.1: Resumen visual de las señales de Empatica E4 disponibles en DREAMT.

Categoría	Señales	Interpretación
Cardiovascular	BVP, HR, IBI	Pulso periférico, frecuencia cardíaca e intervalos entre latidos.
Movimiento	ACC_X, ACC_Y, ACC_Z	Actividad motora de la muñeca en tres ejes espaciales.
Actividad electrodérmica	EDA	Cambios en la conductancia de la piel asociados a activación simpática.
Temperatura	TEMP	Temperatura cutánea periférica de la muñeca.

Las etiquetas de sueño incluidas en DREAMT proceden de las anotaciones realizadas por técnicos expertos a partir de la PSG. Estas etiquetas se proporcionan en épocas de 30 segundos, siguiendo la estructura habitual de los estudios de sueño. Las clases disponibles incluyen vigilia (W), sueño NREM en sus etapas N1, N2 y N3, y sueño REM (R). También se contempla una etiqueta de preparación previa al inicio del registro polisomnográfico y una etiqueta de datos ausentes en casos puntuales. Para una clasificación simplificada como la de este trabajo, las etapas N1, N2 y N3 pueden agruparse en una única clase NREM, obteniendo así un problema de clasificación en tres clases.

La base de datos se organiza en dos modalidades principales. La carpeta `data_64Hz` contiene únicamente las señales procedentes del dispositivo Empatica E4, remuestreadas a 64 Hz y alineadas mediante una marca temporal común, junto con las etiquetas derivadas de la PSG. Según la documentación oficial, no se aplica preprocesamiento adicional sobre los datos crudos más allá del remuestreo. Por otro lado, la car-

peta `data_100Hz` incluye tanto las señales del dispositivo *wearable* como las señales de polisomnografía, todas ellas remuestreadas a 100 Hz para facilitar su alineamiento temporal. Esta segunda modalidad incorpora canales clínicos como electroencefalograma (EEG), electrocardiograma (ECG), señales respiratorias, ronquido, movimiento de piernas, saturación de oxígeno en sangre y demás señales que no son del interés de este estudio de clasificación a partir de datos recopilados con dispositivos *wearable*.

La carpeta `data_64Hz`, que es la que se empleará en este trabajo, contiene un archivo CSV por cada participante, con las señales del dispositivo *wearable* y las etiquetas de sueño correspondientes a cada época de 30 segundos. Cada fila del CSV representa una época de 30 segundos, con columnas para cada señal (BVP, HR, IBI, ACC_X, ACC_Y, ACC_Z, EDA, TEMP) y una columna adicional para la etiqueta de sueño (W, NREM o REM). Esta estructura facilita el preprocesamiento y la extracción de características necesarias para alimentar al modelo de clasificación.

En definitiva, la elección de DREAMT como base de datos para este trabajo, como ya han realizado otras investigaciones [12], otorga un punto de partida adecuado. Sin embargo, con el objetivo de alcanzar resultados competentes, se requiere un enfoque de extracción de características acertado.

4.2 Explicación de RF y SHAP

Aquí es donde, una vez justificado el uso de RF y SHAP en el capítulo anterior, toca explicarlos teóricamente.

5 Metodología

Se explicará el proceso lógico de preprocesamiento de los datos crudos y toda la extracción de features desde DREAMT. También si se hacen pruebas con las features de entrada.

Supongo que aquí iría bien un gráfico enseñando el flujo de trabajo. Estaría bien poner un plan de ruta: Preprocesamiento DREAMT -> Extracción de features -> Clasificación RandomForest -> Explicabilidad SHAP -> Análisis de resultado

5.1 Descripción y justificación del preprocesamiento y extracción de features

Aquí hablaremos cómo hay que tratar DREAMT para conseguir las features que necesitamos.

Esto parece bastante laborioso. Por seguir un orden, para cada paciente tenemos su csv masivo, que tiene una fila por cada 1/64 segundos. Esa fila tiene los atributos medidos (BVP, ACC, etc). Queremos agrupar en épocas de 30 segundos, porque esa es la frecuencia de las etiquetas. ¿Cómo?

Lo primerísimo es quitar los registros P y Missing. No vamos a preprocesar datos cuya etiqueta no nos vale. Se habla también de un control de calidad por sujeto, filtrando por porcentaje de registros fallutos. Como sea, esto tiene pinta de que hay que separarlo por atributos:

Empezamos con BVP. Esta se toma a 64Hz así que cada fila es un nuevo registro. Aquí habla primero de filtrar los Nan o interpolarlos (no pinta). A continuación, filtro pasabanda. Esto es porque la señal viene contaminada con ruido por ser wearable. Se estima un rango de 0.5-7Hz recomendado, que equivale a estar entre 30 y 420 latidos por minuto (crazy).

LAS FEATURES SE EXTRAEN POR CADA ÉPOCA DE 30 SEGS.

5.1.1 Introducción

Los datos recopilados mediante dispositivos *wearable* están expuestos a ruido que puede afectar la calidad de las mediciones. Es por ello que, para asegurar una clasificación

de las etapas del sueño de forma rigurosa, se debe de realizar un preprocesamiento adecuado de la base de datos. Además de esto, DREAMT contiene registros con distinta frecuencia de muestreo, sensibilidad al ruido y significado fisiológico. Trabajar directamente con las señales crudas exigiría arquitecturas profundas capaces de aprender representaciones temporales complejas, lo que incrementa la dimensionalidad, el coste computacional y la dificultad de interpretación.

Tanto esta situación como la correspondencia de las anotaciones de etapas del sueño basadas en PSG con épocas de 30 segundos convierten a la extracción de características derivadas de los registros en una estrategia efectiva para resumir la información concentrada en cada una de estas épocas. Este enfoque no solo reduce la dimensionalidad del problema, sino que facilita la explicabilidad del modelo. Las características extraídas pueden relacionarse con mecanismos fisiológicos conocidos, como la reducción del movimiento durante el sueño, los cambios autonómicos entre REM y NREM o la distribución temporal de las fases a lo largo de la noche.

Para la implementación del preprocesamiento y la extracción de características, se utiliza como base el repositorio abierto `DREAMT_FE` [?]. Sobre él se fundamenta toda la implementación del proceso, discrepando solamente en algunas decisiones de diseño. A continuación, se describen las técnicas de preprocesamiento y extracción de características aplicadas a cada uno de los registros utilizados en este estudio: BVP, HR, IBI y ACC.

5.1.2 BVP

La señal BVP, muestreada a 64Hz, se filtra mediante un filtro pasabanda Chebyshev tipo II, explicado en la sección (). Este tipo de filtro permite atenuar las componentes frecuenciales situadas fuera de la banda de interés, es decir, las muestras que pueden corresponder a ruido, a la vez que mantiene una respuesta monótona en la banda de paso, atribuible a valores acertados del pulso cardíaco. El estudio *An optimal filter for short photoplethysmogram signals* (Liang et al., 2018) [?] afirma que Chebyshev tipo II es el filtro con la mejora más efectiva para las señales PPG y destaca su cuarto orden como el óptimo. El rango de frecuencias de corte se establece entre 0.5 y 8Hz, lo que corresponde a un intervalo de 30 a 480 latidos por minuto, cubriendo así la mayoría de las frecuencias cardíacas fisiológicas posibles [14]. ¿No es mucho?

Es buena idea poner gráfico comparando señal cruda y filtrada. BMES también lo usa. Las features las vemos después.

5.1.3 HR e IBI

En cuanto al preprocesamiento de HR e IBI, hay que hacer una distinción. `DREAMT_FE` recalcula estas variables a partir de la señal BVP previamente filtrada, ignorando los valores aportados por la propia base de datos y que ya fueron derivadas del sensor PPG. Ante la duda de si optar por esta estrategia o conservar los registros originales, se realizó un análisis con una secuencia aleatoria. Para ello, se filtró BVP y se recalcularon HR e IBI a partir de esta señal, siguiendo el ejemplo de `DREAMT_FE`. A continuación, se compararon los valores obtenidos con los aportados por `DREAMT`. Se observó que, para esa muestra, se obtenían valores de correlación negativos de -0.126 y -0.229 para HR e IBI, respectivamente. Así, demostrando que el cálculo de estas variables con las técnicas de `DREAMT_FE` no se correspondía con la tendencia de los valores aportados por `DREAMT`, se decidió conservar estos últimos.

Así, el preprocesamiento de estas variables se realiza como sigue: Para HR se eliminan los valores improbables, concretando un rango de 30-220 latidos por minuto (bpm), se eliminan outliers de cara a la extracción de características y se normaliza por sujeto [12]. El motivo de esta decisión reside en que un mismo valor de HR puede tener un significado fisiológico distinto dependiendo del sujeto, por lo que la normalización por sujeto permite contextualizar cada medición dentro de su rango habitual. De esta manera, el modelo puede aprender a identificar patrones de variación de HR que sean indicativos de las etapas del sueño, independientemente de la frecuencia cardíaca basal de cada individuo. Por ejemplo, la fase REM se caracteriza por una mayor variabilidad de la frecuencia cardíaca, similar a la de la vigilia, mientras que los episodios de fase NREM suelen mostrar una disminución progresiva del HR para permitir la recuperación cardiovascular [?].

Respecto a IBI se eliminan los registros fisiológicamente imposibles siguiendo la fórmula $IBI = 60 / HR$ y se quitan outliers por sujeto. De IBI se extrae la variabilidad de la frecuencia cardíaca (HRV) y sus features. Las features de HR son estadísticas.

MAÑANA TIENES QUE TENER EL CÓDIGO DEL PREPROCESAMIENTO DE HR E IBI. DESPUÉS DE ESO TE PONES CON LA EXTRACCIÓN DE FEATURES DE AMBOS Y BVP. SOLO CUANDO ACABES ESO EMPEZAMOS CON ACC. CONTEMPLAR SERIAMENTE DEJAR TEMP Y EDA PARA DESPUÉS.

5.1.4 ACC

Parece que los atributos anteriores ya lo tengo claro. El ojetivo de esta tarde es tener un script con su preprocesamiento y otro con la feature extraction. Hay que ir documentando las decisiones. Si me da tiempo empiezo a ver cómo cojones se tiene que preprocesar la ACC.

5.1.5 EDA

5.1.6 TEMP

Tabla 5.1: Implementaciones del script `feature_engineering.py` de DREAMT_FE consultadas en cada funcionalidad.

Funcionalidad	Implementación	Discrepancias
Preprocesamiento BVP	<code>preprocess_BVP</code>	Orden 4 en vez de 10 y rango máximo de 8Hz en vez de 15Hz
Preprocesamiento IBI/HR	<code>clean_IBI</code>	De momento no se va a recalcular HR y IBI, los filtramos y ya.
Preprocesamiento ACC	<code>preprocess_ACC</code>	Actividad motora de la muñeca en tres ejes espaciales.
Temperatura	TEMP	Temperatura cutánea periférica de la muñeca.

5.2 Descripción y justificación de la implementación de RF y SHAP

Decimos que se usa scikit-learn, hablamos de la partición train/test, métricas de evaluación elegidas, etc... y por qué

5.3 Posibles probaturas

- Probar evaluación GroupKFold por conjuntos de sujetos y LOSO.
- Hiperoptimización de parámetros de RF.
- Balancear clases con ADASYM/SMOTE o no.
- ¿Distintos modelos? De momento solo RF que es el que mejor le va a todo el mundo.
- Separar datos de entrada. Solo PPG/BVP para comparar con los modelos que hacen eso. Solo ACC a ver cómo rinde. Combinación de ambos a ver cuánto mejora.
- Otras técnicas de explicabilidad adicionales como Permutation Importance o LIME.

6 Resultados obtenidos

Aquí veremos qué features tienen más relevancia para qué clases. Comparativas entre las variantes que de tiempo a hacer deben ir aquí. Habrá que contrastar con la bibliografía. Ver qué diferencias hay con los modelos que utilizaban menos features o un distinto preprocesamiento.

6.1 Posibles comparativas

- Como usamos más variables, obtendremos mejor resultado que los estudios de solo PPG. Aunque nuestra PPG es de pulsera y no clínica.
- Si clasifico más de 3 etapas, pues la comparativa de resultados entre ellos.

7 Conclusiones y vías futuras

Bibliografía

- [1] National Institute of Child Health and Human Development. ¿Cómo afecta la salud un sueño inadecuado? <https://espanol.nichd.nih.gov/salud/temas/sleep/informacion/inadecuado>, September 2018. Oficina de Comunicaciones, NICHD. Consultado el 5 de junio de 2026.
- [2] Resmed. 2026 Global Sleep Survey. <https://sleepsurvey.resmed.com/>, 2026. Consultado el 5 de junio de 2026.
- [3] Joshua E. Brinkman, Vidyadhar Reddy, and Sandeep Sharma. Physiology of sleep. StatPearls, NCBI Bookshelf, 2023. Available at: <https://www.ncbi.nlm.nih.gov/books/NBK482512/>.
- [4] Joseph Feriante and Joao Francisco Araujo. Physiology, rem sleep. StatPearls, NCBI Bookshelf, 2023. Available at: <https://www.ncbi.nlm.nih.gov/books/NBK531454/>.
- [5] Oumaima Benkirane, Mounir Chennaoui, Adrien Gauthier, Pierrick J. Arnal, Collette Drogou, Fabien Sauvet, and Danielle Gomez-Merino. Impact of sleep fragmentation on cognition and fatigue. *International Journal of Environmental Research and Public Health*, 19(23):15485, 2022. doi: 10.3390/ijerph192315485.
- [6] Jessica V. Rundo and Ralph Downey. Polysomnography. *Handbook of Clinical Neurology*, 160:381–392, 2019. doi: 10.1016/B978-0-444-64032-1.00025-4.
- [7] Florentin Smarandache, Satyasri Akula, Saleh I. Alzahrani, Farrukh Arslan, and Amir Ijaz. PPG-Based Sleep Stage Classification Using Pulse Wave Feature Fusion and Explainable AI. *Engineering, Technology & Applied Science Research*, 15(5): 27640–27645, 2025. doi: 10.48084/etasr.13077. URL <https://etasr.com/index.php/ETASR/article/view/13077>.
- [8] Md Abdul Motin, Chandan K. Karmakar, Thomas Penzel, and Marimuthu Palaniswami. Sleep-Wake Classification Using Statistical Features Extracted from Photoplethysmographic Signals. In *2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. IEEE, 2019. doi: 10.1109/EMBC.2019.8857302.
- [9] Md Abdul Motin, Chandan K. Karmakar, Marimuthu Palaniswami, and Thomas Penzel. Photoplethysmographic-Based Automated Sleep–Wake Classification

- Using a Support Vector Machine. *Physiological Measurement*, 41(7):075013, 2020. doi: 10.1088/1361-6579/ab948c.
- [10] Karmen Markov, Mohamed Elgendi, Vera Birrer, and Carlo Menon. Interpretable feature-based machine learning for automatic sleep detection using photoplethysmography. *npj Biosensing*, 2(24), 2025. doi: 10.1038/s44328-025-00041-2. URL <https://www.nature.com/articles/s44328-025-00041-2>.
- [11] Mario Giovanni Terzano, Liborio Parrino, A. Sherieri, Ronald Chervin, Sudhansu Chokroverty, Christian Guilleminault, Max Hirshkowitz, Mark Mahowald, Harvey Moldofsky, Angela Rosa, Robert Thomas, and Arthur Walters. Atlas, Rules, and Recording Techniques for the Scoring of Cyclic Alternating Pattern (CAP) in Human Sleep. *Sleep Medicine*, 2(6):537–553, November 2001. doi: 10.1016/S1389-9457(01)00149-6. Erratum in: *Sleep Medicine*, 2002 Mar;3(2):185.
- [12] Jean Lee, Shaurya Bisht, and Grace X. Gao. Gender-Specific Machine Learning Modeling for Sleep Stage Classification Using Wearable Device Data. Poster presented at the 2024 BMES Annual Meeting, 2024. URL <https://2024bmesannual.eventscribe.net/ajaxcalls/PresentationInfo.asp?PresentationID=1504942>. Poster 80, Biomedical Engineering Society Annual Meeting, October 26, 2024.
- [13] Ke Wang, Jiamu Yang, Ayush Shetty, and Jessilyn Dunn. DREAMT: Dataset for Real-time sleep stage Estimation using Multisensor wearable Technology. *PhysioNet*, June 2026. doi: 10.13026/3f7y-2d80. URL <https://doi.org/10.13026/3f7y-2d80>. Version 2.2.0.
- [14] Vasco António Portilho Carvalho da Silva. Ensemble AI Solutions for Personalized Sleep Monitoring Using Wrist-worn Wearables. Master’s thesis, Instituto Superior de Engenharia do Porto, Polytechnic Institute of Porto, 2025. URL <http://hdl.handle.net/10400.22/31317>.
- [15] Xuan Chen, Rui Wang, Phyllis Zee, Pamela L. Lutsey, Sogol Javaheri, Carmela Alcántara, Chandra L. Jackson, Michelle A. Williams, and Susan Redline. Racial/Ethnic Differences in Sleep Disturbances: The Multi-Ethnic Study of Atherosclerosis (MESA). *Sleep*, 38(6):877–888, June 2015. doi: 10.5665/sleep.4732.
- [16] Will Ke Wang, Jiamu Yang, Leeor Hershkovich, Hayoung Jeong, Bill Chen, Karnika Singh, Ali R. Roghanizad, Md Mobashir Hasan Shandhi, Andrew R. Spector, and Jessilyn Dunn. Addressing wearable sleep tracking inequity: A new dataset and novel methods for a population with sleep disorders. In Tom Pollard, Edward Choi, Pankhuri Singhal, Michael Hughes, Elena Sizikova, Bobak Mortazavi, Irene Chen, Fei Wang, Tasmie Sarker, Matthew McDermott, and Marzyeh Ghassemi, editors, *Proceedings of the Fifth Conference on Health, Inference, and Learning*,
-

- volume 248 of *Proceedings of Machine Learning Research*, pages 380–396. PMLR, 27–28 Jun 2024. URL <https://proceedings.mlr.press/v248/wang24a.html>.
- [17] Ary L. Goldberger, Luis A. N. Amaral, Leon Glass, Jeffrey M. Hausdorff, Plamen Ch. Ivanov, Roger G. Mark, Joseph E. Mietus, George B. Moody, Chung-Kang Peng, and H. Eugene Stanley. PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. *Circulation*, 101(23):e215–e220, 2000. doi: 10.1161/01.CIR.101.23.e215. RRID:SCR_007345.
- [18] Ian F Akyildiz, Dario Pompili, and Tommaso Melodia. Underwater acoustic sensor networks: research challenges. *Ad hoc networks*, 3(5):257–279, 2005.
- [19] Mary Shaw and David Garlan. *Software architecture: perspectives on an emerging discipline*, volume 1. Prentice Hall Englewood Cliffs, 1996.
- [20] BOE. Resolución de 7 de marzo de 2012, de la universidad de alicante, por la que se publica el plan de estudios de graduado en ingeniería multimedia. BOE, 22 marzo de 2012, marzo 2012. URL <http://www.boe.es/boe/dias/2012/03/22/pdfs/BOE-A-2012-4008.pdf>.
- [21] AENOR. norma une 50136:1997., 1997. URL http://docubib.uc3m.es/CURSOS/Documentos_cientificos/Normas%20y%20directrices/UNE_50136=ISO%207144.pdf.
- [22] A Barkan, Robert L Merlino, and N D’angelo. Laboratory observation of the dust-acoustic wave mode. *Physics of Plasmas*, 2(10):3563–3565, 1995.
- [23] Timothy Leighton. *The acoustic bubble*. Academic press, 2012.
-

Lista de Acrónimos y Abreviaturas

AAS	Australian Acoustical Society.
ADAA	Asociación de Acústicos Argentinos.
AES	Audio Engineering Society.
APA	American Psychological Association.
ASA	Acoustical Society of America.
CSIC	Consejo Superior de Investigaciones Científicas.
EAA	European Acoustics Association.
I-INCE	International Institute of Noise Control Engineering.
ICA	International Congress on Acoustics.
IEEE	Institute of Electrical and Electronics Engineers.
IIAV	International Institute of Acoustics and Vibration.
IOA	Institute Of Acoustics.
ISRA	International Symposium on Room Acoustics.
ISVA	International Seminar on Virtual Acoustics.
SEA	Sociedad Española de Acústica.
TFG	Trabajo Final de Grado.
TFM	Trabajo Final de Máster.