



Clasificación de etapas del sueño a partir de señales de dispositivos wearable mediante modelos de aprendizaje automático interpretables

Grado en Ingeniería Informática

Trabajo Fin de Grado

Autor:

Alejandro Cerezal Jiménez

Tutor/es:

Manuel Campos Martínez



Facultad
de Informática
UMU

Clasificación de etapas del sueño a partir de señales de dispositivos wearable mediante modelos de aprendizaje automático interpretables

Análisis de la importancia de las características fisiológicas
en la clasificación de etapas del sueño.

Autor

Alejandro Cerezal Jiménez


Tutor/es

Manuel Campos Martínez

Departamento de Informática y Sistemas



UNIVERSIDAD
DE MURCIA



Facultad
de Informática

Grado en Ingeniería Informática

Murcia, 12 de Junio de 2026

Convocatoria de Junio

Índice general

1. Introducción	1
2. Estado del arte	3
2.1. Estudios basados en rendimiento	4
2.2. Estudios basados en explicabilidad	4
3. Análisis de objetivos	9
3.1. Justificación del trabajo	9
3.2. Objetivos específicos	10
4. Materiales	11
4.1. Base de datos DREAMT	11
4.2. Explicación de RF y SHAP	13
5. Metodología	15
5.1. Descripción y justificación del preprocesamiento y extracción de features	15
5.1.1. Introducción	15
5.1.2. Preprocesamiento	16
5.1.3. Extracción de características	19
5.1.4. Selección de features	22
5.2. Descripción y justificación de la implementación de RF y SHAP	22
5.2.1. Tratamiento de los datos de entrada	23
5.2.2. Implementación de RF	23
5.2.3. Implementación de explicabilidad con SHAP	24
5.3. Posibles probaturas	24
6. Resultados obtenidos	25
6.1. Posibles comparativas	25
7. Conclusiones y vías futuras	27
Bibliografía	29
Lista de Acrónimos y Abreviaturas	33
A. Anexo I: Características extraídas	35

Índice de figuras

5.1.	Comparación entre la señal cruda y filtrada del eje Z de acelerometría, ambas centradas en 0.	18
5.2.	Comparación entre la señal cruda y filtrada EDA, tanto a escala original comocentradas en 0.	19

Índice de tablas

4.1.	Resumen visual de las señales de Empatica E4 disponibles en DREAMT.	12
5.1.	Implementaciones del script <code>feature_engineering.py</code> de DREAMT_FE consultadas en cada funcionalidad.	18
A.1.	Características extraídas por señal.	35

Índice de Códigos

1. Introducción

Un buen descanso es vital para la salud. La presencia de malos hábitos de sueño da lugar a desequilibrios hormonales y del sistema inmunitario, que pueden derivar progresivamente en patologías crónicas como la diabetes tipo 2, hipertensión arterial, obesidad y trastornos de salud mental tales como la depresión [1]. Por ello, la población global está cada vez más concienciada con la calidad de su sueño. [2]

Desde el punto de vista fisiológico, el sueño no es un estado homogéneo, sino que se organiza en una arquitectura cíclica compuesta por fases de sueño REM (movimiento ocular rápido) y sueño no REM (NREM). El sueño NREM incluye estados progresivamente más profundos, mientras que el sueño REM se caracteriza por una mayor actividad cerebral y se asocia con procesos como la regulación emocional y la consolidación de la memoria. En adultos sanos, el sueño NREM representa aproximadamente el 75–80% del tiempo total de sueño, mientras que el sueño REM supone alrededor del 20–25%, alternándose ambas fases en ciclos de unos 90–120 minutos a lo largo de la noche [3, 4]. Por ello, la calidad del sueño depende de la estabilidad y continuidad de esta arquitectura. La fragmentación del sueño puede modificar la proporción y organización de las fases NREM y REM, reducir la eficiencia del sueño y afectar negativamente a funciones cognitivas como la atención, la inhibición y la sensación subjetiva de fatiga [5]. En consecuencia, el seguimiento de estas fases resulta relevante para evaluar de forma más completa la salud del sueño, detectar alteraciones en su estructura y favorecer intervenciones orientadas a mejorar los hábitos de descanso y el estado general de salud.

La polisomnografía (PSG) se considera el estándar clínico de referencia para el estudio del sueño, ya que permite registrar de forma simultánea múltiples señales fisiológicas, como la actividad cerebral, los movimientos oculares, la actividad muscular, la respiración y la saturación de oxígeno, posibilitando así una identificación precisa de las fases de sueño y de posibles trastornos asociados [6]. Sin embargo, se trata de una técnica costosa, poco accesible y generalmente dependiente de entornos clínicos especializados, lo que dificulta su uso repetido o prolongado en la vida cotidiana. En este contexto, los dispositivos *wearable* han adquirido una relevancia creciente como alternativa cómoda, no invasiva y de bajo coste relativo para el seguimiento longitudinal del sueño, permitiendo recoger señales como acelerometría, frecuencia cardíaca o fotopleletismografía en condiciones domésticas. Esta tendencia refleja un interés cada vez mayor de la población por monitorizar su descanso mediante tecnologías de consumo. En el último año, el porcentaje de usuarios de dispositivos *wearable* que realizan

un seguimiento regular de su sueño ha aumentado de un 16% a un 53% globalmente. [2].

Es por ello que el desarrollo de algoritmos de clasificación de fases del sueño basados en datos recogidos mediante dispositivos *wearable* se ha convertido en un área de investigación activa, con el objetivo de mejorar la precisión y utilidad de estas herramientas para la evaluación del sueño en entornos no clínicos. En este contexto, el presente trabajo se centra en la aplicación de técnicas de aprendizaje automático interpretables para poder clasificar las fases del sueño a partir de datos al alcance de todos los usuarios y, principalmente, tratar de descubrir qué características de las señales fisiológicas son más relevantes para esta tarea, con el fin de que futuras investigaciones puedan poner el foco en los atributos más importantes.

2. Estado del arte

Como se ha mencionado, la monitorización del sueño mediante dispositivos wearable es una tendencia creciente entre la población. Esto, junto a difícil accesibilidad a los entornos clínicos basados en PSG, ha hecho que la clasificación automática de etapas del sueño a partir de señales fisiológicas registradas mediante dispositivos *wearable* se haya consolidado en los últimos años como una línea de investigación relevante dentro del análisis computacional del sueño. Sin embargo, la sustitución o aproximación de la información polisomnográfica mediante señales más limitadas, como acelerometría (ACC), frecuencia cardíaca o fotopletismografía (PPG), plantea todavía importantes retos desde el punto de vista del modelado, la generalización y la fiabilidad de las predicciones.

En la literatura reciente pueden identificarse dos orientaciones principales en el desarrollo de modelos de clasificación de etapas del sueño en este contexto. La primera orientación se centra en el diseño de modelos cada vez más potentes, capaces de capturar dependencias temporales complejas y mejorar las métricas de clasificación respecto a aproximaciones anteriores. En esta línea se sitúan arquitecturas profundas basadas en redes convolucionales, redes recurrentes, mecanismos de atención, modelos híbridos y, más recientemente, arquitecturas secuenciales avanzadas. Estos trabajos suelen priorizar el rendimiento predictivo, buscando aproximarse lo máximo posible a la clasificación profesional determinada con la evidencia obtenida mediante PSG.

La segunda orientación, que es la que marca enfoque adoptado en este trabajo, pone el énfasis en la explicabilidad del modelo y en la comprensión de las variables que influyen en la clasificación de las etapas del sueño. En lugar de buscar el mejor rendimiento posible, estos trabajos intentan construir modelos que permitan analizar qué características extraídas de las señales *wearable* contribuyen en mayor medida a distinguir entre vigilia, sueño REM y sueño NREM. Esta perspectiva es especialmente interesante cuando se trabaja con señales fisiológicas reducidas, ya que permite estudiar hasta qué punto variables como el movimiento corporal, la frecuencia cardíaca o medidas derivadas contienen información útil para aproximar la arquitectura del sueño.

2.1. Estudios basados en rendimiento

Más breve que la siguiente sección, solo por contextualizar lo que se investiga sin entrar en detalles técnicos. A mí me gustaría ponerla aunque no sé si es suficientemente relevante para el TFG. Discutir con tutor.

2.2. Estudios basados en explicabilidad

Vamos a anañizar ahora la literatura actual respectiva a la clasificación de etapas del sueño se centra en el desarrollo de modelos interpretables.

Primera fuente: (Indexación temporal)

En esta línea, Smarandache et al. proponen un modelo interpretable basado en *Random Forest* para la clasificación de etapas del sueño a partir de señales de fotopletiografía (PPG), complementado con explicaciones mediante SHAP [7]. El estudio utiliza registros nocturnos procedentes de 10 voluntarios del Charité Hospital de Berlín [8, 9], todos ellos con trastornos respiratorios del sueño, incluyendo señales PSG y PPG. Las señales se segmentan en épocas de 30 segundos y las etiquetas se obtienen manualmente por expertos.. El trabajo plantea tres tareas de clasificación: una clasificación binaria sueño-vigilia, una clasificación de tres clases diferenciando vigilia, NREM y REM, y una clasificación de cuatro clases con vigilia, sueño ligero, sueño profundo (que dividen NREM) y REM.

Hay dos aspectos especialmente relevantes en este trabajo. En primer lugar, la elección del modelo Random Forest, tras obtener este mejores métricas de clasificación que otros modelos como SVM, KNN y Logistic Regression, así como el uso de SHAP para analizar la importancia de las variables de entrada, lo que permite interpretar qué características extraídas de la señal PPG contribuyen a la clasificación de las etapas del sueño. En segundo lugar, lo que llaman *pulse wave feature fusion*. Esto es, la extracción características estadísticas, temporales y no lineales de la señal PPG medida. La idea fisiológica es que la señal PPG cruda contiene información indirecta como variabilidad cardiovascular, vasodilatación o cambios respiratorios. Estos fenómenos experimentan cambios entre las fases de vigilia, REM y NREM, por lo que se busca que las features mencionadas aporten información discriminativa.

Sin embargo, para reducir dimensionalidad y eliminar variables redundantes, los autores aplican *Recursive Feature Elimination (RFE)* para seleccionar solamente las 10 características más relevantes. El procedimiento es simple, se entrena un modelo con todas las features y se elimina la que menos ha aportado a la clasificación de etapas según SHAP. Este proceso se repite iterativamente hasta conseguir el número de características deseado. El estudio afirma que las 10 features que pasan el filtro, en orden

de aportación general a la clasificación, son: dimensión fractal de Higuchi, complejidad de Hjorth, media geométrica, momento central, factor de forma, valor máximo, media recortada al 25%, valor mínimo, desviación absoluta mediana y media aritmética.

Segunda fuente:

Un enfoque similar es el de Markov et al., que desarrollan un modelo basado en características (feature-based) para la clasificación esta vez solamente entre sueño y vigilia utilizando PPG [10]. En este caso, la base de datos utilizada es la *Cyclic Alternating Pattern Sleep Database* de PhysioNet [11], compuesta por 84 participantes que presentaban trastornos del sueño, a los que se les realizó un registro completo PSG. Para la clasificación sueño-vigilia se emplearon únicamente las señales PPG y las etiquetas que sirvieron como *ground truth* fueron anotadas por expertos basándose en los registros PSG.

Del preprocesamiento de la señal cruda PPG se obtienen finalmente 85.542 épocas de 30 segundos con su correspondiente etiqueta. Uno de los problemas que se trata en el artículo es el desbalanceo de las clases debido a agrupar todas las etiquetas REM y NREM como *Sleep*. Para equilibrar la distribución de 19% *Wake* y 81% *Sleep*, los autores aplican ADASYN para generar de forma adaptativa muestras sintéticas de la clase minoritaria. En el artículo se realiza un exhaustivo procedimiento de extracción y selección de características. Se obtienen inicialmente 330 características por época y se aplica una selección de variables más elaborada que la descrita en la anterior referencia [7]. Tras un test de normalidad, eliminación de variables redundantes por multicolinealidad y la aplicación del método *SelectFromModel* para filtrar las features que se sitúan por debajo de un umbral de importancia, se obtienen finalmente 75 características para el dataset original y 35 para el dataset balanceado con ADASYN.

Tras comparar varios modelos basados en *LightGBM*, *XGBoost* y *Random Forest*, se eligió este último como clasificador principal. Se realiza una optimización de hiperparámetros por *Matthews Correlation Coefficient (MCC)* aplicando secuencialmente *Randomized Search* y *Grid Search*, que concretan una distribución de parámetros óptima para cada dataset. Para evitar fuga de información entre sujetos, se utiliza una estrategia de validación cruzada agrupada por individuos. Se prueban varios tamaños de partición concluyendo que los resultados son estables. Para estudiar el rendimiento entre distintas patologías, se realiza también una validación cruzada *Leave-One-Subject-Out (LOSO)*.

Los resultados demuestran que el modelo en el dataset original obtiene mejor F1 Score (89,05% frente a 81,40% en el dataset balanceado), pero tiene más problemas para detectar la vigilia. Otro aspecto a destacar es que, para la explicabilidad del modelo, se basan en las *feature importances* del Random Forest, observando que la importancia

de las características cambia en función del dataset utilizado.

Sin embargo, este trabajo presenta algunas limitaciones que se exponen en el mismo artículo. La primera de ellas es que la clasificación se limita a dos clases y ni siquiera diferencia las etapas REM y NREM. La segunda es que, pese a que se trabaja con PPG para reivindicar la monitorización del sueño mediante dispositivos *wearable* frente a la PSG, la base de datos se ha obtenido clínicamente y no presenta la variabilidad y el ruido que se encontraría en un entorno de monitorización domiciliaria. También se menciona la posibilidad de trabajar en un futuro con un dataset sin datos sintéticos de ADASYM o de utilizar SHAP para mejorar la interpretabilidad.

Tercera fuente:

También resultan relevantes los trabajos presentados en entornos de conferencia ya que, pese a no poder leer más que el abstract de congreso, nos permiten conocer las tendencias de investigación en el área. En la reunión anual de la Biomedical Engineering Society (BMES) de 2024, Jean Lee, Shaurya Bisht y Grace X. Gao presentan un estudio acerca de modelos específicos de género para la clasificación de etapas del sueño con datos de dispositivos *wearable* [12]. Para ello, utiliza la base de datos DREAMT [13], la cual se describe en profundidad en la sección 4.1, que contiene registros de 100 sujetos con señales procedentes de la pulsera Empatica E4. El estudio, a diferencia de los anteriores, utiliza tanto BVP (equivalente a PPG) como métricas de movimiento y temperatura para evaluar diferentes tareas de clasificación: sueño-vigilia, vigilia-REM-NREM y clasificación de cinco clases con vigilia, N1, N2, N3 y REM. Su principal objetivo es comparar el rendimiento de modelos entrenados con datos de un género específico frente a modelos genéricos.

Se entrenan los modelos *Random Forest* (que vuelve a dar los mejores resultados de clasificación), regresión logística y LASSO, siendo este último modelo el que utilizan para interpretar qué características extraídas de las señales son las más relevantes debido a su capacidad de selección de variables. A la hora de la validación se aplicó LOSO y se corrigió el desbalanceo de clases, especialmente presente en la clasificación de 5 clases por la escasa representación de N1 y N3, mediante SMOTE.

Los resultados del resumen indican que las características de IBI, las variables circadianas y las métricas de acelerometría tienen un papel relevante en la discriminación entre etapas, mientras que N1 y N3 aparecen como clases especialmente difíciles de detectar por su menor representación y por la mayor ambigüedad fisiológica. A su vez, los modelos específicos de género muestran un rendimiento ligeramente superior al modelo genérico, lo que sugiere que las diferencias fisiológicas entre géneros pueden influir en la clasificación del sueño a partir de señales *wearable*.

Cuarta fuente:

Finalmente, Vasco António Portilho Carvalho da Silva expone una tesis en el Instituto Superior de Ingeniería de Porto en la que aborda el uso de dispositivos de muñeca para monitorización personalizada del sueño mediante modelos de inteligencia artificial y técnicas de explicabilidad [14]. La tesis plantea un marco general para integrar datos multimodales procedentes de *wearables*, principalmente PPG y acelerometría, con el objetivo de realizar clasificación de etapas del sueño y detección de apnea.

En la parte dedicada a la clasificación de etapas del sueño, se utiliza un subconjunto de la base de datos MESA Sleep [15], con anotaciones polisomnográficas de expertos en cinco clases: vigilia, N1, N2, N3 y REM. Las señales PPG obtenidas con el dispositivo Actiwatch Spectrum se segmentan en épocas de 30 segundos y se alinean con las etiquetas de la PSG. Posteriormente, se extraen características de la señal PPG relacionadas con la morfología del pulso y con la serie de intervalos entre latidos para cada época. A diferencia de los trabajos anteriores, Silva no trata las épocas de 30 segundos independientemente, sino que las agrupa en ventanas deslizantes de 3 minutos que avanzan cada 60 segundos, es decir, con solapamiento. Se justifica esta segmentación por la naturaleza de las características y se etiquetan en función de la clase mayoritaria dentro de la ventana.

Se experimentó también un problema de desbalanceo de clases, que se resuelve con una estrategia híbrida: SMOTE para generar muestras sintéticas de las clases minoritarias en los conjuntos de entrenamiento y submuestreo aleatorio para equiparar las proporciones en los conjuntos de validación. Se comparan 6 modelos clásicos con optimización de hiperparámetros y *Random Forest* es el que obtiene mejores métricas globales, aunque sigue teniendo problemas para reconocer N1 debido a la naturaleza fisiológica de esta etapa del sueño.

La interpretabilidad en la tesis se articula de forma distinta en función de si es global o por clases. A nivel de explicabilidad global, se aplica *permutation importance* para evaluar la variabilidad del resultado cuando cada una de las características es permutada. Respecto a la explicabilidad por clases, se utiliza SHAP para concretar las features que más influyen en la predicción de cada etapa del sueño.

Resumen:

En conjunto, estos trabajos muestran que los modelos interpretables de clasificación del sueño suelen compartir una estrategia común: sustituir la entrada directa de señales crudas por un conjunto de características fisiológicas, entrenar modelos clásicos para la clasificación de distinto número de etapas del sueño, y complementar el análisis mediante técnicas de explicabilidad para entender las características que más aportan

a la predicción. Esta orientación resulta especialmente adecuada para trabajos basados en señales *wearable*, ya que permite estudiar qué información aportan realmente la acelerometría, la PPG, la frecuencia cardíaca, la variabilidad del pulso o las variables circadianas en la clasificación de las etapas del sueño. A continuación, tablas comparando distintos ámbitos de los estudios: Métricas, features más relevantes, ...

3. Análisis de objetivos

Una vez analizado el estado del arte, se expone el objetivo general de este trabajo así como los objetivos específicos que se pretenden alcanzar. Aquí se explicará cuál es el objetivo del trabajo. Un modelo RandomForest con explicabilidad SHAP para buscar la importancia de cada feature a la hora de clasificar cada etapa del sueño.

3.1. Justificación del trabajo

El proyecto a realizar se enmarca dentro del ámbito de la clasificación de etapas del sueño a partir de señales procedentes de dispositivos *wearable* mediante modelos de aprendizaje automático interpretables. Concretamente, se empleará un modelo de *Random Forest* para la predicción de las clases vigilia, REM y NREM. La elección de este modelo específico viene motivada por su obtención de mejores métricas de rendimiento en este contexto en comparación con modelos como Regresión Logística, SVM, LASSO, *XGBoost* o *LightGBM*, entre otros, según los estudios previamente mencionados [7, 10, 12, 14].

Para entrenar y validar el modelo, se empleará la base de datos DREAMT. Esta database de PhysioNet contiene registros de señales fisiológicas del sueño capturadas con la pulsera Empatica E4, lo que la convierte en un fuente apropiada para el ámbito de estudio basado en datos recogidos por dispositivos *wearable*. Además, dispone de anotaciones de las etapas del sueño realizadas por expertos, lo que permite una evaluación rigurosa del modelo. Un aspecto a favor de DREAMT respecto a otras bases de datos utilizadas en estudios de la literatura es que, además de la señal PPG que estas ofrecen, contiene registros de acelerometría, actividad electrodérmica y temperatura cutánea, permitiendo un análisis de interpretabilidad más completo.

Siguiendo la línea de los estudios analizados en el estado del arte, el flujo de trabajo comenzará con un preprocesamiento de los datos crudos para la extracción de características con las que alimentar al modelo de clasificación. Este enfoque nos aporta también mayor explicabilidad a la hora de analizar las variables fisiológicas en las que más se apoya el modelo para predecir cada fase. Esto último se implementa mediante SHAP, una técnica que ya emplean o sugieren dichos estudios. Con ella, se analizará la importancia de cada característica tanto a nivel global como para cada etapa del sueño.

3.2. Objetivos específicos

La fiabilidad de la clasificación será estandar, no se busca mejorarla pero debe ser algo parecido a la media de la literatura. El objetivo principal es la interpretabilidad, que se explique qué features son más importantes para cada etapa que vamos a clasificar (de momento 3) y también globalmente.

Así, los objetivos específicos de este trabajo pretende alcanzar son:

- Preprocesar los datos crudos de DREAMT para la extracción de características fisiológicas.
 - Implementar un modelo de clasificación basado en *Random Forest* para predecir las clases vigilia, REM y NREM a partir de las características extraídas.
 - Evaluar el rendimiento del modelo utilizando métricas estándar como precisión, recall, F1-score y matriz de confusión, comparando los resultados con los obtenidos en estudios previos.
 - Aplicar la técnica de explicabilidad SHAP para analizar la importancia de cada característica en la predicción de etapas del sueño, tanto a nivel global como específico para cada clase.
 - Realizar comparaciones en la medida de lo posible con los resultados que han obtenido otros estudios.
-

4. Materiales

En esta sección se describen los materiales y herramientas metodológicas que sustentan el desarrollo del trabajo. Se busca establecer una base clara sobre los datos empleados y sobre las técnicas de aprendizaje automático e interpretabilidad utilizadas para abordar el problema.

4.1. Base de datos DREAMT

DREAMT, acrónimo de *Dataset for Real-time sleep stage EstimAtion using Multi-sensor wearable Technology*, es una base de datos publicada en PhysioNet orientada al estudio de la estimación de etapas del sueño mediante señales procedentes de dispositivos *wearable*. Como ya se ha explicado, su principal interés para este trabajo reside en que combina registros de una pulsera multisensor con anotaciones clínicas de sueño obtenidas a partir de polisomnografía, lo que permite plantear un problema de aprendizaje supervisado en el que las señales recogidas por el dispositivo portátil actúan como entrada y las fases del sueño anotadas por técnicos expertos sirven como *ground truth* [13, 16, 17].

La base de datos fue recopilada a partir de 100 participantes a los que se les realizaba un estudio nocturno del sueño, diseñado principalmente para detectar y monitorizar eventos de apnea durante el sueño, y se les colocaba una pulsera Empatica E4 en la muñeca izquierda. La adquisición combinaba, por tanto, el registro continuo de señales del dispositivo *wearable* con una polisomnografía clínica nocturna realizada mediante el sistema Nihon Kohden Polysmith 1004.

La población incluida en DREAMT corresponde a pacientes procedentes de un laboratorio de trastornos del sueño, con una presencia relevante de alteraciones respiratorias como la apnea obstructiva del sueño. La página oficial de PhysioNet indica una edad media de 56.2 ± 16.6 años, un índice de masa corporal medio de 33.7 ± 8.6 kg/m², un OAHÍ medio de 19.4 ± 27.5 eventos/hora y un AHI medio de 22.1 ± 28.7 eventos/hora. Además, 68 de los 100 participantes presentaban obesidad o obesidad severa, definida como un IMC mayor o igual a 30 kg/m²; entre los 23 participantes con apnea obstructiva del sueño severa, definida como AHI mayor de 30 eventos/hora, 17 eran obesos o severamente obesos. Esta composición convierte a DREAMT en una base de datos especialmente relevante para evaluar modelos de estimación del sueño en una población

clínica, más compleja que una muestra formada únicamente por sujetos sanos.

En cuanto al contenido de la base de datos, se incluyen señales procedentes de la pulsera Empatica E4 y señales de PSG alineadas temporalmente. Las señales del dispositivo *wearable* comprenden seis señales crudas: pulso de volumen sanguíneo o *Blood Volume Pulse* (BVP), acelerometría triaxial en los ejes ACC_X, ACC_Y y ACC_Z, actividad electrodérmica (EDA) y temperatura cutánea (TEMP). Además, se proporcionan dos señales derivadas del BVP: la frecuencia cardíaca (HR) y el intervalo entre latidos (IBI). Estas señales permiten estudiar distintos aspectos fisiológicos relacionados con el sueño, como la actividad cardiovascular, el movimiento corporal y la variación térmica.

Tabla 4.1: Resumen visual de las señales de Empatica E4 disponibles en DREAMT.

Categoría	Señales	Interpretación
Cardiovascular	BVP, HR, IBI	Pulso periférico, frecuencia cardíaca e intervalos entre latidos.
Movimiento	ACC_X, ACC_Y, ACC_Z	Actividad motora de la muñeca en tres ejes espaciales.
Actividad electrodérmica	EDA	Cambios en la conductancia de la piel asociados a activación simpática.
Temperatura	TEMP	Temperatura cutánea periférica de la muñeca.

Las etiquetas de sueño incluidas en DREAMT proceden de las anotaciones realizadas por técnicos expertos a partir de la PSG. Estas etiquetas se proporcionan en épocas de 30 segundos, siguiendo la estructura habitual de los estudios de sueño. Las clases disponibles incluyen vigilia (W), sueño NREM en sus etapas N1, N2 y N3, y sueño REM (R). También se contempla una etiqueta P de preparación previa al inicio del registro polisomnográfico y una etiqueta Missing de datos ausentes en casos puntuales. Para una clasificación simplificada como la de este trabajo, las etapas N1, N2 y N3 pueden agruparse en una única clase NREM, obteniendo así un problema de clasificación en tres clases.

La base de datos se organiza en dos modalidades principales. La carpeta `data_64Hz` contiene únicamente las señales procedentes del dispositivo Empatica E4, remuestreadas a 64 Hz y alineadas mediante una marca temporal común, junto con las etiquetas derivadas de la PSG. Según la documentación oficial, no se aplica preprocesamiento adicional sobre los datos crudos más allá del remuestreo. Por otro lado, la car-

peta `data_100Hz` incluye tanto las señales del dispositivo *wearable* como las señales de polisomnografía, todas ellas remuestreadas a 100 Hz para facilitar su alineamiento temporal. Esta segunda modalidad incorpora canales clínicos como electroencefalograma (EEG), electrocardiograma (ECG), señales respiratorias, ronquido, movimiento de piernas, saturación de oxígeno en sangre y demás registros que no son del interés de este estudio de clasificación a partir de datos recopilados con dispositivos *wearable*.

La carpeta `data_64Hz`, que es la que se empleará en este trabajo, contiene un archivo `.csv` por cada participante, con las señales del dispositivo *wearable* y las etiquetas de sueño correspondientes a cada época de 30 segundos. Cada fila del `.csv` representa una época de 1/64 segundos, con columnas para cada señal (BVP, HR, IBI, ACC_X, ACC_Y, ACC_Z, EDA, TEMP) y una columna adicional *Sleep_Stage* para la etiqueta de la etapa del sueño. Esta estructura facilita el preprocesamiento y la extracción de características necesarias para alimentar al modelo de clasificación.

En definitiva, la elección de DREAMT como base de datos para este trabajo, como ya han realizado otras investigaciones [12], otorga un punto de partida adecuado. Sin embargo, con el objetivo de alcanzar resultados competentes, se requiere un enfoque de extracción de características acertado.

4.2. Explicación de RF y SHAP

Aquí es donde, una vez justificado el uso de RF y SHAP en el capítulo anterior, toca explicarlos teóricamente.

5. Metodología

Se explicará el proceso lógico de preprocesamiento de los datos crudos y toda la extracción de features desde DREAMT. También si se hacen pruebas con las features de entrada.

Supongo que aquí iría bien un gráfico enseñando el flujo de trabajo. Estaría bien poner un plan de ruta: Preprocesamiento DREAMT -> Extracción de features -> ¿Selección de features? -> Clasificación RandomForest -> Explicabilidad SHAP -> Análisis de resultado

5.1. Descripción y justificación del preprocesamiento y extracción de features

Aquí hablaremos cómo hay que tratar DREAMT para conseguir las features que necesitamos.

Esto parece bastante laborioso. Por seguir un orden, para cada paciente tenemos su csv masivo, que tiene una fila por cada 1/64 segundos. Esa fila tiene los atributos medidos (BVP, ACC, etc). Queremos agrupar en épocas de 30 segundos, porque esa es la frecuencia de las etiquetas. ¿Cómo?

Lo primerísimo es quitar los registros P y Missing. No vamos a preprocesar datos cuya etiqueta no nos vale. Se habla también de un control de calidad por sujeto, filtrando por porcentaje de registros fallutos. Como sea, esto tiene pinta de que hay que separarlo por atributos:

5.1.1. Introducción

Los datos recopilados mediante dispositivos *wearable* están expuestos a ruido que puede afectar la calidad de las mediciones. Es por ello que, para asegurar una clasificación de las etapas del sueño lo más rigurosa posible, se debe de realizar un preprocesamiento adecuado de la base de datos. Además de esto, DREAMT contiene registros con distinta frecuencia de muestreo, sensibilidad al ruido y significado fisiológico. Trabajar directamente con las señales crudas exigiría arquitecturas profundas capaces de aprender representaciones temporales complejas, lo que incrementa la dimensionalidad, el

coste computacional y la dificultad de interpretación.

Tanto esta situación como la correspondencia de las anotaciones de etapas del sueño basadas en PSG con épocas de 30 segundos convierten a la extracción de características derivadas de los registros en una estrategia efectiva para resumir la información concentrada en cada una de estas épocas. Este enfoque no solo reduce la dimensionalidad del problema, sino que facilita la explicabilidad del modelo. Las características extraídas pueden relacionarse con mecanismos fisiológicos conocidos, como la reducción del movimiento durante el sueño o los cambios de actividad cardíaca entre REM y NREM.

Para la implementación del preprocesamiento y la extracción de características, se utiliza como base el repositorio abierto `DREAMT_FE` [18]. Sobre su script `feature_extraction.py` se fundamenta toda la implementación del proceso, discrepando solamente en algunas decisiones de diseño. A continuación, se describen las técnicas de preprocesamiento y extracción de características aplicadas a cada uno de los registros utilizados en este estudio: BVP, HR, IBI, ACC, EDA y TEMP.

5.1.2. Preprocesamiento

El preprocesamiento, implementado en el script `preprocess_dreamt_signal.py`, comienza eliminando los registros con etiquetas de sueño P, que corresponden a períodos de preparación y no aportan información relevante para la clasificación. Posteriormente, se preprocesan cada una de las señales tal y como se detalla en los siguientes apartados.

BVP

La señal BVP, muestreada a 64Hz, se filtra mediante un filtro pasabanda Chebyshev tipo II, explicado en la sección (). Este tipo de filtro permite atenuar las componentes frecuenciales situadas fuera de la banda de interés, es decir, las muestras que pueden corresponder a ruido, a la vez que mantiene una respuesta monótona en la banda de paso, atribuible a valores acertados del pulso cardíaco. El estudio *An optimal filter for short photoplethysmogram signals* (Liang et al., 2018) [19] afirma que Chebyshev tipo II es el filtro con la mejora más efectiva para las señales PPG y destaca su cuarto orden como el óptimo. El rango de frecuencias de corte se establece entre 0.5 y 8Hz, lo que corresponde a un intervalo de 30 a 480 latidos por minuto, cubriendo así la mayoría de las frecuencias cardíacas fisiológicas posibles [14]. ¿No es mucho?

Es buena idea poner gráfico comparando señal cruda y filtrada. BMES también lo usa.

HR e IBI

¿Y SI REPITO EL EXPERIMENTO CON UNA NOCHE ENTERA?

En cuanto al preprocesamiento de HR e IBI, hay que hacer una distinción. **DREAMT_FE** recalcula estas variables a partir de la señal BVP previamente filtrada, ignorando los valores aportados por la propia base de datos y que ya fueron derivados del sensor PPG. Ante la duda de si optar por esta estrategia o conservar los registros originales, se realizó un análisis con una secuencia aleatoria. Para ello, se filtró BVP y se recalcularon HR e IBI a partir de esta señal, siguiendo el ejemplo de **DREAMT_FE**. A continuación, se compararon los valores obtenidos con los aportados por **DREAMT**. Se observó que, para esa muestra, se obtenían valores de correlación negativos de -0.126 y -0.229 para HR e IBI, respectivamente. Así, demostrando que el cálculo de estas variables con las técnicas de **DREAMT_FE** no se correspondía con la tendencia de los valores aportados por **DREAMT**, se decidió conservar estos últimos.

Aquí igual se pueden insertar gráficos que apoyen el análisis.

Por tanto, el preprocesamiento de estas variables se realiza como sigue: Para HR se eliminan los valores improbables, concretando un rango de 30-220 latidos por minuto (bpm), se eliminan outliers de cara a la extracción de características y se normaliza por sujeto [12]. El motivo de esta decisión reside en que un mismo valor de HR puede tener un significado fisiológico distinto dependiendo del paciente, por lo que la normalización por sujeto permite contextualizar cada medición dentro de su rango habitual. De esta manera, el modelo puede aprender a identificar patrones de variación de HR que sean indicativos de las etapas del sueño, independientemente de la frecuencia cardíaca basal de cada individuo. Por ejemplo, la fase REM se caracteriza por una mayor variabilidad de la frecuencia cardíaca, similar a la de la vigilia, mientras que los episodios de fase NREM suelen mostrar una disminución progresiva del HR para permitir la recuperación cardiovascular [20].

Respecto a IBI se eliminan los registros fisiológicamente imposibles siguiendo la fórmula $IBI = \frac{60}{HR}$, es decir, para el rango de frecuencia cardíaca previamente seleccionado corresponde un intervalo aproximado de 0.3 - 2 segundos. También se quitan outliers por sujeto y se interpolan. De IBI se extrae la variabilidad de la frecuencia cardíaca (HRV) y sus features. Las features de HR son estadísticas.

ACC

Los valores de acelerometría de **DREAMT** se dividen en mediciones para cada eje espacial (X, Y, Z) y son muestreados a 32Hz. Para su preprocesamiento, **DREAMT_FE** aplica un filtro pasabanda Butterworth de orden 3 con frecuencias de corte de 3 y 10Hz a cada uno de los ejes, utilizando su misma frecuencia de muestreo. La Figura 5.1 presenta una comparación entre la señal cruda **ACC_Z** y la filtrada.




Figura 5.1: Comparación entre la señal cruda y filtrada del eje Z de acelerometría, ambas centradas en 0.

EDA

El preprocesamiento de la actividad electrodérmica (EDA) es algo distinto. La señal está muestreada a 4Hz, por lo que trabaja a esta frecuencia y posteriormente se reconstruye a 64Hz repitiendo los valores 16 veces. Aquí DREAMT_FE hace un detrending local en ventanas de 5 segundos (20 muestras). EXPLICAR DETRENDING. Tras ello, aplica un filtro paso bajo Butterworth de orden 3 con frecuencias de corte de 0.7Hz. Su objetivo es eliminar las oscilaciones rápidas de la señal que podrían corresponder a ruido ya que la EDA, fisiológicamente, tiene cambios lentos [21]. La Figura 5.2 muestra una comparación entre la señal cruda y la filtrada, tanto a escala original como centradas en 0 para apreciar mejor el efecto del filtrado.

Tabla 5.1: Implementaciones del script `feature_engineering.py` de DREAMT_FE consultadas en cada funcionalidad.

Funcionalidad	Implementación	Discrepancias
Preprocesamiento BVP	<code>preprocess_BVP</code>	Orden 4 en vez de 10 y rango máximo de 8Hz en vez de 15Hz
Preprocesamiento IBI/HR	<code>clean_IBI</code>	De momento no se va a recalcular HR y IBI, los filtramos y ya.
Preprocesamiento ACC	<code>preprocess_ACC</code>	Actividad motora de la muñeca en tres ejes espaciales.
Temperatura	<code>TEMP</code>	Temperatura cutánea periférica de la muñeca.




Figura 5.2: Comparación entre la señal cruda y filtrada EDA, tanto a escala original como centradas en 0.

5.1.3. Extracción de características

Una vez preprocesados los registros, se procede a la extracción de características asociadas a épocas de 30 segundos. Como ya se ha mencionado, esta práctica ayuda tanto a sintetizar los datos (reduce las épocas en un factor de 64×30) como a mejorar los resultados de clasificación y facilitar la explicabilidad. Esta metodología, común en toda la literatura referida en el estado del arte, se justifica también por la correspondencia de las anotaciones de etapas del sueño basadas en PSG con épocas de 30 segundos.

En esta sección se detalla el proceso de extracción y selección de features. Esto significa que vamos a poner qué features se extraen originalmente y luego si las eliminamos por multicolinealidad, `selectFromModel` o lo que sea.

`DREAMT_FE` extrae MUCHAS características de las señales BVP, HR e IBI. Entonces se puede probar a usar todas y luego hacer reducción de características por multicolinealidad y orden de importancia en clasificación. Pero esto es una barbaridad, se extraen 130 características en total por época. Habría que filtrarlas y quitar multicolinealidad. Silva usa 32 y ni las trata después, BMES no explicita pero debe usar pocas. Markov sí que usa 330 iniciales para quedarse en 35. Smarandache pasa de 24 iniciales a 10.

De momento se extraen solo features básicas que no vamos a filtrar, dejo para más

adelante lo elaborado.

Para la extracción de características de BVP, HR e IBI, registros que corresponden a la señal PPG con la que han trabajado todos los estudios referidos, se busca un equilibrio entre la metodología que estos han empleado y la llevada a cabo por DREAMT_FE. Respecto al resto de registros, solo presentes en DREAMT, se reproducirá fielmente la extracción descrita en el repositorio.

BVP

De la señal preprocesada se calculan directamente algunas estadísticas básicas [18] y se incluyen otras como la asimetría o la curtosis que han demostrado tener importancia en la clasificación de etapas del sueño [10]. Además, DREAMT_FE hace uso de la librería `NeuroKit2` ¿NO LA EXPLICAS? para, a través de la señal BVP, obtener características de la variabilidad de la frecuencia cardíaca o *Heart Rate Variability* (HRV), incluidas en este apartado por cómo se calcula, a pesar de su estrecha relación con la IBI.

A través de esta librería se obtienen valores relevantes en otros estudios como las features tipo Poincaré (HRV_SD1SD2), características de complejidad como la dimensión fractal de Higuchi (HRV_HFD) y la entropía muestral (HRV_SampEn) o features en dominio frecuencial como la variabilidad de corto plazo de los intervalos entre latidos (HRV_RMSSD) [10, 12, 14]. Además, se amplía la funcionalidad del repositorio calculando la complejidad Hjorth de la señal BVP, relevante para la clasificación global [7, 14].

FALTA IMPLEMENTAR Y EXPLICAR HJORTH.

HR e IBI

La información cardiovascular queda bastante representada con las features anteriores, por lo que para estas dos señales solamente se extraen algunas características estadísticas: la media, la mediana, el valor máximo, el valor mínimo y la desviación estándar.

ACC

La extracción de características de acelerometría es un calco de la de DREAMT_FE. En primer lugar, para cada eje se eliminan los valores situados por debajo del percentil 10 y por encima del percentil 90, reduciendo así la influencia de valores extremos o artefactos puntuales que puedan afectar a las características estadísticas. Sobre la señal resultante se calculan tres medidas: la media recortada, el valor máximo recortado y el rango intercuartílico (IQR). De este modo, para cada eje se generan las características `ACC_X_trimmed_mean`, `ACC_X_trimmed_max`, `ACC_X_trimmed_IQR`, y sus equivalentes

para los ejes Y y Z.

Estas estadísticas también se calculan, además de sobre la señal recortada, sobre la desviación media absoluta de la señal (MAD). En este caso, cada época se divide en subventanas de 5 segundos. Para cada subventana se calcula la MAD respecto a la media local, definida como:

$$MAD = \frac{1}{N} \sum_{i=1}^N |x_i - \bar{x}|, \quad (5.1)$$

donde x_i representa cada muestra de acelerometría dentro de la subventana, $\bar{x}$ es la media de dicha subventana y N es el número de muestras. Este procedimiento sirve para capturar la variabilidad local del movimiento dentro de la época. Como resultado, se obtienen características como `ACC_X_MAD_trimmed_mean`, `ACC_X_MAD_trimmed_max` y `ACC_X_MAD_trimmed_IQR`, junto con sus equivalentes para los ejes Y y Z.

Finalmente, en `DREAMT_FE` calcula una característica global de actividad denominada `ACC_INDEX`. Para ello, primero se obtiene la magnitud vectorial de la aceleración combinando los tres ejes:

$$ACC = \sqrt{ACC_X^2 + ACC_Y^2 + ACC_Z^2}. \quad (5.2)$$

Posteriormente, esta magnitud se divide en bloques de 5 segundos y se calcula la desviación estándar de cada bloque. La característica `ACC_INDEX` se define como la suma de dichas desviaciones estándar a lo largo de la época. Por tanto, esta variable actúa como un índice agregado de actividad motora: valores elevados indican mayor variabilidad de la aceleración y, por tanto, mayor presencia de movimiento durante la ventana analizada.

EDA: INSERTA FOTO CHON

Igual habría que dar alguna explicación fisiológica de EDA y época fásica. Como sea, volvemos a calcar a `DREAMT_FE`.

A partir de la señal EDA preprocesada, se utiliza de nuevo la librería `NeuroKit2` para descomponerla en sus componentes tónica y fásica. La componente tónica representa el nivel basal o lento de conductancia de la piel, mientras que la componente fásica recoge las variaciones rápidas asociadas a respuestas electrodermales puntuales, conocidas como *Skin Conductance Responses* (SCR).

`DREAMT_FE` centra la extracción de características en la componente fásica de la EDA. Para ello, detecta picos SCR a un umbral mínimo de amplitud de 0.1. A partir de los eventos SCR detectados, se consideran cuatro magnitudes principales: la altura (`SCR_Height`), la amplitud (`SCR_Amplitude`), el tiempo de subida (`SCR_RiseTime`)

y el tiempo de recuperación (SCR_RecoveryTime). Estas variables describen tanto la intensidad de las respuestas electrodermales como su dinámica temporal. Para cada una de estas magnitudes, se calculan la media y el valor máximo, generando ocho características EDA por época.

TEMP

¿Cuándo mencionamos y aplicamos el filtro 31-40 grados? La extracción de características de la señal de temperatura cutánea periférica es muy sencilla. Al igual que con HR e IBI, para cada época se calculan cinco estadísticas: la media, la mediana, el valor máximo, el valor mínimo y la desviación estándar.

Features circadianas, temporales y contextuales entre épocas

Es una interesante posible mejora. De momento lo dejamos estar.

Resumen

Aquí se va a poner una tabla con el tipo de características extraídas de cada señal, y en el anexo se pone ya la tabla completa de features detalladas.

5.1.4. Selección de features

Multicolinealidad obligatoria. Si se hace algo más, irá también en esta sección.

5.2. Descripción y justificación de la implementación de RF y SHAP

Decimos que se usa scikit-learn, hablamos de la partición train/test, métricas de evaluación elegidas, optimización de hiperparámetros, etc... y por qué

Si se hace algo parecido a un EDA (análisis exploratorio de datos) con las épocas, va a ir aquí.

Vamos a poner algo de orden, lo siguiente sigue este flujo: Filtrar épocas con mucho NaN -> ¿Balancear clases? -> Implementar RF ¿GroupKFold/LOSO? ¿Optimización hiperparametros? ¿Métricas rendimiento? -> Explicabilidad ¿SHAP/Feature importance/LIME? -> Resultados, comparaciones (conmigo/SOTA) y demás probaturas (nº etapas/features de entrada) en la siguiente sección

5.2.1. Tratamiento de los datos de entrada

Ya hemos extraído de DREAMT las épocas de 30 segundos con sus correspondientes características. Esas épocas van a ser la entrada que reciba nuestro RF, pero habrá que darle una última preprocesada antes, ¿no?

Filtrado de épocas con NaN

Por ejemplo, habrá que evaluar que los valores de las features tengan sentido, y eliminar aquellas épocas que contengan algún feature inválido. Aquí parece que se elimina directamente un sujeto a partir de un porcentaje dado de épocas inválidas. Para pensar. ¿No tendría más sentido hacerlo antes de preprocesar? Igual hacerlo tanto antes como después.

Una solución a lo de arriba es eliminar las épocas con un porcentaje dado de NaN, y las que tengan algunos NaN pero no tanto interpolarlos con la mediana del conjunto de entrenamiento. Hay que ver cómo de factible es eso.

Balanceo de clases

DREAMT_FE usa SMOTE, ¿mejor que ADASYM? Yo creo que para 3 etapas no va a hacer falta, para 4 diría que tampoco. De todas formas, eso se verá cuando tenga un único .csv con todas las épocas y pueda analizar si hay desbalanceo.

Yo creo que es mejor simplemente poner `class_weight = "balanced"` del propio RF. De esta forma, no hay datos sintéticos. Igual se pueden comparar. Consultar con tutor.

5.2.2. Implementación de RF

En este apartado se detalla y explica la implementación del modelo de clasificación basado en *Random Forest*, para lo que se ha usado la librería `scikit-learn`. Ya se ha explicado en Objetivos que se usa porque ha dado buenos resultados, pero se puede hablar de su capacidad de sacar relaciones no lineales y del extra de interpretabilidad que aporta.

Partición train/test

Se va a hacer una separación *GroupKFold* por sujeto, para evitar que el modelo aprenda patrones específicos de cada paciente en vez de patrones generales asociados a las etapas del sueño [10]. Se probarán varios valores de K y se evaluará también el caso extremo correspondiente a *Leave-One-Subject-Out (LOSO)* [10, 12].

Optimización de hiperparámetros

Para elegir los parámetros con los que definir el modelo, se ha optado por optimizarlos mediante *Grid Search CV* utilizando *5-fold GroupKFold* [10, 14]. Markov usa MCC

como métrica de optimización mientras que Silva usa F1-Score. Decidir cuál usar. Los valores de parámetros con los que realiza la búsqueda, intentando aproximar a los que se utilizan en la literatura referida, son los siguientes:

```
n_estimators = [100, 200, 300], max_depth = [10, 20, None]
min_samples_split = [2, 5, 10], min_samples_leaf = [1, 2, 4].
```

Tras la búsqueda, se concluyó que la configuración óptima de entre las seleccionadas era:

Métricas de evaluación

Sensibilidad, precisión, F1-Score, MCC, AUC.

5.2.3. Implementación de explicabilidad con SHAP

Recordatorio de que hay que hacer SHAP global y por etapa. Se aplicarán otros métodos solo si el resto ya está hecho. Piensa en la posibilidad de, tras sacar la explicabilidad, hacer un EDA para ver si coincide con lo obtenido. También se puede hacer antes, a modo de predicción.

5.3. Posibles probaturas

- Probar evaluación GroupKFold por conjuntos de sujetos y LOSO.
 - Optimización de hiperparámetros de RF.
 - Balancear clases con ADASYM/SMOTE o no.
 - ¿Distintos modelos? De momento solo RF que es el que mejor le va a todo el mundo.
 - Separar datos de entrada. Solo PPG/BVP para comparar con los modelos que hacen eso. Solo ACC a ver cómo rinde. Combinación de ambos a ver cuánto mejora. También se puede probar a meter el momento de la noche.
 - Otras técnicas de explicabilidad adicionales como Permutation Importance o LIME.
 - Igual estaría bien correr el modelo con todas las features y luego correrlo seleccionando solo las 30 más importantes, por ejemplo, para ver si cambia la prioridad de cada una.
-

6. Resultados obtenidos

Aquí veremos qué features tienen más relevancia para qué clases. Comparativas entre las variantes que de tiempo a hacer deben ir aquí. Habrá que contrastar con la bibliografía. Ver qué diferencias hay con los modelos que utilizaban menos features o un distinto preprocesamiento.

6.1. Posibles comparativas

- Como usamos más variables, obtendremos mejor resultado que los estudios de solo PPG. Aunque nuestra PPG es de pulsera y no clínica.
- Si clasifico más de 3 etapas, pues la comparativa de resultados entre ellos.

7. Conclusiones y vías futuras

Bibliografía

- [1] National Institute of Child Health and Human Development. ¿Cómo afecta la salud un sueño inadecuado? <https://espanol.nichd.nih.gov/salud/temas/sleep/informacion/inadecuado>, September 2018. Oficina de Comunicaciones, NICHD. Consultado el 5 de junio de 2026.
- [2] Resmed. 2026 Global Sleep Survey. <https://sleepsurvey.resmed.com/>, 2026. Consultado el 5 de junio de 2026.
- [3] Joshua E. Brinkman, Vidyadhar Reddy, and Sandeep Sharma. Physiology of sleep. StatPearls, NCBI Bookshelf, 2023. Available at: <https://www.ncbi.nlm.nih.gov/books/NBK482512/>.
- [4] Joseph Feriante and Joao Francisco Araujo. Physiology, rem sleep. StatPearls, NCBI Bookshelf, 2023. Available at: <https://www.ncbi.nlm.nih.gov/books/NBK531454/>.
- [5] Oumaima Benkirane, Mounir Chennaoui, Adrien Gauthier, Pierrick J. Arnal, Collette Drogou, Fabien Sauvet, and Danielle Gomez-Merino. Impact of sleep fragmentation on cognition and fatigue. *International Journal of Environmental Research and Public Health*, 19(23):15485, 2022. doi: 10.3390/ijerph192315485.
- [6] Jessica V. Rundo and Ralph Downey. Polysomnography. *Handbook of Clinical Neurology*, 160:381–392, 2019. doi: 10.1016/B978-0-444-64032-1.00025-4.
- [7] Florentin Smarandache, Satyasri Akula, Saleh I. Alzahrani, Farrukh Arslan, and Amir Ijaz. PPG-Based Sleep Stage Classification Using Pulse Wave Feature Fusion and Explainable AI. *Engineering, Technology & Applied Science Research*, 15(5): 27640–27645, 2025. doi: 10.48084/etasr.13077. URL <https://etasr.com/index.php/ETASR/article/view/13077>.
- [8] Md Abdul Motin, Chandan K. Karmakar, Thomas Penzel, and Marimuthu Palaniswami. Sleep-Wake Classification Using Statistical Features Extracted from Photoplethysmographic Signals. In *2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. IEEE, 2019. doi: 10.1109/EMBC.2019.8857302.
- [9] Md Abdul Motin, Chandan K. Karmakar, Marimuthu Palaniswami, and Thomas Penzel. Photoplethysmographic-Based Automated Sleep–Wake Classification

- Using a Support Vector Machine. *Physiological Measurement*, 41(7):075013, 2020. doi: 10.1088/1361-6579/ab948c.
- [10] Karmen Markov, Mohamed Elgendi, Vera Birrer, and Carlo Menon. Interpretable feature-based machine learning for automatic sleep detection using photoplethysmography. *npj Biosensing*, 2(24), 2025. doi: 10.1038/s44328-025-00041-2. URL <https://www.nature.com/articles/s44328-025-00041-2>.
- [11] Mario Giovanni Terzano, Liborio Parrino, A. Sherieri, Ronald Chervin, Sudhansu Chokroverty, Christian Guilleminault, Max Hirshkowitz, Mark Mahowald, Harvey Moldofsky, Angela Rosa, Robert Thomas, and Arthur Walters. Atlas, Rules, and Recording Techniques for the Scoring of Cyclic Alternating Pattern (CAP) in Human Sleep. *Sleep Medicine*, 2(6):537–553, November 2001. doi: 10.1016/S1389-9457(01)00149-6. Erratum in: *Sleep Medicine*, 2002 Mar;3(2):185.
- [12] Jean Lee, Shaurya Bisht, and Grace X. Gao. Gender-Specific Machine Learning Modeling for Sleep Stage Classification Using Wearable Device Data. Poster presented at the 2024 BMES Annual Meeting, 2024. URL <https://2024bmesannual.eventscribe.net/ajaxcalls/PresentationInfo.asp?PresentationID=1504942>. Poster 80, Biomedical Engineering Society Annual Meeting, October 26, 2024.
- [13] Ke Wang, Jiamu Yang, Ayush Shetty, and Jessilyn Dunn. DREAMT: Dataset for Real-time sleep stage Estimation using Multisensor wearable Technology. *PhysioNet*, June 2026. doi: 10.13026/3f7y-2d80. URL <https://doi.org/10.13026/3f7y-2d80>. Version 2.2.0.
- [14] Vasco António Portilho Carvalho da Silva. Ensemble AI Solutions for Personalized Sleep Monitoring Using Wrist-worn Wearables. Master’s thesis, Instituto Superior de Engenharia do Porto, Polytechnic Institute of Porto, 2025. URL <http://hdl.handle.net/10400.22/31317>.
- [15] Xuan Chen, Rui Wang, Phyllis Zee, Pamela L. Lutsey, Sogol Javaheri, Carmela Alcántara, Chandra L. Jackson, Michelle A. Williams, and Susan Redline. Racial/Ethnic Differences in Sleep Disturbances: The Multi-Ethnic Study of Atherosclerosis (MESA). *Sleep*, 38(6):877–888, June 2015. doi: 10.5665/sleep.4732.
- [16] Will Ke Wang, Jiamu Yang, Leeor HersHKovich, Hayoung Jeong, Bill Chen, Karnika Singh, Ali R. Roghanizad, Md Mobashir Hasan Shandhi, Andrew R. Spector, and Jessilyn Dunn. Addressing wearable sleep tracking inequity: A new dataset and novel methods for a population with sleep disorders. In Tom Pollard, Edward Choi, Pankhuri Singhal, Michael Hughes, Elena Sizikova, Bobak Mortazavi, Irene Chen, Fei Wang, Tasmie Sarker, Matthew McDermott, and Marzyeh Ghassemi, editors, *Proceedings of the Fifth Conference on Health, Inference, and Learning*,
-

- volume 248 of *Proceedings of Machine Learning Research*, pages 380–396. PMLR, 27–28 Jun 2024. URL <https://proceedings.mlr.press/v248/wang24a.html>.
- [17] Ary L. Goldberger, Luis A. N. Amaral, Leon Glass, Jeffrey M. Hausdorff, Plamen Ch. Ivanov, Roger G. Mark, Joseph E. Mietus, George B. Moody, Chung-Kang Peng, and H. Eugene Stanley. PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. *Circulation*, 101(23):e215–e220, 2000. doi: 10.1161/01.CIR.101.23.e215. RRID:SCR_007345.
- [18] Will Ke Wang and Jerry Yang. DREAMT_FE: DREAMT Feature Engineering Repository. https://github.com/WillKeWang/DREAMT_FE, 2025. GitHub repository. Accessed: 2026-06-09.
- [19] Yongbo Liang, Mohamed Elgendi, Zhencheng Chen, and Rabab Ward. An Optimal Filter for Short Photoplethysmogram Signals. *Scientific Data*, 5:180076, May 2018. doi: 10.1038/sdata.2018.76.
- [20] Philippe Boudreau, Wen-Hsiu Yeh, Guy A. Dumont, and Diane B. Boivin. Circadian Variation of Heart Rate Variability Across Sleep Stages. *Sleep*, 36(12):1919–1928, December 2013. doi: 10.5665/sleep.3230.
- [21] Marcin Jukiewicz and Joanna Marcinkowska. Analysis of electrodermal signal features as indicators of cognitive and emotional reactions—comparison of the effectiveness of selected statistical measures. *Sensors*, 25(11), 2025. ISSN 1424-8220. doi: 10.3390/s25113300. URL <https://www.mdpi.com/1424-8220/25/11/3300>.
- [22] Hugo F. Posada-Quintero and Ki H. Chon. Innovations in Electrodermal Activity Data Collection and Signal Processing: A Systematic Review. *Sensors*, 20(2):479, January 2020. doi: 10.3390/s20020479.
- [23] Ian F Akyildiz, Dario Pompili, and Tommaso Melodia. Underwater acoustic sensor networks: research challenges. *Ad hoc networks*, 3(5):257–279, 2005.
- [24] Mary Shaw and David Garlan. *Software architecture: perspectives on an emerging discipline*, volume 1. Prentice Hall Englewood Cliffs, 1996.
- [25] BOE. Resolución de 7 de marzo de 2012, de la universidad de alicante, por la que se publica el plan de estudios de graduado en ingeniería multimedia. BOE, 22 marzo de 2012, marzo 2012. URL <http://www.boe.es/boe/dias/2012/03/22/pdfs/BOE-A-2012-4008.pdf>.
- [26] AENOR. norma une 50136:1997., 1997. URL http://docubib.uc3m.es/CURSOS/Documentos_cientificos/Normas%20y%20directrices/UNE_50136=ISO%207144.pdf.
-

- [27] A Barkan, Robert L Merlino, and N D'angelo. Laboratory observation of the dust-acoustic wave mode. *Physics of Plasmas*, 2(10):3563–3565, 1995.
 - [28] Timothy Leighton. *The acoustic bubble*. Academic press, 2012.
-

Lista de Acrónimos y Abreviaturas

AAS	Australian Acoustical Society.
ADAA	Asociación de Acústicos Argentinos.
AES	Audio Engineering Society.
APA	American Psychological Association.
ASA	Acoustical Society of America.
CSIC	Consejo Superior de Investigaciones Científicas.
EAA	European Acoustics Association.
I-INCE	International Institute of Noise Control Engineering.
ICA	International Congress on Acoustics.
IEEE	Institute of Electrical and Electronics Engineers.
IIAV	International Institute of Acoustics and Vibration.
IOA	Institute Of Acoustics.
ISRA	International Symposium on Room Acoustics.
ISVA	International Seminar on Virtual Acoustics.
SEA	Sociedad Española de Acústica.
TFG	Trabajo Final de Grado.
TFM	Trabajo Final de Máster.

A. Anexo I: Características extraídas

Tabla A.1: Características extraídas por señal.

Tipo	Feature	Definición breve
BVP: Pulso Sanguíneo Periférico		
Estadística	BVP_mean	Media de la amplitud de la señal BVP.
	BVP_median	Mediana de la amplitud de la señal BVP.
	BVP_std	Desviación estándar de la señal BVP.
	BVP_min	Valor mínimo de la señal BVP.
	BVP_max	Valor máximo de la señal BVP.
	BVP_range	Diferencia entre el máximo y el mínimo.
	BVP_iqr	Rango intercuartílico de la señal BVP.
	BVP_mad	Desviación absoluta media de la señal BVP.
	BVP_rms	Valor cuadrático medio de la señal BVP.
	BVP_skewness	Asimetría de la distribución de amplitudes.
	BVP_kurtosis	Curtosis de la distribución de amplitudes.
Complejidad	BVP_Hjorth_complexity	Complejidad de Hjorth de la señal BVP.
HRV: Variabilidad de la Frecuencia Cardíaca derivada de BVP		
Temporal	HRV_SDNN	Desviación estándar de los intervalos entre latidos.
	HRV_RMSSD	Raíz cuadrática media de diferencias sucesivas entre intervalos.
	HRV_pNN50	Porcentaje de diferencias sucesivas superiores a 50 ms.

Continued on next page

Tabla A.1: Características extraídas por señal. (Continued)

Tipo	Feature	Definición breve
Poincaré	HRV_SD1	Variabilidad de corto plazo en el diagrama de Poincaré.
	HRV_SD2	Variabilidad de largo plazo en el diagrama de Poincaré.
	HRV_SD1SD2	Relación entre la variabilidad de corto y largo plazo.
Complejidad	HRV_HFD	Dimensión fractal de Higuchi de los intervalos cardíacos.
	HRV_KFD	Dimensión fractal de Katz de los intervalos cardíacos.
	HRV_SampEn	Entropía muestral de la variabilidad cardíaca.
HR: Frecuencia Cardíaca		
Estadística	HR_mean	Frecuencia cardíaca media de la época.
	HR_median	Mediana de la frecuencia cardíaca.
	HR_max	Frecuencia cardíaca máxima.
	HR_min	Frecuencia cardíaca mínima.
	HR_std	Desviación estándar de la frecuencia cardíaca.
IBI: Intervalos entre Latidos		
Estadística	IBI_mean	Intervalo medio entre latidos.
	IBI_median	Mediana del intervalo entre latidos.
	IBI_max	Mayor intervalo entre latidos.
	IBI_min	Menor intervalo entre latidos.
	IBI_std	Desviación estándar de los intervalos entre latidos.
ACC: Acelerometría Triaxial		
Estadística recortada	ACC_X_trimmed_mean	Media recortada del eje X.
	ACC_X_trimmed_max	Máximo recortado del eje X.
	ACC_X_trimmed_IQR	Rango intercuartílico recortado del eje X.

Continued on next page

Tabla A.1: Características extraídas por señal. (Continued)

Tipo	Feature	Definición breve
Estadística	ACC_Y_trimmed_mean	Media recortada del eje Y.
	ACC_Y_trimmed_max	Máximo recortado del eje Y.
	ACC_Y_trimmed_IQR	Rango intercuartílico recortado del eje Y.
	ACC_Z_trimmed_mean	Media recortada del eje Z.
	ACC_Z_trimmed_max	Máximo recortado del eje Z.
	ACC_Z_trimmed_IQR	Rango intercuartílico recortado del eje Z.
	ACC_X_MAD_trimmed_mean	Media de la desviación absoluta media del eje X.
	ACC_X_MAD_trimmed_max	Máximo de la desviación absoluta media del eje X.
	ACC_X_MAD_trimmed_IQR	IQR de la desviación absoluta media del eje X.
	ACC_Y_MAD_trimmed_mean	Media de la desviación absoluta media del eje Y.
	ACC_Y_MAD_trimmed_max	Máximo de la desviación absoluta media del eje Y.
	ACC_Y_MAD_trimmed_IQR	IQR de la desviación absoluta media del eje Y.
	ACC_Z_MAD_trimmed_mean	Media de la desviación absoluta media del eje Z.
	ACC_Z_MAD_trimmed_max	Máximo de la desviación absoluta media del eje Z.
	ACC_Z_MAD_trimmed_IQR	IQR de la desviación absoluta media del eje Z.
	ACC_INDEX	Índice agregado de variabilidad de la aceleración.
EDA: Actividad Electrodermal		
Amplitud SCR	SCR_Height_mean	Altura media de las respuestas electrodermales.
	SCR_Height_max	Altura máxima de las respuestas electrodermales.

Continued on next page

Tabla A.1: Características extraídas por señal. (Continued)

Tipo	Feature	Definición breve
Temporal SCR	SCR_Amplitude_mean	Amplitud media de las respuestas electrodermales.
	SCR_Amplitude_max	Amplitud máxima de las respuestas electrodermales.
	SCR_RiseTime_mean	Tiempo medio de subida de las respuestas SCR.
	SCR_RiseTime_max	Tiempo máximo de subida de las respuestas SCR.
	SCR_RecoveryTime_mean	Tiempo medio de recuperación de las respuestas SCR.
	SCR_RecoveryTime_max	Tiempo máximo de recuperación de las respuestas SCR.
TEMP: Temperatura Periférica		
Estadística	TEMP_mean	Temperatura media de la época.
	TEMP_median	Mediana de la temperatura.
	TEMP_max	Temperatura máxima.
	TEMP_min	Temperatura mínima.
	TEMP_std	Desviación estándar de la temperatura.